

MASTER PLAN ESTRATÉGICO & TÉCNICO

AeroCortex

A maior plataforma mundial de gestão e manutenção de drones agrícolas — do nascimento da startup à expansão internacional.

Documento confidencial • Versão 1.0 • 26/07/2026

Nome de trabalho a validar • Foco inicial: DJI Agras • Expansão: XAG, Jacto e mercado global

20 Fases · 22 Capítulos · Master Roadmap

Sumário

Sumário Executivo — AeroCortex

1. A tese em uma frase
2. O problema e a oportunidade
3. Estratégia e defensibilidade (moat)
4. Modelo de receita
5. Arquitetura e produto (o que já está desenhado)
6. Os 4 pilares estratégicos (diferenciais de unicórnio)
7. Roadmap e captação (visão macro)
8. Principais riscos e mitigações
9. Status desta entrega

Capítulo 1 — Estudo Completo de Mercado

- 1.1 Sumario Executivo do Capitulo
- 1.2 Metodologia e Premissas
- 1.3 Dimensionamento de Mercado — TAM, SAM, SOM
- 1.4 Segmentacao Geografica
- 1.5 Analise de Concorrentes e Substitutos
- 1.6 Cadeia de Valor
- 1.7 Mapa de Dores por Persona
- 1.8 Tendencias e Regulacao
- 1.9 Oportunidades Priorizadas, Riscos e Go-to-Market

Capítulo 2 — Business Plan

- 2.1 Missao, Visao e Valores
- 2.2 Posicionamento Estrategico
- 2.3 Estrategia Blue Ocean — Grid ERRC
- 2.4 Diferenciais Competitivos e Moat (Defensibilidade)
- 2.5 Modelo de Receita (Todas as Linhas)
- 2.6 Business Model Canvas (9 Blocos)
- 2.7 Estrategia de Precificacao
- 2.8 Estrategia de Plataforma e Efeitos de Rede
- 2.9 Comparacao de Modelos de Monetizacao e Mix por Fase
- 2.10 Sintese de Custos, Riscos e Prioridade

Capítulo 3 — Roadmap Corporativo (Ano 1/2/3/5/10)

- 3.1 Sumario Executivo do Capitulo
- 3.2 Filosofia do Roadmap — Tres Horizontes e Waves
- 3.3 North Star Metric e Arvore de Metricas
- 3.4 Roadmap por Horizonte
- 3.5 KPIs por Area (metas por horizonte)
- 3.6 OKRs Concretos por Ano
- 3.7 Indicadores de Saude do Negocio (Business Health)
- 3.8 Tabela Mestra — Prioridades, Riscos e Cronograma Macro
- 3.9 Dependencias Criticas e Caminho Critico

Capítulo 4 — Arquitetura da Plataforma

- 4.1 Sumario Executivo do Capitulo
- 4.2 Principios Arquiteturais e Requisitos Nao-Funcionais (NFRs)
- 4.3 Visao de Alto Nivel (C4 Nivel 1 e 2)
- 4.4 Estrategia de Evolucao: Monolito Modular -> Microservicos
- 4.5 Backend — Linguagem e Framework
- 4.6 Frontend
- 4.7 Banco de Dados

- 4.8 Multi-Tenancy — A Decisao Estrutural
- 4.9 Mensageria e Streaming de Eventos
- 4.10 Cache
- 4.11 API Gateway e Versionamento de API
- 4.12 Service Mesh
- 4.13 Cloud e Infraestrutura como Codigo (IaC)
- 4.14 Containers, Kubernetes e Orquestracao
- 4.15 CI/CD, Versionamento, Feature Flags e Estrategia de Deploy
- 4.16 Estrategia de Testes
- 4.17 Observabilidade e Logs
- 4.18 Resiliencia, Alta Disponibilidade, SLO/SLA, Backup e DR
- 4.19 Estimativa de Custo de Infraestrutura por Fase
- 4.20 Riscos Arquiteturais e Mitigacao (consolidado)
- 4.21 Roadmap e Prioridades (resumo)

Capitulo 5 — ERP Especializado em Drones Agrícolas

- 5.1 Sumario Executivo do Capitulo
- 5.2 Filosofia: ERP Vertical vs Horizontal — Por que Construir
- 5.3 Mapa de Modulos do ERP
- 5.4 Modulo CRM, Clientes e Fornecedores
- 5.5 Modulo Financeiro e Fiscal (NF-e / NFS-e / SPED)
- 5.6 Modulo Compras, Estoque e Almoxarifado
- 5.7 Modulo Ordem de Servico (OS por Estagios) — Coracao Operacional
- 5.8 Modulo Agenda e Agendamento
- 5.9 Modulo Pecas, Garantia e Catalogos de Componente Critico
- 5.10 Rastreabilidade Vitalicia por Serial Number e Lote (Cadeia de Custodia)
- 5.11 Portais (Cliente, Tecnico, Gestor, Fabricante, Revenda)
- 5.12 Modelo de Dados Resumido (ER Simplificado)
- 5.13 Integracoes
- 5.14 Analise Build vs Buy vs Compose por Modulo (Decisao Consolidada)
- 5.15 Custos, Cronograma e Prioridade por Fase
- 5.16 Riscos e Mitigacao
- 5.17 Conclusao do Capitulo

Capitulo 6 — Drone Digital Twin

- 6.1 Sumario Executivo do Capitulo
- 6.2 O Que e o Twin — Definicao e Papel na Plataforma
- 6.3 Modelo de Dados do Twin — O Que Armazenar
- 6.4 Comparacao de Abordagens de Modelagem do Twin
- 6.5 Arquitetura de Ingestao de Telemetria
- 6.6 Banco de Series Temporais — TimescaleDB vs InfluxDB
- 6.7 Object Storage para Midia
- 6.8 Ciclo de Vida do Twin
- 6.9 Versionamento de Estado do Twin
- 6.10 API do Twin
- 6.11 Visualizacao — Dashboard e 3D Opcional
- 6.12 Integracao com IA Preditiva, Computer Vision e Health Score
- 6.13 Seguranca, Privacidade e Integridade (LGPD)
- 6.14 Estimativa de Custo, Dificuldade e Cronograma
- 6.15 Riscos e Mitigacao (consolidado)
- 6.16 Conclusao do Capitulo

Capitulo 7 — IA Preditiva (Manutencao Preditiva)

- 7.1 Sumario Executivo do Capitulo
- 7.2 O Que a IA Preditiva Vai Prever
- 7.3 Fundamento Critico: LiPo e o Risco de Incendio

- 7.4 Abordagens de Modelagem — Comparacao e Recomendacao por Tipo
- 7.5 Engenharia de Features a partir do Digital Twin / Telemetria
- 7.6 O Problema do Cold-Start — Como Prever com Poucos Dados
- 7.7 Arquitetura Tecnica dos Modelos
- 7.8 Pipeline MLOps — Coleta -> Features -> Treino -> Validacao -> Deploy -> Drift
- 7.9 Metricas de Avaliacao e Criterios de Aceite
- 7.10 Monitoramento de Drift e Retreino
- 7.11 Explicabilidade, Confianga e Seguranca
- 7.12 Estimativa de Custo, Dificuldade e Cronograma
- 7.13 Riscos e Mitigacao (consolidado)
- 7.14 Conclusao do Capitulo

Capitulo 8 — Computer Vision para Inspecao

- 8.1 Sumario Executivo do Capitulo
- 8.2 Papel do CV na Plataforma e Fluxo de Valor
- 8.3 Taxonomia de Defeitos — O Que a IA Reconhece
- 8.4 Pipeline de Visao — Arquitetura End-to-End
- 8.5 Pre-processamento e Captura Guiada
- 8.6 Estagio de Deteccao — Comparacao de Arquiteturas
- 8.7 Estagio de Segmentacao
- 8.8 Estagio de Classificacao de Severidade
- 8.9 Estagio de OCR de Seriais
- 8.10 Do Defeito ao Laudo e Orcamento Automatico
- 8.11 Estrategia de Dataset e Rotulagem
- 8.12 Active Learning e Human-in-the-Loop (HITL)
- 8.13 Aumento de Dados e Classes Raras
- 8.14 Metricas de Avaliacao
- 8.15 MLOps de Visao
- 8.16 Custos, Cronograma, Riscos e Prioridade
- 8.17 Roadmap por Waves (resumo)

Capitulo 9 — IA Offline / Edge AI

- 9.1 Sumario Executivo do Capitulo
- 9.2 Por Que Offline-First e Requisito (Contexto)
- 9.3 Comparacao de Runtimes de Inferencia Edge
- 9.4 Comparacao de Hardware Edge
- 9.5 Compressao de Modelos — Quantizacao, Destilacao, Pruning
- 9.6 Arquitetura Hibrida — O Que Roda Onde
- 9.7 Escolha de Modelo por Classe de Dispositivo
- 9.8 Assistente LLM Offline
- 9.9 Sincronizacao Automatica Offline-First
- 9.10 Distribuicao e Atualizacao de Modelos (OTA) e Governanca
- 9.11 Stack de Referencia Recomendada por Dispositivo
- 9.12 Custos, Dificuldade e Cronograma
- 9.13 Riscos e Mitigacao
- 9.14 Roadmap por Waves (resumo)

Sumário Executivo — AeroCortex

Documento: Master Plan Estratégico & Técnico · **Versão:** 1.0 (build parcial) · **Data:** 26/07/2026 **Nome de trabalho:** AeroCortex (a validar) · **Foco inicial:** DJI Agras · **Expansão:** XAG, Jacto e mercado global **Aviso:** Todos os números financeiros e de mercado são **ESTIMATIVAS** de trabalho, com premissas explícitas e câmbio de referência **US\$ 1 = R\$ 5,40**. Devem ser marcados **[VALIDAR]** com dados primários (vendas DJI/revendas, ANAC/MAPA, entrevistas com oficinas e DSPs) antes de comprometer capital, contratações ou metas contratuais.

1. A tese em uma frase

O mercado de drones agrícolas cresceu em ritmo de foguete, mas o **pós-venda** — manutenção, peças, baterias, rastreabilidade e compliance — permaneceu na idade da pedra: planilhas, WhatsApp e ERPs genéricos. A **AeroCortex** nasce para ser o **sistema operacional do ciclo de vida do drone agrícola**: um ERP vertical + Digital Twin + IA (preditiva, visão computacional e offline) + marketplace, unindo oficinas, fabricantes, distribuidores de peças, técnicos certificados e produtores em um único ecossistema onde **cada manutenção torna a plataforma mais inteligente**.

2. O problema e a oportunidade

- Frota global estimada:** 500 mil a 1,2 milhão de drones agrícolas, dominada por DJI Agras e XAG, com a China concentrando 60–75% (Cap. 1).
- Gargalo estrutural:** o pós-venda é a maior dor e o menos digitalizado. Uptime = faturamento para o produtor e para a empresa de pulverização (DSP); cada dia parado custa hectares não pulverizados.
- Vazio competitivo (Blue Ocean):** nenhum player oferece hoje uma solução **vertical, multimarca, com rastreabilidade a nível de número de série/peça, marketplace, IA e operação offline**. DJI/XAG cuidam do próprio hardware; ERPs genéricos e softwares de field service não entendem drone.
- Dimensionamento (ESTIMATIVA):** TAM de **US\$ 3,5–7,0 bi/ano** (camada digitalizável global), SAM endereçável em 5 anos de **US\$ 0,7–1,4 bi**, e SOM de 3 anos de **US\$ 8–20 mi** (Brasil/LatAm).

3. Estratégia e defensibilidade (moat)

O posicionamento é o quadrante **específico + preditivo** (Cap. 2). O fosso competitivo é composto e crescente:

Camada de moat	Como funciona	Chapter
Efeito de rede de dados	Cada OS/laudo/telemetria anonimizada melhora a IA de forma não-linear	Cap. 2, 20
Drone Health Score (0–1000)	Índice proprietário tipo "score de crédito do drone" — vira padrão de mercado para revenda, seguro e risco	Cap. 20
Data Lake Global	Base de conhecimento que só a plataforma com mais drones atendidos consegue construir	Cap. 20
Rastreabilidade vitalícia	Cadeia de custódia da peça (fabricante → descarte) via event sourcing — decisão irreversível que nasce no MVP	Cap. 5, 6

North Star Metric: WAMD — *Weekly Active Managed Drones* (drones com dados de saúde/OS fluindo nos últimos 7 dias). $ARR \approx WAMD \times ARPD$. Escolhida por capturar simultaneamente valor entregue, profundidade do moat de dados e potencial de receita (Cap. 3).

4. Modelo de receita

Business model híbrido em camadas, com precificação *value-based* ancorada no **drone ativo gerenciado**, evoluindo de **produto** (Early) → **plataforma** (Growth) → **ecossistema** (Scale). São **14 linhas de receita** (Cap. 2): SaaS por tiers,

marketplace (take-rate), peças, IA por laudo, API, treinamento, certificação, licenciamento, white label, franquias, enterprise, governo, internacional e dados B2B. Unit economics-alvo: **LTV/CAC 3,5–5,0×**, **NRR 115–130%**.

5. Arquitetura e produto (o que já está desenhado)

- **Plataforma (Cap. 4):** cloud-native na AWS (sa-east-1), **monolito modular** (Java 21 + Spring Boot 3; Go para ingestão de telemetria; Python para IA) que evolui para microserviços **só sob dor real de escala**. Postgres 16 + TimescaleDB + pgvector; Kafka + NATS; Redis; Kong; Terraform; Kubernetes/Fargate; observabilidade OpenTelemetry + Prometheus + Grafana + Loki + Tempo. Multi-tenant RLS → schema-per-tenant → database-per-tenant conforme a maturidade. SLA 99,9%, RTO ≤ 1h / RPO ≤ 5min.
- **ERP vertical (Cap. 5):** estratégia **Compose-first** — construir apenas o que é moat (OS por estágios, rastreabilidade serializada, catálogos de componente crítico, peças, garantia/RMA, estoque serializado) e **integrar** o commodity regulatório (NF-e/NFS-e/SPED via middleware, pagamentos, frete, contabilidade). Cinco portais: Cliente, Técnico, Gestor, Fabricante, Revenda.
- **Digital Twin (Cap. 6):** clone digital vivo de cada drone (híbrido snapshot + event sourcing), telemetria em TimescaleDB, mídia em S3, ingestão poliglota (DAT/DJI, MQTT, app offline-first), *time-travel* para reprocessar o Health Score. É o **substrato de dados** de toda a IA.
- **IA Preditiva (Cap. 7):** portfólio de modelos por tipo de predição — sobrevivência (Weibull/Cox/RSF) para RUL, gradient boosting para risco/custo/tempo, detecção de anomalia como rede de segurança no cold-start, deep learning temporal (TFT/LSTM) na fase de dados abundantes. Subsistema dedicado de **risco de incêndio de bateria LiPo** tratado como **segurança funcional** (recall ≥ 0,97, fail-safe conservador, explicabilidade obrigatória).
- **Computer Vision (Cap. 8):** pipeline multiestágio (YOLOv11-seg → RT-DETR; SAM 2 para rotulagem; ConvNeXt/DINOv2 para severidade; OCR de serial; PatchCore para anomalias raras; VLM para redigir o laudo) que reconhece ~25 defeitos e gera **laudo + severidade + risco + custo + tempo + peças + orçamento automático** ligado ao ERP. O moat é o **dataset proprietário**, não a arquitetura.

6. Os 4 pilares estratégicos (diferenciais de unicórnio)

1. **IA Multimodal** — além de fotos: vídeo, **áudio do motor**, telemetria, logs e arquivos DAT da DJI fundidos para diagnóstico mais preciso.
2. **Data Lake Global** — cada manutenção anonimizada alimenta a base; a IA melhora conforme cresce o número de drones atendidos (flywheel de dados).
3. **Marketplace Técnico** — ecossistema *two-sided* conectando oficinas, fabricantes, distribuidores de peças, técnicos certificados e produtores.
4. **Drone Health Score (0–1000)** — o maior diferencial: prever falhas, estimar valor de revenda, precificar seguro e antecipar necessidades de manutenção.

7. Roadmap e captação (visão macro)

Quatro ondas com *gates* de avanço mensuráveis (Cap. 3):

Onda	Horizonte	Tema	WAMD (est.)	ARR (est.)
MVP → GA	Ano 1	Provar PMF no pós-venda BR	1,5k–4k	R\$ 5–9 mi
GA → Scale	Ano 2	Ativar rede (marketplace + IA)	8k–18k	R\$ 14–30 mi
Scale	Ano 3	Escalar plataforma multimarca	25k–50k	R\$ 35–75 mi
Internacional	Ano 5	Líder LatAm + entrada EUA	120k–250k	R\$ 180–380 mi
Plataforma global	Ano 10	SO global do drone agrícola	600k–1M+	R\$ 1,2–3,0 bi

Investimento estimado dos módulos-núcleo já desenhados (ESTIMATIVA, a validar):

Módulo	Custo de construção (R\$)	Prazo	Prioridade
ERP — MVP (moat)	0,9–1,3 mi	6–8 meses	P0
ERP — completo	3,2–4,8 mi	18–24 meses	P1
Digital Twin	0,45–0,82 mi	—	P0
IA Preditiva	0,62–1,15 mi	—	P1
Computer Vision	0,62–1,15 mi (MVP+GA)	—	P0
Infra (opex)	6–13k/mês (MVP) → 262–589k/mês (Scale)	contínuo	—

8. Principais riscos e mitigações

- **Cold-start de dados/IA** → começar com física + regras + detecção de anomalia no dia 1; *human-in-the-loop* gerando rótulos; dados sintéticos para classes raras (Cap. 7, 8).
- **Segurança de bateria LiPo (risco de incêndio)** → subsistema fail-safe conservador tratado como segurança funcional (Cap. 7).
- **Dependência de ecossistema DJI** → arquitetura multimarca desde o início; ingestão poliglota (Cap. 4, 6).
- **Números não validados** → todo o plano é marcado como estimativa; o primeiro *sprint* de negócio é validação de mercado com dados primários (Cap. 1).

9. Status desta entrega

Este build foi finalizado **sob demanda ("entrega agora")** e contém, em profundidade total, os capítulos abaixo. Os demais estão sendo gerados e entrarão na próxima atualização do documento.

#	Capítulo	Status
00	Sumário Executivo	✓ Incluído
01	Estudo Completo de Mercado	✓ Incluído
02	Business Plan	✓ Incluído
03	Roadmap Corporativo (Ano 1/2/3/5/10)	✓ Incluído
04	Arquitetura da Plataforma	✓ Incluído
05	ERP Especializado em Drones Agrícolas	✓ Incluído
06	Drone Digital Twin	✓ Incluído
07	IA Preditiva	✓ Incluído
08	Computer Vision para Inspeção	✓ Incluído
09	IA Offline / Edge AI	✓ Incluído
10	Assistente Inteligente do Técnico	⌚ Em geração
11	Universidade Corporativa e Treinamento	⌚ Em geração
12	Pesquisa Científica e Vigilância Tecnológica	⌚ Em geração
13	Arquitetura de IA (LLMOps/MLOps)	⌚ Em geração
14	Segurança e Compliance (LGPD, ISO 27001)	⌚ Em geração
15	UX/UI	⌚ Em geração
16	Plano Comercial e Captação	⌚ Em geração
17	Plano Financeiro	⌚ Em geração
18	Documentação Técnica	⌚ Em geração
19	Material de Estudo Obrigatório	⌚ Em geração
20	Pilares Estratégicos (Multimodal, Data Lake, Marketplace, Health Score)	⌚ Em geração
21	Master Roadmap (centenas de tarefas ordenadas)	⌚ Em síntese

Base do Master Roadmap: os 8 capítulos concluídos já produziram **124 tarefas acionáveis** (com horas, custo, equipe, dependências, dificuldade, risco e impacto), que serão consolidadas e deduplicadas no Capítulo 21. Amanhã, ao continuar, retomamos a geração dos capítulos 09–21 e regeramos o HTML/PDF completo.

Capitulo 1 — Estudo Completo de Mercado

Aviso metodologico: Todos os numeros de mercado neste capitulo sao **ESTIMATIVAS** construidas pela equipe a partir de premissas explicitas, engenharia reversa de dados publicos e triangulacao top-down/bottom-up. Nao substituem due diligence com fontes primarias. Onde couber, indicamos **[VALIDAR]** com a fonte recomendada. Nenhuma citacao, URL ou numero foi inventado como se fosse fato oficial.

1.1 Sumario Executivo do Capitulo

O mercado de drones agricolas vive um ponto de inflexao: a frota global saltou de nicho para escala industrial, puxada pela DJI Agras (serie T), com XAG em segundo lugar e entrantes como Jacto, Hyllo e fabricantes chineses de segunda linha. Estimamos uma **frota global de 500 mil a 1,2 milhao de unidades** ativas (2026), sendo China responsavel por 60-75%. O Brasil, ainda pequeno em base instalada (**estimativa de 15 a 40 mil unidades**), e o mercado de crescimento mais acelerado fora da Asia, com CAGR estimado de 35-55% a.a.

O gargalo estrutural nao e a venda do drone, e o **pos-venda**: manutencao, pecas, baterias, calibracao, rastreabilidade de horas de voo/hectares e conformidade regulatoria (ANAC/DECEA/MAPA/ANVISA). Hoje esse pos-venda e gerido em **planilhas, WhatsApp e ERPs genericos**, sem rastreabilidade de numero de serie, sem historico de peca, sem IA de diagnostico e sem marketplace. Essa e a dor central que a AeroCortex ataca.

Dimensionamento (estimativas, detalhadas nas secoes 1.3):

Metrica	Valor estimado (global)	Valor estimado (Brasil/LatAm foco inicial)
TAM (economia de pos-venda + software)	US\$ 3,5-7,0 bi/ano	US\$ 250-500 mi/ano
SAM (SaaS + marketplace enderecavel)	US\$ 700 mi-1,4 bi/ano	US\$ 60-120 mi/ano
SOM (3 anos, captura realista)	US\$ 40-90 mi/ano	US\$ 8-20 mi/ano

Recomendacao go-to-market: entrar pelo Brasil (Centro-Oeste e Sul), focando **oficinas/assistencias autorizadas e independentes + empresas de pulverizacao (DSPs)**, com produto SaaS de gestao de OS (ordem de servico) + rastreabilidade de frota + catalogo de pecas, e so depois abrir marketplace e IA de diagnostico.

1.2 Metodologia e Premissas

Usamos **duas metodologias em paralelo** e triangulamos o intervalo onde ambas convergem — pratica padrao em consultoria tier-1 para reduzir vies de fonte unica.


Premissas mestras (explicitas):

Premissa	Valor adotado	Justificativa / [VALIDAR]
Cambio	US\$ 1 = R\$ 5,40	Media 2025-2026; [VALIDAR] BCB PTAX na data do plano
Frota global ativa de drones agricolas	500 mil-1,2 mi	Triangulacao vendas cumulativas DJI Agras + XAG; [VALIDAR] relatorios DJI/XAG e analistas (ex.: Drone Industry Insights, MarketsandMarkets)
% da frota fora da China	25-40%	China e mercado maduro; expansao forte India/Brasil/EUA
Vida util economica do drone	3-5 anos / 800-1.500 h de voo	Desgaste de motores, bombas, ESCs e degradacao de baterias
Gasto anual de manutencao + pecas por drone	US\$ 1.500-4.500	Baterias (maior item), helices, bombas, bicos, motores, ESC, sensores
Baterias por drone/ano	1-3 packs (consumivel)	Ciclo 300-1.000 cargas; item de maior ocorrencia
Ticket medio de OS de manutencao	R\$ 800-6.000	Da revisao simples ao reparo de crash
ARPU SaaS alvo (oficina/DSP)	R\$ 300-2.500/mes	Por tier; detalhado no cap. de pricing
Oficinas/assistencias no Brasil	150-600 pontos	Autorizadas DJI + independentes + revendas com bancada; [VALIDAR] rede oficial

1.3 Dimensionamento de Mercado — TAM, SAM, SOM

1.3.1 Metodologia A — Top-Down

Partimos do tamanho do mercado global de drones agricolas (hardware + servicos), estimado por analistas na faixa de **US\$ 5-12 bi em 2026** (crescendo para US\$ 15-30 bi ate 2030, CAGR 20-30%) **[VALIDAR com Drone Industry Insights, MarketsandMarkets, Grand View Research]**. Aplicamos os cortes:



*O TAM inclui parte do valor de pecas/servicos que transita pela plataforma (GMV do marketplace + SaaS + IA), nao apenas a receita de SaaS. Detalhamos os dois recortes abaixo.

1.3.2 Metodologia B — Bottom-Up

Construimos de baixo para cima, o metodo mais confiavel para o recorte de software:

(1) TAM do pos-venda (wallet total): Frota global x gasto anual manut+pecas/drone

- Baixo: 500.000 x US\$ 1.500 = **US\$ 0,75 bi**
- Alto: 1.200.000 x US\$ 4.500 = **US\$ 5,4 bi**
- Convergencia com top-down: **TAM aftermarket ~US\$ 2,0-5,0 bi**. Somando SaaS e IA -> **TAM total US\$ 3,5-7,0 bi**.

(2) SAM — receita enderecavel pela AeroCortex (SaaS + take-rate de marketplace):

Componente	Formula	Estimativa/ano
SaaS oficinas/DSPs (global enderecavel)	~30-60 mil contas x US\$ 1.200-4.000 ARPU	US\$ 360 mi-2,4 bi
Take-rate marketplace pecas	GMV enderecavel US\$ 1,5-3 bi x take 4-8%	US\$ 60-240 mi
Modulos IA/rastreabilidade premium	15-25% da base x uplift	US\$ 50-150 mi
SAM consolidado (foco realista)		US\$ 0,7-1,4 bi

(3) SOM Brasil/LatAm (3 anos):

Ano	Contas pagas (oficinas+DSPs+frotas)	ARPU medio/mes (R\$)	GMV marketplace (R\$)	Receita total estimada
Ano 1	120-250	700	5-15 mi	R\$ 4-9 mi (US\$ 0,7-1,7 mi)
Ano 2	400-800	900	25-60 mi	R\$ 12-28 mi (US\$ 2,2-5,2 mi)
Ano 3	900-1.800	1.100	70-160 mi	R\$ 30-70 mi (US\$ 5,5-13 mi)

Leitura: o SOM de 3 anos (Brasil/LatAm) converge para **US\$ 8-20 mi/ano**, consistente com capturar 5-8% do SAM regional. Global (com EUA e Asia via parceiros) empurra o teto para US\$ 40-90 mi.

1.4 Segmentacao Geografica

Regiao	Frota estimada	Maturidade	Atratividade inicial	Racional
China/Asia	60-75% da frota	Alta (DJI/XAG saturado em servico)	Media (via parceiro)	Volume gigante, mas competicao local feroz e barreiras de idioma/rede
Brasil	15-40 mil	Media, crescimento explosivo	Muito alta (entrada)	Agro forte, dor de pos-venda aguda, poucos concorrentes de software
America Latina	5-20 mil	Baixa-media	Alta (fase 2)	Argentina, Paraguai, Colombia, Mexico; expansao natural do Brasil
EUA	10-30 mil	Media, alto ticket	Alta (fase 2-3)	Regulacao FAA restritiva (Part 137/44807) cria demanda por compliance; ticket premium
Africa	2-10 mil	Baixa	Media (fase 3+)	Potencial ESG/impacto, mas infra e poder de compra limitados
Europa	5-15 mil	Baixa (EASA restritiva a pulverizacao)	Baixa-media	Regulacao anti-pulverizacao aerea limita TAM; foco em inspecao/mapeamento

Melhor opcao de entrada: Brasil. Justificativa: (1) dor de pos-venda aguda e mal atendida; (2) baixa concorrencia de software especializado; (3) agronegocio digitalmente maduro e disposto a pagar por ROI; (4) equipe/idioma; (5) trampolim natural para LatAm.

Segmentacao por Tipo de Cliente

Segmento	Tamanho relativo	Dor dominante	Disposicao a pagar	Prioridade GTM
Empresas de pulverizacao / DSPs	Alto e crescente	Uptime, custo/ha, gestao de frota	Alta	1 (ancora)
Oficinas/assistencias autorizadas	Medio	OS, pecas, garantia, rastreabilidade	Alta	1 (ancora)
Oficinas independentes	Medio-alto (cauda longa)	Falta de sistema, diagnostico	Media-alta	2
Revendas/distribuidores	Medio	Estoque de pecas, pos-venda	Media	2
Cooperativas	Alto (agregador)	Gestao multi-frota, rateio	Alta	2 (canal poderoso)
Usinas (cana)	Medio, ticket alto	Escala, integracao ERP, compliance	Alta	3
Produtor rural individual	Cauda muito longa	Custo, simplicidade	Baixa-media	3 (self-serve)

1.5 Analise de Concorrentes e Substitutos


Os concorrentes se dividem em **(a) fabricantes/rede oficial**, **(b) softwares horizontais de field service**, e **(c) substitutos improvisados** (planilhas, WhatsApp, ERPs genericos).

Player	Tipo	Cobertura pos-venda drone	IA/diagnostico	Rastreabilidade N/S+peca	Marketplace pecas	Offline/campo	Foco agro-drone
DJI (Care + rede autorizada)	Fabricante	Alta (so DJI)	Baixa	Media (fechada)	Nao (so pecas DJI)	Parcial	Sim (proprietario)
XAG (rede/servico)	Fabricante	Media (so XAG)	Baixa-media	Media (fechada)	Nao	Parcial	Sim (proprietario)
Jacto/entrantes	Fabricante	Baixa (nascente)	Baixa	Baixa	Nao	Nao	Parcial
ServiceMax / IFS	Field service enterprise	Generico	Media	Generica (nao drone)	Nao	Sim	Nao
Fractal / manutencao (CMMS)	Manutencao ativos	Generico	Baixa-media	Generica	Nao	Parcial	Nao
Planilhas / WhatsApp / ERP generico	Substituto	Nula-baixa	Nao	Nenhuma	Nao	Sim (manual)	Nao
AeroCortex (proposto)	Vertical SaaS+marketplace	Multi-marca	Alta (visao)	Alta (N/S, hora, ha, peca)	Sim	Sim	Sim (nucleo)


Insight competitivo: ninguem oferece uma solucao **vertical, multi-marca, com rastreabilidade a nivel de numero de serie/peca, marketplace e IA, funcionando offline no campo**. As redes de fabricante sao silos fechados por marca; os softwares horizontais nao entendem drone agricola (baterias, horas de voo, hectares, calibracao de bicos, crash reports). Esse "vazio de mercado" e o fosso (moat) inicial da AeroCortex.

Matriz de posicionamento (2 eixos):

Especializacao agro-drone vs. Abrangencia de plataforma



1.6 Cadeia de Valor



Onde a AeroCortex captura valor: o elo **oficina/assistencia <-> cliente final (DSP/coop)** e o ponto de maior friccao e menor digitalizacao. A plataforma se posiciona como **sistema operacional do pos-venda**, conectando fabricantes (catalogo/garantia), revendas (estoque de pecas), oficinas (OS/diagnostico) e clientes (frota/uptime), monetizando via SaaS + take-rate de marketplace + modulos de IA.

1.7 Mapa de Dores por Persona

Persona	Principais dores	Custo da dor (estimativa)	Como resolve hoje
Produtor rural	Drone parado em safra; nao sabe historico; medo de peca falsa; janela agronomica perdida	R\$ 200-2.000/ha nao aplicado; multa de safra	Liga para revenda, espera, WhatsApp
Cooperativa	Gerir multi-frota associados; rateio de custo; padronizar manutencao; compliance coletivo	Ociosidade de frota; retrabalho administrativo	Planilhas por associado, ERP generico
Usina (cana)	Escala, integracao ERP (SAP/TOTVS), compliance ambiental, disponibilidade	Downtime x custo/ha x milhares de ha	ERP corporativo sem modulo drone
Empresa de pulverizacao / DSP	Uptime = faturamento; custo por hectare; gestao de baterias; SLA com cliente	Cada dia parado = R\$ 5-30 mil de receita	Controle manual, multiplas planilhas
Oficina / assistencia	Sem sistema de OS; controle de garantia; pecas; historico por N/S; produtividade do tecnico	Perda de margem, retrabalho, disputa de garantia	Caderno, WhatsApp, planilha, ERP fiscal
Tecnico de campo	Diagnostico sem historico; sem manual/peca a mao; offline; sem checklist	Visitas repetidas, erro de diagnostico	Experiencia propria, grupos de WhatsApp
Gestor (frota/servico)	Falta de KPI (MTTR, MTBF, custo/ha, uptime); previsibilidade	Decisao no escuro, capex mal alocado	BI improvisado, relatorios manuais
Fabricante	Visibilidade de campo, qualidade, garantia, fidelizacao de pecas	Custo de garantia, churn de marca	Sistemas fechados por regioao
Revenda/distribuidor	Giro de estoque de pecas; previsao de demanda; pos-venda como receita	Capital preso, ruptura de peca critica	ERP fiscal + feeling

Sintese: a dor transversal e **falta de rastreabilidade e de dados** — ninguem sabe, com precisao, o historico de um drone (horas, ha, quedas, pecas trocadas, garantia). Isso alimenta downtime, disputas de garantia, peca pirata e decisao ruim. **Custo agregado da dor no Brasil: estimativa de R\$ 150-400 milhoes/ano** em ociosidade, retrabalho e perdas de safra [VALIDAR via pesquisa de campo com DSPs].

1.8 Tendencias e Regulacao

Regulacao (fator critico de mercado):

Jurisdicao	Orgao	Impacto no mercado
Brasil	ANAC (RBAC-E 94), DECEA (voo/SARPAS), MAPA/ANVISA (defensivos), IBAMA	Exige cadastro, habilitacao, rastreabilidade de aplicacao — tailwind para software de compliance
EUA	FAA (Part 107, Part 137 exemption, 44807)	Pulverizacao exige waiver + peso >55lb; compliance complexo = demanda por sistema
Europa	EASA	Restritiva a pulverizacao aerea (Diretiva uso sustentavel) — limita TAM de spray, favorece inspecao

Tendencias tecnologicas e de mercado:

- Eletrificacao e baterias** — item de maior ocorrencia de pos-venda; gestao de ciclo de bateria e killer feature.
- BVLOS (voo alem da linha visual)** — abre operacoes maiores; aumenta exigencia de rastreabilidade/manutencao preventiva.
- Swarm (enxame)** — multiplos drones por operacao; escala a complexidade de gestao de frota.
- IA de diagnostico e manutencao preditiva** — de logs de voo/telemetria a previsao de falha (moat de dados).
- Seguros agricolas e de equipamento** — demanda por historico auditavel de manutencao para underwriting/sinistro.
- ESG e rastreabilidade de aplicacao** — pressao por reducao de defensivo e comprovacao ambiental.

PESTEL (resumo)

Fator	Sinal	Implicacao
Politico	Incentivo ao agro; regulacao de drones amadurecendo	Positivo, com risco regulatorio
Economico	Juros/cambio; credito rural	Sensibilidade a capex; SaaS OPEX e vantagem
Social	Escassez de mao de obra rural qualificada	Aumenta adocao de drone e de ferramentas
Tecnologico	Edge AI, baterias, conectividade rural (Starlink)	Viabiliza offline + IA no campo
Ecologico	Pressao ESG, uso racional de defensivo	Rastreabilidade vira exigencia
Legal	ANAC/DECEA/MAPA, LGPD	Compliance como feature vendavel

5 Forcas de Porter

Forca	Intensidade	Comentario
Rivalidade	Media-baixa (software vertical)	Vazio competitivo; alta em field service horizontal
Novos entrantes	Media	Barreira = dados + rede + integracao com fabricantes
Poder do comprador	Media	DSPs/coops negociam, mas dor alta
Poder do fornecedor	Alta (DJI)	Dependencia de API/dados/pecas do fabricante = risco-chave
Substitutos	Media-alta	Planilhas/WhatsApp sao "gratis"; vencer pela dor e ROI

SWOT AeroCortex

Forcas	Fraquezas
Vertical, multi-marca, rastreabilidade, offline, IA, marketplace	Marca nova; dependencia de dados de fabricante; capital inicial
Oportunidades	Ameacas
Vazio de mercado; regulacao pro-compliance; expansao LatAm/EUA; dados como moat	DJI/XAG fecharem ecossistema; entrante bem financiado; mudanca regulatoria

1.9 Oportunidades Priorizadas, Riscos e Go-to-Market


Oportunidades priorizadas

#	Oportunidade	Impacto	Dificuldade (1-5)	Prioridade
1	SaaS de OS + rastreabilidade para oficinas/DSPs (BR)	Alto	3	P0
2	Modulo compliance ANAC/DECEA/MAPA	Alto	3	P0
3	Gestao de baterias e frota (uptime/custo-ha)	Alto	3	P1
4	Marketplace de pecas multi-marca	Muito alto	4	P1
5	IA de diagnostico/preditiva (moat de dados)	Muito alto	5	P2
6	Canal via cooperativas (agregador)	Alto	2	P1
7	Expansao LatAm e EUA (compliance premium)	Alto	4	P2

Riscos de mercado + mitigacao

Risco	Prob.	Impacto	Mitigacao
DJI/XAG fecharem API/dados ou lancarem software proprio	Media	Alto	Multi-marca, dados proprios via app do tecnico, foco em oficina independente
Adocao lenta (cultura de planilha)	Media	Alto	Onboarding assistido, ROI claro, free tier, integracao WhatsApp
Mudanca regulatoria (restringir pulverizacao)	Baixa-media	Alto	Diversificar para mapeamento/inspecao; compliance como feature
Entrante bem financiado	Media	Medio	Velocidade, moat de dados, rede de oficinas
Cambio/juros comprimindo capex do agro	Media	Medio	Modelo OPEX/SaaS, precos em R\$

Go-to-Market inicial recomendado



Recomendacao final: ancorar em **oficinas autorizadas/independentes e DSPs no Brasil** com um SaaS de OS + rastreabilidade + compliance (dor aguda, ROI imediato, baixo CAC via rede), usar **cooperativas como canal de distribuicao**, e construir o **moat de dados** que habilita marketplace e IA nas ondas seguintes. Melhor opcao por combinar maior dor, menor concorrência e caminho natural de expansão regional.

Capitulo 2 — Business Plan

Escopo: Este capitulo define a espinha dorsal comercial da AeroCortex (nome de trabalho, a validar) — a plataforma de gestao e manutencao de drones agricolas com foco inicial em **DJI Agras** e expansao para **XAG, Jacto** e todo o mercado. Aqui consolidamos missao/visao/valores, posicionamento, a estrategia Blue Ocean, o moat de dados, o modelo de receita completo (todas as linhas), o Business Model Canvas e a estrategia de precificacao.

Aviso metodologico: Todos os numeros financeiros e de mercado sao **ESTIMATIVAS** de trabalho, construidas por analogia (SaaS vertical B2B, fleet management, marketplaces de pecas) e premissas explicitas. **Cambio de trabalho:** US\$ 1,00 = R\$ 5,40. Devem ser validados com fonte primaria (dados de vendas DJI/revendas, ANAC/MAPA, entrevistas com operadores) antes de qualquer decisao de investimento.

2.1 Missao, Visao e Valores

Missao

Manter cada drone agricola do mundo voando com o maximo de disponibilidade, seguranca e retorno por hectare — transformando manutencao reativa em inteligencia preditiva.

A missao ancora a proposta de valor na dor economica real do operador: **downtime na janela de aplicacao custa safra**. Um Agras parado em plena janela de pulverizacao pode representar perda de R\$ 5.000 a R\$ 20.000/dia em faturamento de servico (ESTIMATIVA: 150–400 ha/dia x R\$ 30–50/ha).

Visao (10 anos)

Ser o sistema operacional global da manutencao e operacao de drones agricolas — o "CarFax + Salesforce + AWS" do setor — presente em >50 paises e cobrindo >70% da frota ativa de pulverizacao.


Valores

Valor	Traducao operacional
Seguranca primeiro	Nenhuma recomendacao de IA sobrepoee checklist de aeronavegabilidade; rastreabilidade total de laudos.
Dado como ativo do cliente	Operador e dono do seu dado; monetizamos agregados anonimizados com consentimento (opt-in).
Obcecados por uptime	Metrica-norte interna = disponibilidade da frota dos clientes.
Aberto e interoperavel	APIs abertas, sem lock-in artificial de hardware.
Bilingue campo-engenharia	Produto usavel por tecnico de barracao e por engenheiro de dados.

2.2 Posicionamento Estrategico

Statement de posicionamento: Para operadores, prestadores de servico e revendas de drones agricolas que perdem receita com downtime e falta de rastreabilidade, a AeroCortex e a plataforma de gestao e manutencao preditiva que unifica saude da frota, pecas, laudos com IA e conformidade regulatoria — diferente de planilhas, do app nativo do fabricante e de ERPs genericos, porque foi construida especificamente para a operacao de pulverizacao aerea e melhora a cada manutencao registrada.

Posicionamento competitivo



Por que este quadrante é defensável: o app nativo do fabricante nunca será multimarca (conflito estratégico com XAG/Jacto) e ERPs genéricos nunca terão o modelo de dados de aeronavegabilidade de drone. Ocupamos o canto superior-direito sozinhos.

2.3 Estratégia Blue Ocean — Grid ERRC

A lógica Blue Ocean: em vez de competir de frente com o app do fabricante (oceano vermelho de features de voo), criamos um **espaço de mercado novo** — a camada de gestão, manutenção e finanças da frota — onde a concorrência é irrelevante.


Grid Eliminar-Reduzir-Aumentar-Criar

Dependência de planilhas e grupos de WhatsApp para histórico	Custo/tempo de diagnóstico manual em barracão
Lock-in de marca única (so DJI)	Complexidade de onboarding (setup em minutos, não dias)
Papelada física de laudos e ordens de serviço	Dependência de técnico especialista para triagem inicial
AUMENTAR	CRIAR
---	---
Rastreabilidade e valor de revenda do drone	Drone Health Score (índice 0–100 preditivo, portátil)
Disponibilidade (uptime) da frota	Data Lake Global com benchmarking anônimo entre operadores
Velocidade de acesso a peças certas	Laudos de IA por foto/log/áudio de defeito
Confiança em conformidade (ANAC/MAPA)	Passaporte digital do drone (histórico que segue o ativo na revenda)

Curva de valor — insight central: competidores investem pesado em "features de voo/mapeamento". Nos investimos onde ninguém investe: **saude preditiva, economia de pecas, conformidade e liquidez de revenda**. Isso muda o eixo de competicao de "quem voa melhor" para "quem opera com menor custo total de propriedade (TCO)".

2.4 Diferenciais Competitivos e Moat (Defensibilidade)

Tres ativos compostos criam um fosso que aumenta com o tempo:



Moat	O que e	Por que e defensavel
Efeito de rede de dados	Cada manutencao/falha registrada treina os modelos; precisao cresce com N.	Entrante novo começa com dados zerados; não consegue igualar o Health Score sem escala equivalente.
Drone Health Score	Indice preditivo 0–100 por drone e por frota, padrao de mercado.	Vira "moeda" na revenda e na aceitacao de seguro — efeito de padrao (standard lock-in).
Data Lake Global	Repositorio agregado e anonimizado de MTBF, modos de falha, custo de peca por regioao.	Ativo unico, não replicavel; base para receita de dados B2B (fabricantes, seguradoras).
Custo de troca (switching cost)	Historico completo do ativo vive na plataforma; migrar = perder passaporte digital.	Aumenta com o tempo de uso; ancora recorrência.
Conformidade embarcada	Templates ANAC/MAPA e trilha de auditoria.	Barreira regulatoria local dificil para players estrangeiros.

Como cada manutencao aumenta o valor do dado (o coracao do modelo): cada ordem de servico adiciona um par (sintoma → causa → peca → resultado). Com milhares desses pares, a IA prediz falhas antes que ocorram (ex.: "ESC do motor 3 com 78% de probabilidade de falha em 40 horas de voo"). Isso converte manutencao **corretiva (cara, com downtime)** em **preditiva (barata, agendada)** — o unico ativo que competidor nenhum copia sem passar pelos mesmos milhares de voos.

2.5 Modelo de Receita (Todas as Linhas)

Arquitetura de receita em **tres camadas**: (1) recorrente/previsivel (SaaS), (2) transacional/variavel (marketplace, IA, pecas), (3) estrategica/alavancada (licenciamento, white label, dados, governo). Premissa: diversificacao reduz risco de concentracao e aumenta LTV.

2.5.1 Tabela mestre de linhas de receita (ESTIMATIVA)

#	Linha	Descrição	Pricing sugerido (R\$ / US\$)	Unit economics-chave	% receita @Scale (est.)
1	SaaS Assinatura (tiers)	Núcleo recorrente por drone/assento.	Ver 2.5.2. Free / Pro R\$249 (US\$46) por drone/mes / Business R\$1.490 (US\$276)/mes / Enterprise sob consulta	Margem bruta ~85%; CAC recuperado em 6–10 meses	40%
2	Marketplace de serviços	Conecta operador a técnico/oficina credenciada.	Take-rate 12–18% do valor do serviço	GMV médio/serviço R\$800; receita R\$96–144	8%
3	Receita por Peças	E-commerce/dropship de peças e consumíveis (hélices, bicos, baterias, ESC).	Markup 15–25% ou take-rate 10–15% em terceiros	Ticket médio R\$450; margem R\$70–110	12%
4	Receita por IA (por uso/laudo)	Laudo diagnóstico por foto/log/áudio; créditos de IA.	R\$29–89 (US\$5–16) por laudo; pacotes de créditos	Custo marginal de inferência ~R\$3–8; margem >85%	9%
5	Receita por API	Acesso programático (dados de frota, Health Score) para ERPs/revendas.	R\$0,05–0,50/chamada; planos R\$990–9.900/mes	Margem ~90%; sticky (integração)	4%
6	Receita por Treinamento	Cursos de operação/manutenção/piloto, on-demand e presencial.	R\$390–2.900 (US\$72–537) por trilha; B2B corporativo	Margem 60–75% (conteúdo reutilizável)	4%
7	Receita por Certificação	Selo "Técnico Certificado AeroCortex" / oficina credenciada.	R\$490–1.900/ano por profissional/oficina	Recorrente anual; reforça marketplace	3%
8	Licenciamento	Licença de tecnologia/modelos a revendas e integradores.	R\$ fixo + royalty 3–8% da receita gerada	Alta margem; escala sem CAC direto	3%
9	White Label	Plataforma com marca da revenda/cooperativa.	Setup R\$50k–250k + mensal R\$5k–30k	Ancora grandes contas; margem 70%	4%
10	Franquias	Unidades de serviço/assistência com marca e sistema.	Taxa de franquia R\$40k–120k + royalty 5–8%	Expansão capital-light da malha física	2%
11	Enterprise	Grandes frotas (cooperativas, agrosserviços, usinas).	Contrato R\$120k–1,2M/ano (por frota/uso)	ACV alto; ciclo 3–6 meses; churn baixo	6%
12	Governo	Órgãos (Defesa Agropecuária, MAPA, estaduais) — fiscalização/rastreabilidade.	Licitação/contrato R\$200k–5M/ano	Ciclo longo; alto ticket; reforça conformidade	2%
13	Internacional	Mesmas linhas em US\$/EUR, ajustadas por PPP.	Pricing local (US\$/mes por drone)	Alavanca de TAM; requer localização	(transversal)
14	Dados B2B (Data Lake)	Insights agregados anônimos a fabricantes, seguradoras, financeiras.	Assinatura R\$100k–2M/ano ou por relatório	Margem >90%; so possível com escala	3%

Linhas listadas no briefing como duplicadas — "Recorrente", "Transacional", "Receita por Marketplace", "Receita por Assinatura" — são **categorias/agregações** das linhas 1–5 acima, não SKUs adicionais. Consolidadas para evitar

2.5.2 Tiers de assinatura SaaS (detalhe)

Tier	Público	Preço (R\$/mes)	Preço (US\$/mes)	Limites	Objetivo estratégico
Free / Starter	1 drone, autônomo	R\$ 0	US\$ 0	1 drone, histórico 90 dias, sem IA	Aquisição / topo de funil (PLG)
Pro	Operador pequeno (1–3 drones)	R\$ 249 por drone	US\$ 46 por drone	Health Score, laudos IA limitados, peças	Monetização base
Business	Prestador de serviço / frota (4–15)	R\$ 1.490 flat + R\$149/drone extra	US\$ 276 + US\$28	IA ilimitada*, API básica, multiusuário	Coração da receita
Enterprise	Cooperativa / agrosserviço (>15)	Sob consulta (a partir de R\$ 10k)	A partir de US\$ 1.850	SLA, SSO, white label opcional, CSM	ACV alto, baixo churn


*"Ilimitada" com política de uso justo (fair use) para proteger custo de inferência.

2.5.3 Unit economics de referência (ESTIMATIVA)

Métrica	Valor-alvo (Scale)	Premissa / metodologia
ARPA (receita média por conta/ano)	R\$ 8.400 (US\$ 1.556)	Mix Pro/Business ponderado + transacional
Margem bruta blended	78–85%	SaaS 85%, peças 20%, IA 85%, marketplace ~100% do take
CAC (Business)	R\$ 3.500–6.000	Vendas inside + canal revenda
LTV (Business, 3 anos, churn 12%/ano)	R\$ 20.000–28.000	ARPA x margem / churn
LTV/CAC	3,5–5,0x	Meta saudável SaaS B2B (>3x)
Payback CAC	6–10 meses	Alvo <12 meses
Net Revenue Retention (NRR)	115–130%	Expansão por drone + upsell IA/peças

Distribuição de receita @Scale (visão gráfica):

Mix de receita estimado @Scale



2.6 Business Model Canvas (9 Blocos)

Bloco	Conteudo
1. Segmentos de Cliente	(a) Operadores/prestadores de pulverizacao; (b) Revendas e integradores DJI/XAG/Jacto; (c) Cooperativas e agrosservicos (Enterprise); (d) Fabricantes, seguradoras e financeiras (Dados B2B); (e) Governo/orgaos de fiscalizacao.
2. Proposta de Valor	Maximizar uptime e reduzir TCO da frota via manutencao preditiva (Drone Health Score), laudo por IA, pecas na hora certa, conformidade automatica e passaporte digital que aumenta valor de revenda.
3. Canais	PLG (free tier + conteudo), canal de revendas (co-selling), inside sales para Business/Enterprise, marketplace, eventos do agro (feiras), parceria com fabricantes.
4. Relacionamento	Self-service (Pro), Customer Success dedicado (Enterprise), comunidade de operadores, programa de certificacao, suporte tecnico multicanal.
5. Fontes de Receita	14 linhas da secao 2.5 (SaaS, pecas, IA, marketplace, API, treinamento, certificacao, licenciamento, white label, franquias, enterprise, governo, internacional, dados).
6. Recursos-Chave	Data Lake Global, modelos de IA/Health Score, base de conhecimento de manutencao, engenharia de plataforma, marca/credenciamento, rede de oficinas.
7. Atividades-Chave	Desenvolvimento de produto/IA, curadoria de dados, gestao do marketplace, credenciamento tecnico, vendas e CS, compliance regulatorio.
8. Parcerias-Chave	Revendas DJI/XAG/Jacto, distribuidores de pecas, oficinas, seguradoras, cooperativas, provedores de nuvem (Edge/Cloud), instituicoes de treinamento.
9. Estrutura de Custos	Nuvm + inferencia de IA, P&D/engenharia, vendas e marketing (CAC), CS/suporte, custo de pecas (COGS marketplace), compliance, G&A. Maiores alavancas: inferencia IA e CAC.

2.7 Estrategia de Precificacao

Adotamos **precificacao hibrida value-based**, combinando quatro eixos para capturar valor onde ele existe sem criar atrito de adocao:


Eixo de precificacao	Como funciona	Quando usar	Vantagem	Risco/mitigacao
Por drone	Preco escala com nº de drones ativos.	Pro / Business	Alinha preco a valor (frota maior = mais valor)	Penaliza frota grande → aplicar desconto por volume
Por frota (flat + faixa)	Assinatura fixa por faixa de tamanho de frota.	Business / Enterprise	Previsivel para o cliente	Subprecifica outliers → limites de fair use
Por assento (seat)	Cobranca por usuario (tecnico, gestor, financeiro).	Enterprise / cooperativas	Captura valor em times grandes	Compartilhamento de login → SSO obrigatorio
Por uso de IA	Creditos/laudos consumidos (usage-based).	Todos os tiers	Monetiza usuarios intensivos; barreira baixa de entrada	Imprevisibilidade → pacotes + alertas de consumo

Principio-guia (value metric): a metrica de valor primaria e o **drone ativo gerenciado** — cresce com o sucesso do cliente e sustenta NRR >115%. IA e pecas sao **overlays transacionais** sobre a base recorrente.

Ancoragem de valor: o ROI para o cliente e comunicado em "dias de downtime evitados". Se a assinatura Business custa ~R\$ 18k/ano e evita 2–3 dias de parada em safra (R\$ 10k–60k), o **payback do cliente e < 1 mes** — ancora que justifica value-based pricing acima do custo.

2.8 Estrategia de Plataforma e Efeitos de Rede

A AeroCortex e desenhada como **plataforma de dois/tres lados**, nao apenas SaaS de ferramenta:



Efeitos de rede em tres camadas:

- Rede de dados (o mais forte):** cada manutencao melhora a IA para todos — retorno crescente de escala.
- Rede de marketplace:** mais operadores atraem mais oficinas/fornecedores, que atraem mais operadores (efeito cross-side).
- Rede de padrao:** quando o Drone Health Score vira referencia na revenda e no seguro, adotar a plataforma deixa de ser opcional.

Como cada manutencao aumenta o valor do dado — mecanismo economico: o valor marginal de um novo registro nao e linear — ele **compõe**. Registro nº 1.000.000 melhora a predicao para 100% da base instalada simultaneamente. Isso e o oposto de um servico de mao de obra (onde o valor nao acumula) e e o que justifica valuation de plataforma, nao de agencia.

2.9 Comparacao de Modelos de Monetizacao e Mix por Fase

2.9.1 Modelos alternativos avaliados

Modelo	Descricao	Pros	Contras	Veredito
SaaS puro (assinatura)	So mensalidade por drone/assento	Previsivel, alta margem, valuation premium	Teto de receita; subexplora transacional	Base obrigatoria, insuficiente sozinho
Transacional puro (take-rate)	So marketplace/pecas/laudo	Baixa barreira de entrada; escala com uso	Receita volatil, sazonal (safra), churn alto	Complemento, nao nucleo
Marketplace puro	So intermediacao servico/pecas	Capital-light; efeito de rede	Sem lock-in de dados; margem depende de GMV	Acelerador, precisa do SaaS ancorando
Licenciamento/White label	Vender tecnologia a terceiros	Alta margem, escala sem CAC	Canibaliza marca; dependencia de parceiro	Alavanca seletiva (grandes contas)
Dados (data-as-a-product)	Vender insights agregados	Margem >90%; unico	So viavel com escala + governanca de dados	Colher no Scale
Hibrido em camadas (recomendado)	SaaS + transacional + estrategico	Diversifica risco; maximiza LTV; NRR alto	Complexidade operacional/faturamento	MELHOR OPCAO

Recomendacao: modelo HIBRIDO em camadas. Justificativa: nenhum modelo isolado captura o valor total nem sustenta o moat. O SaaS ancora previsibilidade e valuation; o transacional captura upside de safra e usuarios intensivos; o estrategico (dados/licenca/gov) so e possivel com escala e tem margem altissima. A combinacao entrega **NRR alto + margem + defensibilidade**.

2.9.2 Mix recomendado por fase

Linha	Early (0–18m, MVP/GA)	Growth (18–36m)	Scale (36m+)	Racional
SaaS Assinatura	55%	48%	40%	Fundacao; foco em PMF e recorrência
Pecas	10%	12%	12%	Cresce com base instalada
IA (laudos)	8%	10%	9%	Requer maturidade de modelo
Marketplace servicos	5%	8%	8%	Depende de liquidez de rede
API	2%	4%	4%	Ecossistema de integracao maduro
Treinamento	8%	5%	4%	Alto no early (educa mercado), estabiliza
Certificacao	4%	3%	3%	Reforca marketplace
Enterprise	3%	5%	6%	Ciclo longo; matura no growth
White Label / Licenc.	3%	4%	7%	Escala via parceiros no scale
Franquias	1%	1%	2%	Malha fisica capital-light
Dados B2B	0%	~0–1%	3%	So com escala de dados
Governo	1%	~0–1%	2%	Ciclo de licitacao longo

Leitura estrategica: no **Early**, concentre em SaaS + Treinamento (educar mercado e provar PMF); no **Growth**, ative marketplace, IA e Enterprise (liquidez de rede + ACV); no **Scale**, colha as linhas de altissima margem (Dados, White Label, Licenciamento) que so a escala destrava. O mix migra de "produto" para "plataforma" para "ecossistema".

2.10 Síntese de Custos, Riscos e Prioridade

Iniciativa comercial	Custo impl. (R\$ / US\$)	Dificuldade (1–5)	Prioridade	Risco principal → mitigação
Definir pricing/tiers + billing	R\$ 120k / US\$ 22k	3	P0	Pricing errado → testes A/B, entrevistas, revisão trimestral
Motor de assinatura + medição de uso (IA)	R\$ 380k / US\$ 70k	4	P0	Vazamento de receita → billing com auditoria de uso
Marketplace (v1 serviços + peças)	R\$ 650k / US\$ 120k	4	P1	Falta de liquidez → seed manual de oferta, take-rate baixo inicial
Data Lake + governança (LGPD)	R\$ 900k / US\$ 167k	5	P1	Consentimento/privacidade → opt-in, anonimização, DPA
Programa de certificação/franquia	R\$ 300k / US\$ 56k	3	P2	Qualidade inconsistente → auditoria e SLA de credenciados
Oferta de Dados B2B	R\$ 450k / US\$ 83k	4	P2 (Scale)	Sensibilidade de dados → contratos, agregação k-anônima

Riscos transversais do modelo de negócio:

- **Concentração em DJI** → mitigar com roadmap multimarca (XAG/Jacto) desde o design de dados.
- **Sazonalidade da safra** (receita transacional oscila) → ancorar em contratos anuais SaaS.
- **Guerra de preço com app do fabricante** → competir em multimarca + dados + conformidade, não em features de voo.
- **Custo de inferência de IA** corroendo margem → pacotes/creditos, otimização de modelo e Edge/TinyML (ver capítulo de IA).

Fim do Capítulo 2. Próximos capítulos detalham arquitetura de produto, stack de IA, go-to-market e projeções financeiras que quantificam as premissas aqui declaradas como ESTIMATIVA.

Capítulo 3 — Roadmap Corporativo (Ano 1/2/3/5/10)

Escopo: Este capítulo traduz a estratégia (Cap. 1 — mercado; Cap. 2 — business plan) em um **roadmap corporativo executável** por horizonte de tempo (Ano 1, 2, 3, 5 e 10). Para cada horizonte definimos: tema estratégico, metas, marcos (milestones), expansão geográfica, produtos lançados, headcount resumido e dependências. Em seguida ancoramos a execução em uma **North Star Metric (NSM)** com árvore de métricas, **KPIs por área**, **OKRs concretos por ano**, **indicadores de saúde do negócio** e uma **tabela mestra de prioridades, riscos e cronograma macro**.

Aviso metodológico: Todos os números de metas, headcount, ARR, GMV e frota são **ESTIMATIVAS** de trabalho, derivadas por analogia (SaaS vertical B2B, fleet management, marketplaces) e coerentes com o dimensionamento (SOM) dos Capítulos 1 e 2. **Câmbio de trabalho:** US\$ 1,00 = R\$ 5,40. Devem ser **[VALIDAR]** com dados primários (vendas DJI/revendas, ANAC/MAPA, entrevistas com DSPs e oficinas) antes de comprometer capital, contratações ou metas contratuais.


3.1 Sumário Executivo do Capítulo

O roadmap organiza 10 anos em **quatro ondas** já definidas no Cap. 1 (MVP → GA → Scale → Internacional) e cinco checkpoints anuais. A lógica: **primeiro provar Product-Market Fit (PMF) no pós-venda de oficinas/DSPs no Brasil, depois ativar rede (marketplace + IA), depois escalar a plataforma multimarca, e por fim internacionalizar e colher as linhas de altíssima margem (dados, licenciamento, governo)**. A métrica que amarra todos os horizontes é a **North Star Metric = Drones Ativos Gerenciados Semanalmente (WAMD)** — drones com dados de saúde/OS fluindo nos últimos 7 dias —, escolhida por capturar simultaneamente **valor entregue ao cliente** (uptime), **profundidade do moat de dados** e **potencial de receita** (o "drone ativo" e a value metric do Cap. 2).

Horizonte	Tema estratégico	WAMD (est.)	ARR (est. R\$ / US\$)	Headcount (est.)	Onda
Ano 1	Provar PMF no pós-venda BR	1,5k–4k	R\$ 5–9 mi / US\$ 0,9–1,7 mi	25–40	MVP → GA
Ano 2	Ativar rede (marketplace + IA)	8k–18k	R\$ 14–30 mi / US\$ 2,6–5,6 mi	70–110	GA → Scale
Ano 3	Escalar plataforma multimarca	25k–50k	R\$ 35–75 mi / US\$ 6,5–14 mi	180–260	Scale
Ano 5	Lider LatAm + entrada EUA	120k–250k	R\$ 180–380 mi / US\$ 33–70 mi	600–900	Internacional
Ano 10	SO global do drone agrícola	600k–1,0M+	R\$ 1,2–3,0 bi / US\$ 0,22–0,56 bi	2,5k–4,0k	Plataforma global

3.2 Filosofia do Roadmap — Tres Horizontes e Waves

Adotamos o modelo dos **Tres Horizontes** (defender o núcleo, construir o adjacente, semear o transformacional) sobreposto às quatro ondas de produto do Cap. 1. Cada onda só abre quando a anterior atinge **gates de saída** mensuráveis — evitando o erro clássico de escalar antes do PMF.



Gates de saída (critérios de avanço): PMF (NRR ≥ 110%, NPS ≥ 40, retenção logo ≥ 85% em 12m) → abre Wave 2; **liquidez de marketplace** (>60% das OS com peça/serviço transacionado na plataforma) e **acurácia de IA ≥ 85%** → abre Wave 3; **escala BR** (>3.000 contas pagas, EBITDA de contribuição positivo) → abre Wave 4.


3.3 North Star Metric e Arvore de Metricas

3.3.1 Escolha da North Star Metric

Candidata a NSM	Captura valor ao cliente?	Correlaciona com receita?	Reforça o moat de dados?	Facil de instrumentar?	Veredito
ARR / MRR	Nao (mede caixa, nao valor)	Sim	Nao	Sim	Metrica de resultado, nao NSM
Nº de contas pagas	Parcial	Parcial	Nao	Sim	Vaidade; ignora expansao e uso
Uptime agregado da frota (%)	Sim (missao)	Indireto	Parcial	Dificil (dado externo cedo)	Nobre, mas nao instrumentavel no MVP
GMV do marketplace	Nao (fase-dependente)	Sim	Parcial	Medio	So relevante pos-Wave 2
WAMD — Drones Ativos Gerenciados Semanalmente	Sim (drone com dado fluindo = valor recebido)	Sim (value metric = drone ativo)	Sim (cada drone alimenta o Data Lake)	Sim (evento de telemetria/OS)	MELHOR OPCAO

North Star Metric = Drones Ativos Gerenciados Semanalmente (WAMD): numero de drones distintos com pelo menos um evento significativo (sync de telemetria/log, OS, laudo de IA, ou registro de peca) nos ultimos 7 dias. **Por que e a melhor:** (1) e a unidade de valor do cliente (drone voando e monitorado = downtime evitado); (2) e a value metric de precificacao (Cap. 2), entao crescer WAMD *tende* a crescer receita; (3) cada WAMD produz dados que compoem o moat; (4) exclui contas "zumbis" (pagam mas nao usam), forçando a organizacao a perseguir uso real, nao vaidade.

3.3.2 Arvore de metricas (NSM decomposta)



ARPD = receita media por drone/ano. A identidade que guia o negocio: **ARR ≈ WAMD × ARPD**, e crescimento de ARR = crescimento de WAMD (volume) × crescimento de ARPD (monetizacao/expansao).

3.4 Roadmap por Horizonte

3.4.1 Ano 1 — "Provar PMF no pos-venda" (Wave 1: MVP → GA)

Dimensao	Detalhe
Tema	Resolver a dor #1 (OS, rastreabilidade N/S, compliance ANAC/DECEA/MAPA) para oficinas e DSPs no Brasil.
Metas	120–250 contas pagas; WAMD 1,5k–4k; ARR R\$ 5–9 mi (US\$ 0,9–1,7 mi); NRR ≥ 105%; NPS ≥ 40.
Marcos	M1 (mes 3): MVP em beta com 10 design partners. M2 (mes 6): GA do modulo OS + frota. M3 (mes 9): modulo compliance + passaporte digital v1. M4 (mes 12): billing/tiers ativos, primeiro laudo de IA piloto.
Expansao geografica	Brasil — Centro-Oeste (MT, GO, MS) e Sul (PR, RS).
Produtos lancados	App de campo (offline-first), gestao de OS, cadastro de frota por N/S, catalogo de pecas (read-only), templates de compliance, passaporte digital v1.
Headcount (est.)	25–40: Eng 12–18, Produto/Design 4–6, IA/Dados 3–5, GTM/CS 5–8, G&A 2–3.
Dependencias	Capital seed; 8–12 design partners; acesso a dados basicos de log/telemetria; base de conhecimento de manutencao Agras.

3.4.2 Ano 2 — "Ativar a rede" (Wave 2: GA → Scale)

Dimensao	Detalhe
Tema	Transformar SaaS de ferramenta em plataforma de rede : marketplace de pecas/servicos + IA de diagnostico + canal cooperativas.
Metas	400–800 contas; WAMD 8k–18k; ARR R\$ 14–30 mi (US\$ 2,6–5,6 mi); GMV marketplace R\$ 25–60 mi; NRR ≥ 115%; acuracia IA ≥ 85%.
Marcos	M5: marketplace de pecas v1 (take-rate). M6: laudo de IA por foto/log em GA. M7: 3–5 cooperativas como canal. M8: API basica publica (v1).
Expansao geografica	Brasil nacional (SP, MG, BA, MATOPIBA) + piloto LatAm (Paraguai/Argentina via parceiro).
Produtos lancados	Marketplace pecas + servicos, IA de laudo (foto/log/audio), Drone Health Score v1, portal de cooperativas, API v1, programa de certificacao de tecnicos.
Headcount (est.)	70–110: Eng 30–45, Produto/Design 10–14, IA/Dados 12–18, GTM/CS 14–22, G&A 6–10.
Dependencias	Seed de oferta no marketplace (oficinas/fornecedores); volume de dados rotulados para IA (dep. do Ano 1); LGPD/governanca de dados; integracao de pagamentos e split.

3.4.3 Ano 3 — "Escalar a plataforma multimarca" (Wave 3: Scale)

Dimensao	Detalhe
Tema	Consolidar lideranca BR, virar multimarca de fato (XAG, Jacto) e destravar Enterprise (usinas/coops grandes).
Metas	900–1.800 contas; WAMD 25k–50k; ARR R\$ 35–75 mi (US\$ 6,5–14 mi); GMV R\$ 70–160 mi; NRR ≥ 120%; EBITDA de contribuicao positivo.
Marcos	M9: suporte XAG + Jacto em producao. M10: IA preditiva (previsao de falha por horas de voo). M11: 1º contrato Enterprise (>R\$ 500k/ano). M12: integracao ERP (TOTVS/SAP) para usinas.
Expansao geografica	Brasil (lideranca) + LatAm ativo (Paraguai, Argentina, Colombia, Mexico).
Produtos lancados	Suporte multimarca, IA preditiva/Health Score v2, modulo Enterprise (SSO, SLA, CSM), conectores ERP, gestao avancada de baterias, BI/dashboards de frota.
Headcount (est.)	180–260: Eng 70–100, Produto/Design 24–34, IA/Dados 30–45, GTM/CS 40–60, G&A 16–24.
Dependencias	Series A/B; dados multimarca; parcerias com distribuidores de pecas; time de vendas Enterprise; maturidade do Data Lake.


3.4.4 Ano 5 — "Lider LatAm + entrada EUA" (Wave 4: Internacional)

Dimensao	Detalhe
Tema	Internacionalizar (LatAm consolidado, EUA via compliance premium) e ligar as linhas de altissima margem : Dados B2B, White Label, Governo.
Metas	WAMD 120k–250k; ARR R\$ 180–380 mi (US\$ 33–70 mi); GMV R\$ 400–900 mi; NRR ≥ 120%; ≥ 3 regioes com receita material; margem bruta blended ≥ 78%.
Marcos	M13: operacao EUA (Part 137/44807 compliance). M14: 1ª venda de Dados B2B (fabricante/seguradora). M15: 2–3 contratos White Label (revendas/coops). M16: gemeos digitais (digital twin) v1 por drone.
Expansao geografica	Brasil + LatAm (5–8 paises) + EUA (Corn Belt/Sul) + piloto Asia via parceiro.
Produtos lancados	Localizacao multi-idioma/moeda, Dados B2B (Data Lake as a product), White Label, gемеo digital do drone, seguros embarcados (parceria), modulo governo/fiscalizacao.
Headcount (est.)	600–900, distribuido em BR (HQ), hub LatAm e hub EUA; ~40% Eng/IA, ~35% GTM/CS, ~25% G&A/ops.
Dependencias	Series C; entidade e compliance nos EUA; contratos de dados (k-anonizacao/DPA); parceiros de seguro; escala do Data Lake (governanca madura).

3.4.5 Ano 10 — "Sistema operacional global do drone agricola"

Dimensao	Detalhe
Tema	Ser o SO global do pos-venda e da operacao de drones agricolas — o "CarFax + Salesforce + AWS" do setor (visao do Cap. 2).
Metas	WAMD 600k–1,0M+ (cobrindo faixa relevante da frota global); ARR R\$ 1,2–3,0 bi (US\$ 0,22–0,56 bi); presenca em >20 paises; Drone Health Score como padrao de mercado em revenda e seguro.
Marcos	M17: Health Score aceito por seguradoras/financeiras como criterio. M18: ecossistema de apps de terceiros sobre a API (plataforma aberta). M19: expansao adjacente (outros ativos agricolas conectados). Opcionalidade de IPO/M&A estrategico.
Expansao geografica	Global — Americas, Asia (via parceria/JV), selecao de Europa (inspecao), Africa (impacto/ESG).
Produtos lancados	Plataforma aberta (developer ecosystem), autonomia preditiva de manutencao, finanças embarcadas (credito/leasing por Health Score), expansao para novos ativos agricolas conectados.
Headcount (est.)	2,5k–4,0k, multi-hub global; forte peso de IA/Dados e ecossistema/parcerias.
Dependencias	Efeito de rede consolidado; governanca de dados global (LGPD/GDPR/local); parcerias com fabricantes; capital de crescimento/IPO.

3.4.6 Cronograma macro consolidado



3.5 KPIs por Area (metas por horizonte)

Todas as celulas sao **ESTIMATIVAS-alvo**; setas indicam direcao desejada.

3.5.1 Produto e Engajamento

KPI	Ano 1	Ano 2	Ano 3	Ano 5	Ano 10
WAMD (North Star)	1,5k–4k	8k–18k	25k–50k	120k–250k	600k–1,0M+
Ativacao (drone atinge 1º "aha")	≥ 55%	≥ 65%	≥ 70%	≥ 75%	≥ 80%
Time-to-value (dias)	≤ 7	≤ 3	≤ 2	≤ 1	≤ 1
DAU/MAU dos portais (stickiness)	0,20	0,30	0,38	0,45	0,50
Eventos de dado por drone/semana	1–2	3–5	6–10	10–15	15+

3.5.2 Receita e Retencao

KPI	Ano 1	Ano 2	Ano 3	Ano 5	Ano 10
ARR (R\$)	5–9 mi	14–30 mi	35–75 mi	180–380 mi	1,2–3,0 bi
NRR (Net Revenue Retention)	≥ 105%	≥ 115%	≥ 120%	≥ 120%	≥ 120%
Gross churn logo (anual)	≤ 15%	≤ 12%	≤ 10%	≤ 8%	≤ 6%
LTV/CAC	≥ 3,0x	≥ 3,5x	≥ 4,0x	≥ 4,5x	≥ 5,0x
ARPD (receita/drone/ano, R\$)	~2,5k	~2,2k	~2,0k	~2,2k	~2,5k

3.5.3 IA, Marketplace e Operacoes

KPI	Ano 1	Ano 2	Ano 3	Ano 5	Ano 10
Acuracia de laudo de IA	piloto	≥ 85%	≥ 90%	≥ 93%	≥ 95%
Antecedencia de predicao de falha	—	—	≥ 30 h voo	≥ 60 h voo	≥ 100 h voo
GMV do marketplace (R\$/ano)	—	25–60 mi	70–160 mi	400–900 mi	> 3 bi
Take-rate efetivo	—	8–12%	10–14%	12–15%	12–15%
Gemeos digitais ativos	—	—	piloto	120k–250k	600k–1,0M+
MTTR medio da frota gerida	linha base	–15%	–30%	–45%	–60%
Uptime medio da frota gerida	linha base	+3 p.p.	+6 p.p.	+9 p.p.	+12 p.p.

3.6 OKRs Concretos por Ano

Ano 1 — Objetivo: Provar PMF no pos-venda BR.

- KR1: Fechar 120+ contas pagas com NRR ≥ 105%.
- KR2: Atingir WAMD ≥ 2.000 e ativacao ≥ 55%.
- KR3: NPS ≥ 40 e retencao logo em 12m ≥ 85%.
- KR4: Publicar passaporte digital v1 em 100% das contas ativas.

Ano 2 — Objetivo: Ativar os efeitos de rede.

- KR1: GMV de marketplace ≥ R\$ 25 mi com take-rate efetivo ≥ 8%.
- KR2: Acuracia de laudo de IA ≥ 85% em amostra auditada.
- KR3: 3+ cooperativas ativas como canal, gerando ≥ 25% dos novos drones.
- KR4: NRR ≥ 115% e ARR ≥ R\$ 14 mi.

Ano 3 — Objetivo: Escalar plataforma multimarca e destravar Enterprise.

- KR1: XAG + Jacto em producao com ≥ 15% dos WAMD nao-DJI.
- KR2: 1º contrato Enterprise ≥ R\$ 500k/ano assinado.
- KR3: IA preditiva prevendo falha com ≥ 30 h de voo de antecedencia.
- KR4: EBITDA de contribuicao positivo e ARR ≥ R\$ 35 mi.

Ano 5 — Objetivo: Internacionalizar e ligar linhas de alta margem.

- KR1: Operacao EUA ativa com ≥ 30 contas pagas em compliance Part 137.
- KR2: 1ª receita de Dados B2B ≥ R\$ 2 mi/ano com governanca k-anonima auditada.
- KR3: Receita material em ≥ 3 regioes; ARR ≥ R\$ 180 mi.
- KR4: Gemedo digital v1 em ≥ 50% dos WAMD.

Ano 10 — Objetivo: Tornar-se o SO global (padrao de mercado).

- KR1: Drone Health Score adotado por ≥ 2 seguradoras/financeiras como criterio.
- KR2: Presenca em > 20 paises; ARR $\geq$ R\$ 1,2 bi.
- KR3: Ecossistema aberto com ≥ 50 integracoes de terceiros ativas.
- KR4: Cobertura de frota global relevante (WAMD $\geq 600k$) e margem bruta $\geq 80\%$.

3.7 Indicadores de Saude do Negocio (Business Health)

Painel executivo revisado mensalmente (operacional) e trimestralmente (board). Faixas verdes = **ESTIMATIVAS-alvo** por horizonte.


Indicador	Definicao / por que importa	Alvo Ano 1	Alvo Ano 3	Alvo Ano 5	Alvo Ano 10
ARR	Receita recorrente anualizada; motor de valuation	R\$ 5–9 mi	R\$ 35–75 mi	R\$ 180–380 mi	R\$ 1,2–3,0 bi
NRR	Expansao liquida da base; saude do moat/lock-in	$\geq 105\%$	$\geq 120\%$	$\geq 120\%$	$\geq 120\%$
Gross churn (logo)	Perda de clientes; indicador precoce de PMF fraco	$\leq 15\%$	$\leq 10\%$	$\leq 8\%$	$\leq 6\%$
GMV do marketplace	Volume transacionado; liquidez da rede	—	R\$ 70–160 mi	R\$ 400–900 mi	$> \text{R\$ } 3 \text{ bi}$
DAU/MAU dos portais	Stickiness; habito de uso	0,20	0,38	0,45	0,50
Acuracia da IA	Confiabilidade do laudo/predicao; sustenta receita de IA	piloto	$\geq 90\%$	$\geq 93\%$	$\geq 95\%$
Drones/gemeos digitais ativos (WAMD)	Escala do negocio e do moat de dados	1,5k–4k	25k–50k	120k–250k	600k–1,0M+
LTV/CAC & payback	Eficiencia de crescimento	3,0x / $\leq 12m$	4,0x / $\leq 10m$	4,5x / $\leq 9m$	5,0x / $\leq 8m$
Margem bruta blended	Qualidade da receita	70–78%	$\geq 78\%$	$\geq 78\%$	$\geq 80\%$
Uptime da frota gerida	Prova da promessa (missao); leading de retencao	linha base	+6 p.p.	+9 p.p.	+12 p.p.

Alertas de saude (thresholds de acao): NRR $< 100\%$ por 2 trimestres → congelar expansao, revisar PMF; churn logo $>$ alvo +5 p.p. → task force de retencao; acuracia de IA cair > 3 p.p. → rollback de modelo + reauditoria; DAU/MAU $< 0,15$ → problema de habito/valor no produto.

3.8 Tabela Mestra — Prioridades, Riscos e Cronograma Macro


Horizonte	Iniciativa-chave (P0/P1/P2)	Custo impl. (R\$ / US\$)	Dificuldade (1–5)	Prioridade	Risco principal → mitigacao
Ano 1	Core SaaS (OS + frota + compliance) + billing/tiers	R\$ 1,8–2,6 mi / US\$ 0,33–0,48 mi	3	P0	PMF fraco → design partners, ROI claro, iteracao semanal
Ano 1	App offline-first de campo	R\$ 0,7–1,1 mi / US\$ 0,13–0,20 mi	4	P0	Conectividade rural → sync offline, cache, Starlink-ready
Ano 2	Marketplace v1 (pecas + servicos)	R\$ 3,5–5,0 mi / US\$ 0,65–0,93 mi	4	P1	Falta de liquidez → seed manual de oferta, take-rate baixo inicial
Ano 2	IA de laudo (foto/log/audio)	R\$ 2,5–4,0 mi / US\$ 0,46–0,74 mi	4	P1	Acuracia baixa → human-in-the-loop, dados rotulados, guardrails
Ano 3	Multimarca (XAG/Jacto) + IA preditiva	R\$ 6–9 mi / US\$ 1,1–1,7 mi	5	P1	Dados fechados do fabricante → app do tecnico gera dado proprio
Ano 3	Modulo Enterprise (SSO/SLA/CSM/ERP)	R\$ 4–6 mi / US\$ 0,74–1,1 mi	4	P1	Ciclo longo → pre-vendas dedicada, POCs pagas
Ano 5	Internacionalizacao (LatAm + EUA)	R\$ 25–45 mi / US\$ 4,6–8,3 mi	5	P1	Compliance/legal local → parceiros locais, entidade dedicada
Ano 5	Dados B2B + gемеo digital	R\$ 12–20 mi / US\$ 2,2–3,7 mi	5	P2	Privacidade/sensibilidade → opt-in, k-anonimia, DPA, auditoria
Ano 10	Plataforma aberta + padrao de mercado	R\$ 80–200 mi / US\$ 15–37 mi	5	P2	Fragmentacao/regulacao global → governanca, parcerias, padroes

Marcos corporativos por horizonte



3.9 Dependencias Criticas e Caminho Critico

O caminho critico do roadmap e uma **cadeia de dados**: sem uso (WAMD) nao ha dados; sem dados nao ha IA; sem IA nao ha moat nem receita de dados. Por isso o Ano 1 e integralmente subordinado a **gerar uso real e capturar dados limpos**, mesmo antes de monetizar IA.



Dependencias inter-horizonte (resumo):

- **Ano 2 depende do Ano 1:** volume e qualidade de dados de OS/telemetria para treinar a IA de laudo.
- **Ano 3 depende do Ano 2:** liquidez de rede + acuracia de IA $\geq 85\%$ (gate) antes de escalar Enterprise e multimarca.
- **Ano 5 depende do Ano 3:** escala BR + EBITDA de contribuicao positivo antes de queimar capital em internacionalizacao.
- **Ano 10 depende do Ano 5:** efeito de rede em ≥ 3 regioes e Data Lake governado antes de virar padrao/plataforma aberta.
- **Transversal:** capital nos estagios certos, governanca de dados (LGPD desde o Ano 1) e relacao com fabricantes (risco de fechamento de API — mitigado pelo dado proprio via app do tecnico).

Fim do Capitulo 3. Os proximos capitulos detalham a arquitetura de produto/plataforma, a stack de IA (que sustenta as metas de acuracia e predicao aqui declaradas), o go-to-market operacional e as projecoes financeiras que quantificam ARR, GMV e headcount tratados aqui como ESTIMATIVA.

Capítulo 4 — Arquitetura da Plataforma

Escopo: Este capítulo redesenha, do zero, a arquitetura cloud-native da AeroCortex (nome de trabalho, a validar). Define stack de backend/frontend, banco de dados, mensageria, cache, observabilidade, API Gateway, estratégia multi-tenant, containers/Kubernetes, CI/CD, testes, alta disponibilidade, backup e disaster recovery. Cada decisao e justificada, comparada em tabela contra alternativas, e acompanhada de custo (R\$ e US\$), dificuldade (1 a 5), riscos + mitigacao, cronograma e prioridade.

Aviso metodologico: Custos de infraestrutura sao **ESTIMATIVAS** de trabalho, construidas por dimensionamento bottom-up de recursos (vCPU, RAM, storage, egress) x precos de lista publicos das nuvens, com desconto de committed-use/Savings Plans. **Cambio de trabalho:** US\$ 1,00 = R\$ 5,40. Todo valor precisa ser validado com **[VALIDAR]** cotacao real (AWS Pricing Calculator, contrato de committed-use, egress medido) antes de decisao de orcamento.

4.1 Sumario Executivo do Capitulo

A AeroCortex nasce como **monolito modular** (modular monolith) em um unico deploy, evoluindo para **microservicos seletivos** conforme dor de escala aparece — nao antes. Essa e a decisao mestra do capitulo: microservicos prematuros matam startups por overhead operacional. Adotamos **Java 21 + Spring Boot 3** no backend transacional, **Go** para servicos de alta concorrencia (ingest de telemetria, gateway de eventos), **React + Next.js** no frontend, **PostgreSQL 16** como banco primario (com **TimescaleDB** para series temporais de telemetria e **pgvector** para busca semantica/RAG do laudo de IA), **Kafka** como espinha dorsal de eventos (com NATS para comando/RPC leve), **Redis** para cache/filas rapidas, **Kong** como API Gateway, **AWS** como nuvem primaria, **Terraform** para IaC e a stack **OpenTelemetry + Prometheus + Grafana + Loki + Tempo** para observabilidade unificada.

Multi-tenancy: comece com **row-level (RLS + tenant_id)** no MVP pela simplicidade e custo, migra tenants enterprise para **schema-per-tenant** no GA, e reserva **database-per-tenant** para clientes soberanos/regulados no Scale. Metas de servico: **SLA 99,9%** (GA), **RTO <= 1h / RPO <= 5min** para dados criticos, DR **multi-AZ** no GA e **multi-regiao** no Scale.

Custo de infra estimado: ~R\$ 9-16 mil/mes (MVP), ~R\$ 45-80 mil/mes (GA), ~R\$ 180-380 mil/mes (Scale) — detalhado na secao 4.19.

4.2 Principios Arquiteturais e Requisitos Nao-Funcionais (NFRs)

Principios (guiam toda decisao):


1. **Simplicidade primeiro, complexidade sob demanda** — nao pagamos custo de microservicos antes de ter a dor.
2. **Cloud-native e portavel** — containers + Kubernetes + Terraform reduzem lock-in de nuvem.
3. **Event-driven no nucleo** — o "passaporte digital do drone" e o Health Score exigem trilha de eventos imutavel.
4. **Multi-tenant seguro por padrao** — isolamento de dado do cliente e requisito de negocio (moat de dados) e de compliance (LGPD).
5. **Observabilidade e requisito, nao afterthought** — todo servico nasce instrumentado com OpenTelemetry.
6. **Seguranca e privacidade por design** — zero-trust interno, criptografia em transito e em repouso, segregacao de segredos.

NFRs alvo (por fase):


NFR	MVP	GA	Scale
Disponibilidade (SLA)	99,5%	99,9%	99,95%
Latencia API p95 (leitura)	< 400 ms	< 250 ms	< 150 ms
Ingest de telemetria	~1k eventos/s	~20k eventos/s	~200k+ eventos/s
Tenants ativos	10-50	500-3.000	10.000+
RTO / RPO (dados criticos)	4h / 1h	1h / 5min	15min / <1min
Deploys/semana	1-3	10-30	50+ (contínuo)

4.3 Visao de Alto Nivel (C4 Nivel 1 e 2)

C4 Nivel 1 — Contexto (quem usa e sistemas externos):



C4 Nivel 2 — Contêineres (blocos internos):



4.4 Estrategia de Evolucao: Monolito Modular -> Microservicos

Comecar com microservicos e o erro mais comum e mais caro de plataformas B2B em estagio inicial. A recomendacao e um **modular monolith**: um unico deploy, mas com fronteiras de modulo rigorosas (packages por dominio, sem imports cruzados diretos, comunicacao via interfaces e eventos internos). Quando um modulo tem dor real (escala independente, time dedicado, ciclo de deploy proprio), ele e **extraido** para microservico — as fronteiras ja existem, entao a extracao e barata.

Abordagem	Vantagens	Desvantagens	Quando
Monolito modular (recomendado inicio)	Deploy simples, 1 pipeline, transacoes ACID locais, debugging facil, baixo custo op.	Escala tudo junto; risco de acoplamento se disciplina falhar	MVP + GA inicial
Microservicos seletivos	Escala e deploy independentes onde importa (ingest, IA)	Overhead: rede, observabilidade distribuida, consistencia eventual	GA maduro / Scale
Microservicos "puros" desde o dia 1	Escala teorica maxima	Mata velocidade de produto, custo op. explode, dev pequeno afoga	Nunca nesta fase

Ordem de extracao recomendada: (1) Ingest de telemetria (Go, ja separado desde o inicio por perfil de carga), (2) Servico de IA/laudo (Python, GPU sob demanda), (3) Marketplace/pagamentos, (4) Faturamento/billing, (5) Notificacoes. Dominios transacionais de baixo trafego (tenants, catalogo, OS) permanecem no monolito o maximo possivel.

4.5 Backend — Linguagem e Framework

Critério (peso)	Java 21 + Spring Boot 3	Go	Node.js + NestJS
Maturidade ecossistema B2B/ERP (25%)	Excelente	Bom	Bom
Produtividade de dominio complexo (20%)	Excelente (JPA, validacao, transacoes)	Media (verboso p/ CRUD)	Boa
Performance/concorrencia (15%)	Muito boa (virtual threads 21)	Excelente	Boa (I/O-bound)
Talento no Brasil (15%)	Abundante	Escasso/medio	Abundante
Consumo de memoria/custo runtime (10%)	Medio-alto	Baixo	Medio
Tipagem/robustez p/ dominio critico (15%)	Forte	Forte	Media (TS ajuda)
Veredito	MELHOR p/ nucleo transacional	MELHOR p/ ingest/gateway	Alternativa p/ BFF

Decisao: Java 21 + Spring Boot 3 para o nucleo transacional (OS, frota, faturamento, tenants, compliance) — maturidade, talento abundante no Brasil, virtual threads (Project Loom) que eliminam a antiga fraqueza de concorrência, e ecossistema de integracao ERP/fiscal insuperavel. **Go** para o servico de ingest de telemetria e o event gateway, onde milhares de conexoes/eventos por segundo exigem footprint baixo e concorrência nativa. **Python (FastAPI)** exclusivamente no servico de IA/laudo, por ser onde vivem os frameworks de ML/CV/LLM. Justificativa: usar cada linguagem onde ela e imbativel, sem fragmentar o time (2 linguagens no core, Python isolado no dominio de IA).

- Custo/dificuldade: dificuldade **2**; sem custo de licenca (OpenJDK). Risco: sprawl de linguagens -> mitigacao: limitar a 3, com templates/scaffolding padrao por linguagem.

4.6 Frontend

Decisao: React + Next.js (App Router) para web e **React Native (Expo)** para mobile, compartilhando design system e camada de tipos (TypeScript) com o web.

Opcao	Vantagens	Desvantagens	Veredito
React + Next.js	SSR/SSG p/ SEO da landing, RSC, ecossistema gigante, talento abundante	Curva do App Router	MELHOR
SPA React puro (Vite)	Simples	Sem SSR nativo, pior SEO	Bom p/ app interno
Angular	Estruturado, enterprise	Menos talento no BR, verboso	Nao
Vue/Nuxt	Leve, curva suave	Ecossistema menor no B2B BR	Nao

Racional: Next.js entrega a landing/marketing (SEO), o dashboard autenticado (RSC + streaming) e APIs de borda (route handlers) num so framework. React Native (Expo) reaproveita conhecimento e permite recurso critico de campo: **operacao offline-first** no barracao (baixa conectividade), com sincronizacao quando volta a rede. Design system em **shadcn/ui + Tailwind**; dados via **TanStack Query**. Dificuldade 2.

4.7 Banco de Dados

Decisao: **PostgreSQL 16** como banco primario relacional, estendido com **TimescaleDB** (hypertables para telemetria/series temporais de voo e sensores) e **pgvector** (embeddings para RAG do laudo de IA e busca semantica de pecas/defeitos). Consolidar em torno do Postgres reduz superficie operacional (um motor, um backup, um skillset) — principio "Postgres for everything" ate a dor justificar especializacao.

Necessidade	Solucao	Alternativa considerada	Por que Postgres+ext vence
Transacional (OS, frota, billing)	PostgreSQL 16	MySQL, SQL Server	RLS nativo, extensoes, JSONB, licenca livre
Series temporais (telemetria)	TimescaleDB	InfluxDB, ClickHouse	Fica no Postgres; SQL unico; compressao/retencao
Busca vetorial (IA/RAG)	pgvector	Pinecone, Milvus, Qdrant	Sem novo servico no MVP; migravel depois se escalar
Objetos (fotos/logs/laudos)	S3 (object storage)	Postgres BLOB	Barato, escalavel, CDN-friendly
Analitico/BI (Scale)	Data lake (S3+Parquet) + query engine	Postgres direto	Isola OLAP do OLTP

Evolucao: no Scale, se a busca vetorial ultrapassar centenas de milhoes de vetores, avaliar mover embeddings para um vector DB dedicado (Qdrant/Milvus) e a telemetria de altissimo volume para ClickHouse. Ate la, Postgres+extensoes evita 3 sistemas separados. Dificuldade 3; risco: crescimento de series temporais estoura custo/IO -> mitigacao: politicas de compressao e retencao (hot 90d / cold em S3) no TimescaleDB desde o inicio.


4.8 Multi-Tenancy — A Decisao Estrutural

Como isolar dados de cada cliente (operador/oficina/DSP) e o coracao do modelo. Comparacao:

Modelo	Isolamento	Custo/tenant	Complexidade	Escala de nº de tenants	Custom por tenant	Blast radius
Row-Level (RLS + tenant_id)	Logico (policy)	Baixissimo	Baixa	Milhares+	Dificil	Alto (bug de policy vaza)
Schema-per-tenant	Medio (schema)	Baixo-medio	Media	Centenas-milhares	Medio	Medio
Database-per-tenant	Forte (fisico)	Alto	Alta	Dezenas-centenas	Facil	Baixo (1 DB = 1 cliente)

Recomendacao por fase:

- **MVP -> row-level (RLS):** um schema, coluna `tenant_id` em todas as tabelas, **Postgres Row-Level Security** forçando o filtro no nivel do banco (nao so na aplicacao). Menor custo, maior velocidade. Regra de ouro: **defesa em profundidade** — RLS no banco + tenant context injetado por middleware/JWT + testes automatizados de vazamento entre tenants.
- **GA -> hibrido:** maioria em RLS; tenants enterprise/regulados migram para **schema-per-tenant** (isolamento e backup granular por cliente, restore individual).
- **Scale -> adicionar database-per-tenant** para clientes soberanos, com requisito de residencia de dados ou contratos que exijam isolamento fisico. Router de tenants direciona a conexao correta.




Dificuldade 4 (o erro aqui e catastrofico: vazamento cross-tenant). Risco alto -> mitigacao: RLS obrigatorio no banco (nunca so na app), suite de testes de isolamento em CI, auditoria de queries sem `tenant_id`.

4.9 Mensageria e Streaming de Eventos

Critério	Apache Kafka	RabbitMQ	NATS (JetStream)
Throughput/streaming	Excelente	Medio	Muito bom
Replay/retencao de log (event sourcing)	Excelente (nativo)	Fraco	Bom (JetStream)
RPC/comando request-reply	Fraco	Excelente	Excelente
Operacao/curva	Alta	Media	Baixa
Ecossistema (connectors, CDC)	Excelente	Bom	Emergente
Melhor uso	Espinha de eventos/telemetria/CDC	Filas de tarefa classicas	Comando/RPC leve, edge

Decisao: Kafka como espinha dorsal de eventos — a plataforma e event-driven no nucleo (passaporte do drone, Health Score, trilha de auditoria imutavel, CDC do Postgres via Debezium para o data lake). **NATS** para comando/RPC de baixa latencia entre servicos e comunicacao com edge/mobile. RabbitMQ e descartado: seus pontos fortes (filas de tarefa) sao cobertos por Kafka + Redis Streams no nosso perfil. No MVP, usar **Redis Streams** como fila leve e adiar Kafka ate haver volume (Kafka gerenciado — MSK/Confluent — so no GA).

Fluxo de eventos (exemplo — telemetria gera Health Score e alerta de OS):



Dificuldade **4**; risco: complexidade operacional do Kafka -> mitigacao: usar servico gerenciado (MSK/Confluent Cloud), comecar com Redis Streams no MVP.

4.10 Cache

Decisao: Redis (ElastiCache/MemoryDB gerenciado) para cache de leitura, sessoes, rate-limiting, locks distribuidos e filas leves (Redis Streams no MVP). Alternativas (Memcached — sem estruturas ricas; KeyDB/Dragonfly — menos maduro gerenciado) nao superam a ubiquidade e o ferramental do Redis. Padroes: cache-aside para catalogos/pecas, TTL curto para dados de frota, invalidacao por evento (assinando topicos Kafka). Dificuldade **2**.

4.11 API Gateway e Versionamento de API

Gateway	Base	Vantagens	Desvantagens	Veredito
Kong	Nginx/OpenResty	Ecossistema de plugins maduro, OSS + enterprise, RBAC, rate-limit, OIDC	Consumo de recursos, config as data	MELHOR (GA)
APISIX	Nginx + etcd	Performance alta, hot-reload, OSS Apache	Comunidade menor no BR	Forte alternativa
Envoy (via gateway)	C++	Base do service mesh, altissima performance	Config complexa (xDS)	Camada de mesh, nao gateway direto

Decisao: Kong como API Gateway (autenticacao OIDC/JWT, rate-limiting por tenant, quotas de plano SaaS, roteamento, transformacao, observabilidade). No MVP, o proprio Next.js/Spring pode expor as rotas; Kong entra quando ha multiplos backends e necessidade de politicas por tenant/plano. **Envoy** aparece depois como data plane do service mesh (secao 4.12), nao como substituto do Kong.

Versionamento de API: versionamento por **URI** (/v1 , /v2) para APIs publicas/parceiros (previsibilidade), contratos definidos em **OpenAPI 3.1** (gerando SDKs e docs), politica de **deprecacao com N+1** (uma versao antiga suportada), e eventos versionados via **schema registry** (Avro/Protobuf) no Kafka para evolucao compativel. Dificuldade **3**.

4.12 Service Mesh

Service mesh (mTLS automatico, retries, circuit breaking, observabilidade L7) so se justifica com muitos servicos.

Decisao: nao adotar no MVP/GA inicial; introduzir **Istio** ou **Linkerd** no Scale, quando o numero de microservicos e as exigencias de zero-trust interno justificarem. **Linkerd** e preferivel se a prioridade for simplicidade e footprint; **Istio** se forem necessarias politicas L7 avancadas e integracao ampla. Ate la, mTLS e resiliencia sao resolvidos com bibliotecas (Resilience4j) e TLS gerenciado. Dificuldade **4** (quando chegar).

4.13 Cloud e Infraestrutura como Codigo (IaC)

Criterio	AWS	GCP	Azure
Maturidade/breadth de servicos	Excelente	Muito bom	Muito bom
Presenca/regiao Brasil (sa-east-1)	Sim (SP)	Sim (SP)	Sim (BR South)
Ecosistema gerenciado (RDS, MSK, EKS, S3)	Excelente	Bom (forte em dados/IA)	Bom
Talento/mercado no BR	Maior	Medio	Medio-grande
Custo (perfil geral)	Competitivo c/ commit	Competitivo	Competitivo
Veredito	MELHOR (primaria)	Forte p/ dados/IA (2ª)	Alternativa enterprise

Decisao: **AWS** como nuvem primaria (regiao **sa-east-1 / Sao Paulo** para residencia de dados e latencia BR, LGPD), pela maturidade de servicos gerenciados (RDS/Aurora Postgres, MSK, EKS, ElastiCache, S3), maior pool de talento e ecossistema. **Estrategia anti-lock-in:** tudo em containers + Kubernetes + Terraform, evitando servicos proprietarios "colados" onde houver equivalente open-source portavel. GCP fica como opcao secundaria se cargas de IA/BigQuery pesarem.


IaC: **Terraform** (multi-cloud, HCL, estado gerenciado em S3+DynamoDB lock), estrutura em modulos por ambiente (dev/stg/prod) e **Terragrunt** para DRY. Config de app via **Helm** (charts versionados). Segredos em **AWS Secrets Manager / Vault**. GitOps com **ArgoCD** no GA. Dificuldade **3**.

4.14 Containers, Kubernetes e Orquestracao

Decisao: **Docker** (build multi-stage, imagens distroless para reduzir superficie) + **Kubernetes gerenciado (EKS)**. No **MVP**, para reduzir custo e complexidade, rodar em **ECS Fargate ou um EKS pequeno** — ate um unico nodegroup pode bastar; nao super-dimensionar. Autoscaling: **HPA** (por CPU/RAM e metricas custom via KEDA — ex.: lag de consumidor Kafka), **Cluster Autoscaler/Karpenter** para nós. Namespaces por ambiente; recursos com requests/limits definidos; **PodDisruptionBudgets** para HA. Dificuldade **4**; risco: complexidade de K8s afoga time pequeno -> mitigacao: comecar com Fargate/serverless-containers, adotar EKS pleno so no GA.

4.15 CI/CD, Versionamento, Feature Flags e Estrategia de Deploy

- Versionamento:** Git (GitHub), **trunk-based development** com branches curtas + PRs obrigatorios, **Conventional Commits** + **SemVer** para libs/APIs, **monorepo** (Turborepo/Nx) para web+mobile+shared, e repos separados por servico backend quando extraídos.
- CI/CD:** **GitHub Actions** para CI (build, lint, testes, SAST, scan de dependencias/containers com Trivy) e **ArgoCD (GitOps)** para CD no GA. Pipeline: PR -> testes+scans -> merge -> build imagem assinada (Cosign) -> deploy staging -> Canary 5% -> 25% -> 100% -> Prod (blue-green).
- Feature flags:** **Unleash** (open-source, self-host) ou LaunchDarkly (SaaS). Permite dark launch, rollout por tenant/percentual e kill-switch. Essencial para desacoplar deploy de release.
- Estrategia de deploy:** **blue-green** para o monolito (troca instantanea, rollback rapido) e **canary** (rollout progressivo com analise de metricas via Argo Rollouts) para servicos criticos. Migracoes de banco com **expand/contract** (compativel para frente/para tras) para permitir rollback.



Dificuldade **3**.

4.16 Estrategia de Testes

Piramide de testes com portoes em CI (cobertura minima como gate, nao vaidade):

Camada	Ferramenta	Meta	Onde roda
Unitario	JUnit5/Testify/Vitest	~70% do volume, rapido	Todo push
Integracao	Testcontainers (Postgres/Kafka reais)	Contratos com DB/broker	PR
Contrato (API)	Pact / OpenAPI validation	Compatibilidade entre servicos	PR
E2E	Playwright	Fluxos criticos (OS, checkout)	Pre-merge/nightly
Carga	k6 / Gatling	NFR de throughput/latencia	Antes de release maior
Seguranca	SAST (CodeQL), DAST, Trivy	Vulnerabilidades	CI + agendado
Isolamento multi-tenant	Suite dedicada	Zero vazamento cross-tenant	CI obrigatorio

Dificuldade **3**; a suite de isolamento multi-tenant e negociavel (ver 4.8).

4.17 Observabilidade e Logs

Decisao: stack unificada e portavel sobre **OpenTelemetry** como padrao de instrumentacao (traces, metrics, logs), evitando lock-in de agente proprietario.

Sinal	Ferramenta	Papel
Metricas	Prometheus (+ Thanos p/ long-term no Scale)	Series de saude/negocio
Dashboards/alertas	Grafana + Alertmanager	Visualizacao e SLOs
Logs	Loki	Logs estruturados, barato (indexa labels)
Traces	Tempo	Tracing distribuido
Instrumentacao	OpenTelemetry Collector	Coleta e exporta tudo
Erros	Sentry	Erros de app front/back

Alternativa gerenciada (Datadog/New Relic) e mais simples porem cara em escala; comecar self-host (Grafana stack) mantem custo previsivel, com opcao de Grafana Cloud gerenciado no MVP para nao operar a stack cedo demais. **SLOs** definidos como codigo (Sloth) com **error budgets** guiando ritmo de release. Dificuldade **3**.

4.18 Resiliencia, Alta Disponibilidade, SLO/SLA, Backup e DR

Alta disponibilidade: multi-AZ desde o GA (RDS Multi-AZ, nós K8s em ≥ 2 AZs, replicas de leitura Postgres). Padroes de resiliencia: **circuit breaker**, **retry com backoff+jitter**, **bulkhead**, **timeout**, **idempotencia** (Resilience4j) e **graceful degradation** (ex.: se IA cai, plataforma segue operando sem Health Score em tempo real).

SLO/SLA:

Servico	SLO interno	SLA cliente (GA)
API core	99,95%	99,9%
Ingest telemetria	99,9%	best-effort
Servico IA/laudo	99,5%	best-effort

Backup e DR:

Item	Estrategia	RTO	RPO
Postgres (OLTP)	Snapshots automatizados + PITR (WAL) + replica cross-AZ	GA: 1h / Scale: 15min	5min -> <1min
TimescaleDB (telemetria)	Snapshot + tiering p/ S3	4h	15min
Object storage (S3)	Versionamento + replicacao cross-region (CRR)	min	~0
Config/IaC	Git (fonte da verdade)	min	0

- **DR multi-regiao (Scale):** regioa secundaria (ex.: us-east-1 como DR de sa-east-1, ou outra regioa BR quando disponivel) com **pilot-light -> warm-standby**; replicacao assincrona de dados; **runbooks e game-days trimestrais** para testar failover de verdade. Backups testados por restore automatizado (backup nao testado = backup inexistente).
- Dificuldade **4**; risco: DR "no papel" que falha na hora -> mitigacao: game-days obrigatorios e restore automatizado validado em CI/agendamento.

4.19 Estimativa de Custo de Infraestrutura por Fase

ESTIMATIVA bottom-up (precos de lista AWS sa-east-1, com committed-use no GA/Scale). Cambio R\$ 5,40.
[VALIDAR] com AWS Pricing Calculator e egress real medido.


Componente	MVP (US\$/mes)	GA (US\$/mes)	Scale (US\$/mes)
Compute (K8s/Fargate)	300-600	2.500-4.500	12.000-25.000
Postgres/Aurora + replicas	250-450	1.500-3.000	8.000-16.000
TimescaleDB/telemetria	100-250	800-1.800	5.000-12.000
Kafka (MSK/Confluent)	0 (Redis Streams)	700-1.500	4.000-9.000
Redis (ElastiCache)	80-150	500-1.000	2.500-5.000
S3 + CDN + egress	80-200	700-1.800	4.000-10.000
Observabilidade	100-250 (Grafana Cloud)	500-1.200	3.000-7.000
IA/GPU (inferencia)	100-300 (on-demand)	800-2.500	6.000-15.000
DR/backup/secundaria	incluido	400-1.000	4.000-10.000
Total (US\$/mes)	~1.100-2.450	~8.400-18.300	~48.500-109.000
Total (R\$/mes)	~R\$ 6-13 mil	~R\$ 45-99 mil	~R\$ 262-589 mil

Faixas amplas por design (incerteza de estagio inicial). Alavancas de reducao: committed-use/Savings Plans (-30 a -50% em compute/DB), spot para cargas tolerantes (ingest/batch/IA), compressao+tiering de telemetria, e CDN para cortar egress. Dificuldade de controle de custo **3** — instituir **FinOps** (tags de custo por tenant/modulo, alertas de budget) desde o GA.

4.20 Riscos Arquiteturais e Mitigacao (consolidado)

Risco	Prob.	Impacto	Mitigacao	Prioridade
Vazamento cross-tenant (RLS mal aplicado)	Media	Critico	RLS no banco + testes de isolamento em CI + auditoria	P0
Microservicos prematuros afogam o time	Alta	Alto	Monolito modular; extrair sob dor real	P0
Custo de telemetria explode	Alta	Alto	Compressao/retencao/tiering no TimescaleDB	P1
Complexidade operacional de Kafka/K8s	Media	Alto	Gerenciado (MSK/EKS/Fargate); adiar ao MVP	P1
DR nunca testado falha no incidente	Media	Critico	Game-days + restore automatizado	P1
Lock-in de nuvem	Baixa	Medio	Containers + Terraform + OSS portavel	P2
Sprawl de linguagens/stacks	Media	Medio	Limite de 3 linguagens + scaffolding padrao	P2

4.21 Roadmap e Prioridades (resumo)



O detalhamento acionavel (tarefas com horas, custo, equipe, dependencias, impacto, dificuldade, risco e wave) e entregue no objeto estruturado deste capitulo.

Capítulo 5 — ERP Especializado em Drones Agrícolas

Escopo: Este capítulo especifica o **ERP vertical** da AeroCortex (nome de trabalho, a validar) — o sistema de registro (system of record) que sustenta a operação de oficinas, revendas, DSPs e frotas de drones agrícolas. Ao contrário de um ERP horizontal (SAP, Totvs, Odoo), este ERP nasce com o **DNA do drone**: rastreabilidade vitalícia por Serial Number e lote, catálogos por componente crítico (motores, ESC, baterias LiPo, RTK, controladoras), Ordem de Serviço por estágios e integração nativa com o Digital Twin e o Health Score. Cada decisão é justificada, comparada em tabela contra alternativas, com custo (R\$ e US\$), dificuldade (1 a 5), riscos + mitigação, cronograma e prioridade.

Aviso metodológico: Custos são **ESTIMATIVAS** de trabalho (bottom-up por pessoa-mes de engenharia x custo carregado, + licenças SaaS de lista pública). **Câmbio de trabalho:** US\$ 1,00 = R\$ 5,40. Custo carregado de engenheiro senior BR de trabalho: ~R\$ 35 mil/mes. Todo valor precisa **[VALIDAR]** com cotação real antes de decisão de orçamento.

5.1 Sumário Executivo do Capítulo

O ERP da AeroCortex **nao e um ERP generico adaptado** — e a coluna vertebral transacional de uma plataforma de manutenção de ativos aeronáuticos de alto valor (R\$ 80 mil a R\$ 400 mil por drone Agras). A tese central deste capítulo e a estratégia **Compose-first: construir proprio (build)** apenas os módulos que são *moat* e diferenciação — Ordem de Serviço por estágios, rastreabilidade vitalícia por Serial/lote, catálogos de componente crítico, garantia e peças — e **integrar/terceirizar (buy)** aquilo que é commodity regulatória e sem diferenciação — **fiscal brasileiro (NF-e/NFS-e/SPED)**, gateway de pagamento, contabilidade e frete.

A decisão mestra: **NAO construir motor fiscal proprio**. O compliance fiscal brasileiro (NF-e 4.0, NFS-e nacional, SPED Fiscal/Contribuições, EFD-Reinf) e um pantano regulatório que muda mensalmente por município; reconstruir isso destrói o roadmap. Usamos um **middleware fiscal como serviço** (ex.: eNotas, Focus NF-e, PlugNotas, [NFe.io](#) — classe amplamente conhecida no mercado BR) via API. Da mesma forma, faturamento contábil e conciliado com **ERP contábil do escritório do cliente** via integração, não substituído.

O núcleo próprio adota o modelo de dados de **rastreabilidade como cidadã de primeira classe**: toda peça crítica tem passaporte digital (cadeia de custódia do fabricante ao descarte), e a OS por estágios e a máquina de estados que orquestra a oficina. Cinco portais (Cliente, Técnico, Gestor, Fabricante, Revenda) consomem o mesmo núcleo com escopos distintos.

Investimento estimado do ERP completo: **~R\$ 3,2-4,8 milhões** (build do núcleo ao longo de 18-24 meses) + **~R\$ 8-25 mil/mes** de licenças de serviços integrados (fiscal + pagamentos + frete) no GA. O MVP (OS + Peças + Estoque + Clientes + Fiscal integrado) sai por **~R\$ 900 mil-1,3 mi** em 6-8 meses.


5.2 Filosofia: ERP Vertical vs Horizontal — Por que Construir

Pergunta fundadora: por que não pegar Odoo/ERPNext (open-source) ou Totvs/SAP e adaptar?

Criterio	ERP Horizontal (adaptar Totvs/SAP/Odoo)	ERP Vertical proprio (AeroCortex)
Rastreabilidade por Serial/lote vitalicia	Fraca; lote existe, mas nao "passaporte de componente"	Nativa, cidadã de 1a classe
OS por estagios de drone (bancada, voo de teste, calibracao RTK)	Generica; workflow custom caro	Modelada para o dominio
Catalogo por componente critico (ESC, LiPo, motor)	Item generico	Taxonomia rica com atributos de engenharia
Integracao Digital Twin / Health Score	Inexistente	Nativa (moat)
Custo de licenca por usuario	Alto (SAP/Totvs) a moderado (Odoo)	Zero (SaaS proprio)
Fiscal BR pronto	Sim (Totvs) / parcial (Odoo)	Via middleware integrado
Velocidade de evolucao do produto	Lenta (dependencia de customizador)	Alta (time proprio)
Time-to-market inicial	Rapido	Medio (mitigado por Compose)

Decisao (MELHOR opcao): Construir o nucleo vertical, compor o commodity. O moat da AeroCortex e dados de manutencao + rastreabilidade + IA; isso *precisa* viver em um schema proprio. Mas fiscal, pagamento e frete sao terceirizados. Isso e a estrategia **Composable ERP** — o padrao moderno (headless/API-first) que a Gartner descreve para ERPs pos-monoliticos.

5.3 Mapa de Modulos do ERP



5.4 Modulo CRM, Clientes e Fornecedores

Funcao: cadastro 360 de clientes (produtores rurais, DSPs, cooperativas, revendas), fornecedores (DJI, distribuidores de pecas, fabricantes de LiPo), leads e pipeline comercial. Integra com o modulo de OS (historico de servicos do cliente) e com o Digital Twin (frota do cliente).

Entidades-chave: **Cliente** (PF/PJ, CPF/CNPJ, endereco, inscricao estadual, regime tributario), **Contato**, **Fornecedor** (com rating de qualidade de peca), **Lead**, **Oportunidade**, **Contrato** (SLA de manutencao, planos de assinatura). Suporte a **hierarquia** (cooperativa -> produtores associados).

Diferenciais verticais: cada cliente carrega sua **frota vinculada** (drones por Serial), com Health Score agregado visivel ao gestor comercial — permite upsell proativo ("3 drones do cliente X com bateria em fim de vida"). Recomendacao: **BUILD** (integrado ao nucleo; CRM generico nao entende frota de drone). Dificuldade 3.

5.5 Modulo Financeiro e Fiscal (NF-e / NFS-e / SPED)

Este e o modulo onde **Buy vence Build de forma decisiva** no componente fiscal.

Financeiro (contas a pagar/receber, fluxo de caixa, conciliacao): BUILD leve no nucleo — modelamos `TituloFinanceiro` (a pagar/receber), `Parcela`, `MovimentoCaixa`, `CentroCusto`. Simples o suficiente para nao justificar ERP externo, e precisa estar acoplado a OS (faturamento de servico gera titulo automaticamente).

Fiscal (emissao de documento): BUY via middleware fiscal API-first. Comparativo:

Opcao Fiscal	Cobertura	Esforco integracao	Custo	Risco	Recomendacao
Motor fiscal proprio	Total (se mantido)	5/5 (24+ meses)	R\$ 2-4 mi + manutencao eterna	Altissimo (muda por municipio)	Nao
Middleware SaaS (eNotas/Focus/PlugNotas/NFe.io)	NF-e, NFS-e (milhares de municipios), NFC-e	2/5	~R\$ 0,10-0,50/nota + mensalidade	Baixo	MELHOR
ERP fiscal completo (Totvs modulo)	Total	4/5	Licenca alta + lock-in	Medio	Nao (over-engineered)

SPED (Fiscal, Contribuicoes, EFD-Reinf): geramos os arquivos via o mesmo middleware ou via **export para o contador** (SPED e apuracao, geralmente feita pelo escritorio contabil do cliente). Modelamos os dados fiscais (CFOP, NCM, CST, ICMS/IPI/PIS/COFINS/ISS) no nucleo e delegamos a apuracao. **Decisao: middleware fiscal + export contabil.** Dificuldade 2 (integracao) vs 5 (build). Isso economiza ~R\$ 2-4 mi e ~18 meses.

5.6 Modulo Compras, Estoque e Almoxarifado

Compras: `RequisicaoCompra` -> `PedidoCompra` -> `RecebimentoMercadoria` -> entrada em estoque com **captura obrigatoria de Serial/lote** no recebimento (ponto de nascimento da cadeia de custodia interna). Cotacao multi-fornecedor, aprovacao por alcada.


Estoque e Almoxarifado: controle multi-deposito (matriz, filiais, van do tecnico de campo, consignado). Kardex por item, curva ABC, ponto de reposicao, reserva de peca para OS. Diferencial: **estoque serializado** — para pecas criticas (baterias, motores, RTK), cada unidade e rastreada individualmente, nao apenas por quantidade.


Tipo de item	Controle	Exemplo
Serialized (unico)	Por Serial Number	Bateria LiPo, motor, ESC, controladora, modulo RTK
Por lote	Por lote + validade	Selantes, adesivos, graxas, o-rings
Por quantidade	Saldo simples	Parafusos, cabos genericos, EPI

Recomendacao: **BUILD** (estoque serializado e o coracao da rastreabilidade; ERPs genericos fazem isso mal para o caso drone). Dificuldade 4.

5.7 Modulo Ordem de Servico (OS por Estagios) — Coracao Operacional

A OS e a **maquina de estados** que orquestra a oficina. Modelada como workflow configuravel por tipo de servico (corretiva, preventiva, sinistro, upgrade, revisao de garantia).





Entidades: `OrdemServico`, `EstagioOS` (com SLA por estagio, responsavel, checklist), `ItemOS` (pecas + servicos), `RegistroTempo` (apontamento de mao de obra), `Anexo` (fotos, videos, logs), `Aprovacao`. Cada transicao gera **evento imutavel** (trilha de auditoria — alinhado ao event-driven do Cap. 4).

Diferenciais verticais: estagios especificos de drone (Calibracao RTK, Voo de Teste com telemetria capturada), integracao com leitura de logs DJI no Diagnostico, sugestao de laudo pela IA (Health Score). **Recomendacao: BUILD (moat maximo)**. Dificuldade 5. Prioridade **P0 no MVP**.

5.8 Modulo Agenda e Agendamento

Agenda de bancadas, tecnicos e equipamentos de teste. Agendamento de coleta/entrega, visitas de campo (manutencao no local do produtor), janelas de safra (pico de demanda). Integra OS (cada estagio pode gerar compromisso) e capacidade da oficina (evita overbooking de bancada). **Recomendacao: BUILD leve** (acoplado a OS). Dificuldade 3.

5.9 Modulo Pecas, Garantia e Catalogos de Componente Critico

Catalogo mestre de pecas com taxonomia rica por familia de componente critico. Cada familia tem **atributos de engenharia** proprios:

Componente critico	Atributos-chave rastreados	Metrica de vida util
Motor (BLDC)	KV, corrente max, fabricante, torque	Horas de voo, temperatura acumulada
ESC	Amperagem, firmware, protocolo	Ciclos, falhas de sync
Bateria LiPo	Capacidade (mAh), S (celulas), C-rate, quimica	Ciclos de carga, SoH, inchaco, IR
Carregador	Potencia, canais, protocolo	Horas de uso
RTK (base/rover)	Freq., precisao, firmware	Horas, versao de correcao
Controladora de voo	Modelo, firmware, IMU/compass	Horas, resets, erros criticos
Bomba	Vazao (L/min), tipo, material	Horas, litros bombeados, corrosao
Sensor (radar/LiDAR/camera)	Alcance, resolucao, firmware	Horas, drift de calibracao


Garantia: modelamos `Garantia` (por peca serializada e por servico prestado), com regras de cobertura (fabricante DJI vs revenda vs AeroCortex), acionamento de **RMA** (Return Merchandise Authorization) ao fabricante, e workflow de

sinistro. A rastreabilidade permite responder instantaneamente: "esta bateria ainda esta na garantia? quantos ciclos tem? foi trocada em qual OS?".

Recomendacao: BUILD (moat central). Dificuldade 4. Prioridade P0 (pecas+catalogo) / P1 (garantia+RMA).

5.10 Rastreabilidade Vitalicia por Serial Number e Lote (Cadeia de Custodia)

Este e o **diferencial mais defensavel** do ERP. Cada peca critica tem um **passaporte digital** que registra toda sua vida — do fabricante ao descarte — de forma imutavel.



Entidade central: `EventoRastreabilidade` (append-only) ligada a `PecaSerializada`. Cada evento: tipo, timestamp, ator, OS relacionada, drone relacionado, localizacao, documento fiscal. Isso responde perguntas de compliance, seguro e seguranca de voo: "esta LiPo que pegou fogo tinha quantos ciclos? em quais 4 drones ja foi instalada? qual lote? ha recall?". Habilita **recall dirigido** (localizar todas as unidades de um lote defeituoso em minutos) — valor enorme para fabricantes e seguradoras.

Recomendacao: BUILD, event-sourced. Dificuldade 5. Prioridade P0 (nasce com o MVP; retrofit posterior e caro). Risco: performance de trilha append-only em escala — **mitigacao:** particionamento temporal + TimescaleDB/tabela particionada (Cap. 4).


5.11 Portais (Cliente, Tecnico, Gestor, Fabricante, Revenda)

Cinco portais consomem o mesmo nucleo com escopos (RBAC/ABAC) e UX distintos.

Portal	Persona	Funcionalidades principais	Prioridade
Cliente	Produtor, DSP, cooperativa	Acompanhar OS em tempo real, aprovar orcamento, ver frota + Health Score, historico, garantias, faturas, agendar servico	P0 (MVP)
Tecnico	Mecanico/bancada	App mobile: fila de OS, checklist por estagio, apontamento de tempo, foto/video, leitura de peca (QR/Serial), baixa de estoque, laudo assistido por IA	P0 (MVP)
Gestor	Dono da oficina/revenda	Dashboards (faturamento, SLA por estagio, produtividade, margem por OS), gestao de estoque/compras, aprovacoes por alcada, BI	P1 (GA)
Fabricante	DJI/XAG/Jacto	Visao de campo agregada e anonimizada: falhas por modelo/lote, RMAs, taxa de retorno, dados para recall, garantia	P2 (Scale)
Revenda	Distribuidor autorizado	Multi-oficina, repasse de garantia, estoque consignado, comissoes, pipeline de vendas de pecas	P1-P2


O portal Fabricante e a **ponte B2B2B** que transforma dados de campo em produto vendavel (insights de confiabilidade) — receita adicional e alinhado ao moat de dados.

5.12 Modelo de Dados Resumido (ER Simplificado)



Entidades centrais: Cliente, Fornecedor, Drone, PecaSerializada, CatalogoPeca, FamiliaComponente, ComponenteInstalado, OrdemServico, EstagioOS, ItemOS, EventoRastreabilidade, Garantia, TituloFinanceiro, DocumentoFiscal. As relacoes com DigitalTwin e HealthScore sao as pontes com os capitulos de IA/Twin.

5.13 Integrações



Integracao	Padrao	Direcao	Prioridade	Dificuldade
Fiscal (middleware)	REST API	Bidirecional	P0	2
Pagamento (Pix/cartao)	REST + Webhook	Bidirecional	P0	2
Transportadoras	REST (cotacao + rastreo)	Bidirecional	P1	3
Contabilidade	Export SPED / API	Saida	P1	2
DJI Cloud/SDK	REST/SDK (logs, telemetria)	Entrada	P0-P1	4
Digital Twin	Evento interno (Kafka)	Bidirecional	P1	3
Health Score / IA	Evento interno	Entrada	P1	3

Risco DJI: SDK/API de terceiros com termos restritivos e mudancas unilaterais. **Mitigacao:** camada anti-corrupcao (adapter) isolando o dominio interno; fallback de importacao manual de logs.

5.14 Analise Build vs Buy vs Compose por Modulo (Decisao Consolidada)

Modulo	Build	Buy	Compose		Justificativa	Dif.	Prioridade
OS por estagios	✓			BUILD	Moat maximo, dominio unico	5	P0
Rastreabilidade Serial/lote	✓			BUILD	Diferencial defensavel	5	P0
Catalogos componente critico	✓			BUILD	Taxonomia de engenharia unica	4	P0
Pecas & Garantia/RMA	✓			BUILD	Acoplado a rastreabilidade	4	P0/P1
Estoque serializado	✓			BUILD	Nucleo da rastreabilidade	4	P0
CRM / Clientes / Fornecedores	✓		~	BUILD leve	Precisa de frota vinculada	3	P0
Financeiro (AP/AR)	✓			BUILD leve	Acoplado a OS; simples	3	P0/P1
Fiscal (NF-e/NFS-e/SPED)		✓	✓	COMPOSE (middleware)	Pantano regulatorio; commodity	2	P0
Pagamentos		✓	✓	COMPOSE (gateway)	Commodity; PCI fora de escopo	2	P0
Compras	✓			BUILD	Ligado a recebimento serializado	3	P1
Agenda	✓			BUILD leve	Acoplado a OS/capacidade	3	P1
Transportadoras			✓	COMPOSE	API de cotacao/rastreo	3	P1
Contabilidade		✓	✓	COMPOSE (export)	Feito pelo contador do cliente	2	P1
BI / Dashboards	~	✓	✓	COMPOSE (Metabase/embed)	Nao reinventar BI	3	P1/P2

Regra de ouro: BUILD o que e moat (dado + workflow do dominio), COMPOSE o que e regulatorio/commodity, evitar BUY monolitico (lock-in). Isso reduz o investimento inicial em ~40% e o time-to-market em ~8-12 meses versus construir tudo.

5.15 Custos, Cronograma e Prioridade por Fase

Premissas: time nucleo de 5-7 engenheiros; custo carregado ~R\$ 35 mil/mes/eng; **[VALIDAR]** com folha real.

Fase	Modulos	Duracao	Esforco (pessoa-mes)	Custo estimado (R\$)	Custo (US\$)
MVP	OS, Rastreabilidade, Catalogo, Pecas, Estoque serializado, CRM leve, Financeiro basico, Fiscal+Pagamento integrados, Portais Cliente+Tecnico	6-8 meses	30-38	R\$ 900 mil-1,3 mi	US\$ 167-241 mil
GA	Garantia/RMA, Compras, Agenda, Portal Gestor+BI, Frete, Contabilidade, DJI integracao	+6-8 meses	40-52	R\$ 1,4-1,8 mi	US\$ 259-333 mil
Scale	Portal Fabricante+Revenda, multi-oficina, insights B2B, consignado, comissoes, hardening/escala	+6-8 meses	26-40	R\$ 0,9-1,7 mi	US\$ 167-315 mil
Total build	—	18-24 meses	96-130	R\$ 3,2-4,8 mi	US\$ 593-889 mil

Custos recorrentes de servicos compostos (GA, mensal): fiscal ~R\$ 2-6 mil + por-nota; pagamentos ~2-4% do TPV; frete por cotacao; BI embed ~R\$ 0,5-2 mil. Total ~R\$ 8-25 mil/mes **[VALIDAR]**.

5.16 Riscos e Mitigacao

Risco	Prob.	Impacto	Mitigacao
Fiscal BR muda e quebra emissao	Alta	Alto	Terceirizar em middleware (transferir risco ao fornecedor especialista)
Rastreabilidade mal modelada -> retrofit caro	Media	Altissimo	Event-sourcing desde o MVP; nao adiar
Lock-in em middleware fiscal	Media	Medio	Camada de abstracao fiscal; contrato com portabilidade
Performance da trilha append-only	Media	Medio	Particionamento temporal, TimescaleDB, arquivamento
Dependencia de API DJI (termos/mudancas)	Alta	Alto	Adapter anti-corrupcao + import manual de fallback
Complexidade da OS por estagios estoura prazo	Media	Alto	Workflow configuravel, mas MVP com 1 fluxo fixo; generalizar depois
Adocao pelos tecnicos (UX de campo)	Media	Alto	App mobile offline-first, leitura QR/Serial, design testado com oficina piloto

5.17 Conclusao do Capitulo

O ERP da AeroCortex vence pela **especializacao onde importa e pragmatismo onde nao importa**. O nucleo proprio — OS por estagios, rastreabilidade vitalicia, catalogos de componente critico, pecas e garantia — e o *moat* transacional que nenhum ERP horizontal replica. O fiscal, pagamento, frete e contabilidade sao compostos via APIs de especialistas, poupando milhoes e anos. O modelo Compose-first entrega um MVP defensavel em 6-8 meses (~R\$ 0,9-1,3 mi) e um ERP completo, integrado ao Digital Twin e a IA, em 18-24 meses (~R\$ 3,2-4,8 mi). A rastreabilidade event-sourced e a decisao irreversivel: precisa nascer no MVP, pois retrofit e proibitivo. Este ERP e a fundacao de dados sobre a qual o Health Score, o Digital Twin e o marketplace da plataforma serao construidos.

Capítulo 6 — Drone Digital Twin

Escopo: Este capítulo especifica o módulo **Drone Digital Twin (DDT)** da AeroCortex (nome de trabalho, a validar): a representação digital viva de cada drone agrícola. Cada equipamento físico (DJI Agras T20/T25/T40/T50, XAG, Jacto e futuros) ganha um **clone digital** que acumula todo o seu ciclo de vida — horas de voo, litros pulverizados, saúde de motores, temperaturas, erros, alertas, peças trocadas, histórico completo, fotos, vídeos, laudos, checklists, firmware/versão, localização, serial, número de ciclos, vida útil prevista, saúde do equipamento e **Drone Health Score**. Definimos a arquitetura de ingestão de telemetria (logs DAT/DJI, MQTT, upload por app, integração ERP e IA), o banco de séries temporais, o object storage de mídia, o modelo de dados do twin, seu ciclo de vida e versionamento de estado, a API do twin, a visualização (dashboard e 3D opcional) e a integração com IA Preditiva, Computer Vision e Health Score.

Aviso metodológico: Custos são **ESTIMATIVAS** de trabalho (dimensionamento bottom-up de esforço de engenharia e recursos de nuvem x preços de lista). **Câmbio de trabalho:** US\$ 1,00 = R\$ 5,40. Todo valor deve ser validado com **[VALIDAR]** cotação real (AWS Pricing Calculator, folha de custo de time) antes de decisão de orçamento. Este capítulo herda as decisões de arquitetura do Capítulo 4 (PostgreSQL 16 + TimescaleDB, Kafka/Redis Streams, S3, Go para ingest, event-driven no núcleo).

6.1 Sumário Executivo do Capítulo

O **Drone Digital Twin** é o coração de dados e o **moat** da AeroCortex: enquanto concorrentes vendem software de OS (ordem de serviço), a AeroCortex vende a **memória completa e viva de cada drone** — um "prontuário + passaporte" que agrega valor a cada voo e não pode ser replicado por quem chega depois. O twin transforma dados brutos e dispersos (arquivos DAT no cartão SD, planilhas de oficina, fotos no celular do técnico) em um **estado consolidado, versionado e consultável** que alimenta IA Preditiva, Computer Vision e o Drone Health Score, e que sustenta valor residual do ativo, garantia, seguro e revenda.

Decisão mestra: adotamos o padrão **twin híbrido — snapshot de estado + event sourcing (log de eventos imutável)**. O estado corrente do drone (para leituras rápidas e dashboard) é materializado a partir de um **log de eventos append-only** (a fonte da verdade), o que dá versionamento temporal nativo ("como estava o drone em qualquer data"), auditabilidade e capacidade de reprocessar o Health Score quando os modelos de IA evoluem. A telemetria de alta frequência vai para **TimescaleDB** (extensão do Postgres já escolhido no Cap. 4), a mídia para **S3**, e o estado + eventos de domínio para **PostgreSQL** com trilha em **Kafka**.


Custo de construção estimado do módulo: **~R\$ 480 mil - R\$ 820 mil (US\$ 89 mil - US\$ 152 mil)** ao longo de MVP+GA, mais **~R\$ 3-9 mil/mes** de infra incremental no MVP. Prioridade **P0** — o twin é pré-requisito de praticamente todos os módulos de IA e do diferencial competitivo.

6.2 O Que é o Twin — Definição e Papel na Plataforma

Um digital twin, no contexto AeroCortex, **não** é uma simulação física em tempo real do voo (não pilotamos o drone remotamente). É um **twin de ciclo de vida (lifecycle twin / asset twin)**: uma entidade de dados que espelha fielmente o estado, o histórico e a saúde do ativo físico ao longo de toda a sua vida, do desembalar ao descarte/revenda.

Papeis do twin:

1. **Prontuário único** — reúne tudo que se sabe sobre aquele serial específico.
2. **Passaporte digital** — trilha imutável que comprova procedência, manutenção e uso (valor de revenda, garantia, seguro).
3. **Substrato de IA** — features consolidadas que alimentam predição de falha, CV e Health Score.
4. **Fonte de verdade operacional** — o que a oficina, o operador e o ERP consultam para decidir manutenção.



6.3 Modelo de Dados do Twin — O Que Armazenar

O twin e composto por **quatro categorias de dado** com características de acesso e armazenamento distintas — a separacao correta e o que mantem custo baixo e leitura rapida.

Categoria	Exemplos	Onde vive	Frequencia	Padrao de acesso
Estado / cadastro (twin state)	serial, modelo, firmware/versao, localizacao atual, dono/tenant, status, vida util prevista, Health Score atual, contadores agregados	PostgreSQL (tabela <code>twin</code>)	muda em eventos	leitura constante (dashboard)
Eventos de dominio (log)	peca trocada, OS aberta/fechada, alerta, laudo emitido, checklist, upgrade de firmware, mudanca de dono	PostgreSQL (<code>twin_event</code> , append-only) + Kafka	por evento	append + replay historico
Series temporais (telemetria)	horas de voo, litros pulverizados, RPM/temperatura/corrente de motor, tensao/ciclos de bateria, GPS, erros/warnings do voo	TimescaleDB (hypertables)	alta (por voo)	agregacao/janela
Midia e documentos	fotos, videos, laudos PDF, screenshots de erro, DAT bruto arquivado	S3 (object storage) + metadados no Postgres	por upload	esporadico, CDN

Campos de estado do twin (nucleo — tabela `twin`):

Campo	Tipo	Origem	Observacao
<code>serial</code> (PK natural)	string	DJI/fabricante	identidade fisica imutavel
<code>tenant_id</code>	uuid	plataforma	multi-tenancy (RLS, Cap. 4)
<code>modelo</code> , <code>fabricante</code>	enum	cadastro	DJI Agras T40/T50, XAG, Jacto
<code>firmware-versao</code>	string	telemetria/app	historico completo em <code>twin_event</code>
<code>localizacao_atual</code>	geo + texto	telemetria/app	ultima conhecida
<code>horas_voo_total</code>	numeric	agregacao de series	contador materializado
<code>litros_pulverizados_total</code>	numeric	agregacao de series	idem
<code>ciclos_total</code>	int	agregacao	ciclos de voo/decolagem/bateria
<code>motores[]</code>	jsonb/tabela filha	telemetria + OS	saude por motor (1..N), horas, ultima troca
<code>baterias[]</code>	jsonb/tabela filha	telemetria	ciclos, saude, temperatura
<code>pecas_criticas[]</code>	tabela filha	OS/ERP	bomba, bicos, hastes, ESCs — horas desde troca
<code>vida_util_prevista</code>	numeric/data	IA Preditiva	RUL (Remaining Useful Life)
<code>health_score</code>	0-100 + faixa	Health Score	denormalizado para leitura rapida
<code>status</code>	enum	plataforma	ativo, em_manutencao, inativo, vendido, sinistrado
<code>state_version</code>	int	plataforma	versao do estado (versionamento)
<code>updated_at</code> , <code>created_at</code>	timestampz	plataforma	auditoria


Contadores agregados (`horas_voo_total` , `litros_pulverizados_total` , `ciclos_total`) sao **materializados** via *continuous aggregates* do TimescaleDB e/ou consumo de eventos, para o dashboard nao ter que varrer bilhoes de pontos. A verdade granular vive nas series; o twin state e a **projecao** rapida.

6.4 Comparacao de Abordagens de Modelagem do Twin

Como representar o twin? Tres padroes concorrem — a escolha define versionamento, auditabilidade e capacidade de reprocessar IA.

Abordagem	Como funciona	Vantagens	Desvantagens	Veredito
State-only (CRUD)	uma linha por drone, sobrescrita a cada update	simples, barato, leitura trivial	perde historico, sem "como estava em X", auditoria fraca, nao reprocessa score	Insuficiente (so p/ protótipo)
Event sourcing puro	so o log de eventos existe; estado sempre derivado	auditoria total, viagem no tempo, reprocessavel	leitura lenta sem projecao, curva de aprendizado, complexo p/ time pequeno	Overkill isolado
Hibrido: snapshot + event sourcing (recomendado)	log de eventos append-only e a verdade; estado materializado (projecao) p/ leitura; snapshots periodicos	leitura rapida + historico completo + reprocessavel + auditavel; versionamento nativo	mais engenharia que CRUD; precisa disciplina de projecao	MELHOR
Twin "pesado" (simulacao fisica / gêmeo 3D em tempo real)	modelo fisico do drone rodando em paralelo (ex.: fadiga estrutural simulada)	fidelidade fisica maxima	custo e complexidade enormes, dados de sensor insuficientes p/ calibrar	Fora de escopo (roadmap distante)

Decisao: twin hibrido (snapshot + event sourcing). Justificativa: (1) o versionamento de estado ("como estava o drone quando foi vendido / quando o motor falhou") e requisito de negocio (passaporte, garantia, disputa de seguro); (2) quando um modelo de IA melhora, precisamos **reprocessar o Health Score historico** — so possivel com o log de eventos + series preservados; (3) leitura de dashboard precisa ser instantanea — a projecao materializada resolve. Nao adotamos event sourcing puro (leitura sofre) nem simulacao fisica (dados insuficientes, custo desproporcional). Dificuldade 4.




6.5 Arquitetura de Ingestao de Telemetria

O dado do drone chega por **multiplos canais** com formatos e latencias muito diferentes. O ingest deve normalizar tudo em um **schema canonico de telemetria** antes de persistir. Servico de ingest em **Go** (Cap. 4), stateless, escalavel horizontalmente.

Canal	Formato	Latencia	Volume	Complexidade	Uso
Arquivos DAT/DJI (log de voo)	binario proprietario DJI (.DAT, .txt/logs)	batch (pos-voo)	alto por arquivo	Alta (parsing/engenharia reversa)	fonte mais rica de telemetria historica
MQTT (streaming)	JSON/binario sobre MQTT	quase real-time	continuo	Media	drones/gateways que suportam telemetria live
Upload por app (mobile/web)	JSON, fotos, checklist, DAT	sob demanda	medio	Baixa-Media	operacao de campo, offline-first (Cap. 4)
Integracao ERP	REST/eventos	eventual	baixo	Media	pecas trocadas, custo, NF-e, OS financeira
Integracao IA (retorno)	eventos Kafka	por processamento	medio	Media	score, RUL, deteccoes de CV escrevem no twin

Fluxo de ingestao (canonizacao -> persistencia -> eventos):



Pontos criticos de projeto:

- **Idempotencia e deduplicacao:** o mesmo DAT pode ser enviado 2x (app re-sincroniza). Chave de idempotencia por hash do arquivo + `(serial, timestamp_voo)`. Sem isso, contadores (horas/litros) duplicam — erro grave.
- **Parser DAT (o item mais arriscado):** o formato DJI e proprietario e parcialmente nao documentado. Existem projetos comunitarios de parsing e ferramentas oficiais/semi-oficiais da DJI; a estrategia e comecar extraindo os campos de maior valor (tempo de voo, alturas, alertas, tensao de bateria, GPS) e expandir. **Nunca inventar campos;** validar cada campo contra a documentacao/ferramenta oficial DJI e contra voos reais. Ver Cap. 5/ingestao para detalhamento da integracao DJI.
- **Buffer/backpressure:** picos pos-jornada (dezenas de drones sincronizando a noite). Redis Streams (MVP) / Kafka (GA) absorvem o pico; ingest consome no proprio ritmo.
- **Associacao ao tenant:** todo dado entra amarrado a `(serial, tenant_id)` com RLS (Cap. 4) — vazamento cross-tenant aqui e catastrofico.

6.6 Banco de Series Temporais — TimescaleDB vs InfluxDB

A telemetria (RPM, temperatura, corrente por motor, tensao de bateria, GPS, litros/min) e a maior massa de dados do twin. A escolha do TSDB define custo e simplicidade operacional.

Criterio (peso)			ClickHouse
Consolidacao com stack (Postgres ja escolhido) (25%)	Excelente (e o proprio Postgres)	Fraca (novo motor)	Fraca
SQL / familiaridade do time (15%)	Excelente (SQL puro + joins com dados relacionais)	Media (Flux/InfluxQL)	Boa (SQL-like)
Compressao e retencao (hot/cold) (15%)	Muito boa (compressao nativa + tiering S3)	Muito boa	Excelente
Ingest throughput bruto (15%)	Muito bom	Excelente	Excelente
Continuous aggregates (contadores materializados) (10%)	Excelente	Bom	Bom (mat. views)
Custo operacional / gerenciado (10%)	Baixo (RDS/Timescale Cloud)	Medio	Medio-alto
Ecossistema BI/Grafana (10%)	Excelente	Excelente	Bom
Veredito	MELHOR	Alternativa forte se so-telemetria	Melhor p/ OLAP massivo (Scale)

Decisao: TimescaleDB. Justificativa decisiva: e uma **extensao do PostgreSQL** que ja e o banco primario (Cap. 4), entao ganhamos **um so motor, um so backup, um so skillset, e joins nativos** entre a telemetria (serie) e o dado relacional do twin (serial, tenant, OS) — algo que InfluxDB nao faz bem (exigiria correlacao na aplicacao). Continuous aggregates materializam os contadores do twin (horas de voo, litros) de forma barata. InfluxDB so venceria num cenario puro de telemetria sem correlacao relacional — nao e o nosso. ClickHouse fica reservado para o data lake analitico no **Scale**, se o volume de series ultrapassar bilhoes de pontos com necessidade OLAP pesada.

- Custo/dificuldade: dificuldade **3**. Risco: crescimento de series estoura IO/custo -> mitigacao: politicas de **compressao** (apos 7-30d) e **tiering hot/cold** (hot 90d no TimescaleDB, cold em S3/Parquet), definidas desde o MVP. **[VALIDAR]** volume real por drone/voo com dados de campo.


6.7 Object Storage para Midia

Fotos de inspecao, videos, laudos PDF, screenshots de erro e o **DAT bruto arquivado** vao para **S3** (Cap. 4), nunca para o banco (BLOB em Postgres e caro e nao escala). Metadados (qual foto, de qual OS, de qual serial, hash, EXIF, geo) ficam no Postgres apontando para a chave S3.

- **Organizacao de chaves:** `tenant_id/serial/tipo/ano/mes/uuid.ext` — facilita lifecycle, particao por tenant e limpeza.
- **Lifecycle S3:** Standard -> Infrequent Access (90d) -> Glacier (1a) para midia antiga e DAT bruto; laudos e fotos "de valor" (que embasam garantia/seguro) ficam em classe quente + versionamento + Object Lock (WORM) para imutabilidade legal.
- **Entrega:** URLs pre-assinadas + CDN (CloudFront) para nao expor bucket e cortar egress.
- **Integracao CV:** ao subir foto, evento dispara pipeline de Computer Vision (deteccao de trinca, corrosao, desgaste de bico) cujo resultado volta como evento de dominio para o twin. Dificuldade **2**.

6.8 Ciclo de Vida do Twin

O twin nasce, evolui e "morre" acompanhando o ativo fisico. Estados e transicoes:



Regras de ciclo de vida:

- **Provisionamento:** twin criado no cadastro (serial + modelo + tenant), mesmo antes do 1o voo. Idempotente por serial (nunca dois twins para o mesmo serial global).
- **Transferencia de propriedade (revenda):** o twin **persiste** — muda o `tenant_id` corrente, mas o **historico completo continua** (esse e o valor do passaporte). Política de privacidade LGPD: o novo dono ve historico tecnico (manutencao, horas), mas dados sensiveis do dono anterior (localizacao de fazendas, clientes) sao **redacted**/anonimizados conforme contrato. Decisao de granularidade da heranca de historico e **[VALIDAR]** com juridico.
- **Descarte/sinistro:** twin arquivado (read-only), mas preservado para historico de frota, garantia e analise de falha de fleet.

6.9 Versionamento de Estado do Twin

Requisito central: responder **"como estava o drone X em qualquer data?"** e **reprocessar o Health Score** quando o modelo de IA muda. Como o padrao e event sourcing hibrido, o versionamento e natural:

Mecanismo	O que da	Como
Log de eventos append-only (<code>twin_event</code>)	fonte da verdade, viagem no tempo	cada mudanca e um evento imutavel com <code>state_version++</code>
Snapshots periodicos	reconstrucao rapida sem replay total	snapshot do estado a cada N eventos / periodicamente
Series bi-temporais (event_time vs ingest_time)	distingue "quando ocorreu" de "quando soubemos"	2 timestamps na telemetria/eventos
Score versionado (<code>model_version</code> no score)	rastrear qual modelo gerou o score	reprocessar historico com replay quando modelo evolui

Reconstrucao de estado em uma data: `snapshot mais recente <= data` + replay dos eventos ate a data. Isso da a "foto" exata do drone para laudo, disputa de garantia/seguro e auditoria. O `state_version` monotonicos tambem serve de **controle de concorrencia otimista** (evita escritas conflitantes de dois canais simultaneos). Dificuldade 4.

6.10 API do Twin

A API do twin e a interface publica do modulo — consumida pelo dashboard, mobile, ERP, parceiros e pelos servicos de IA. Contrato em **OpenAPI 3.1** (REST) para CRUD/consulta e **eventos versionados via schema registry (Avro/Protobuf) no Kafka** para o fluxo assincrono (Cap. 4).

Endpoint / evento	Metodo	Descricao
/v1/twins/{serial}	GET	estado corrente completo do twin
/v1/twins/{serial}/state?at={data}	GET	estado historico (viagem no tempo)
/v1/twins/{serial}/events	GET	log de eventos (paginado, filtravel)
/v1/twins/{serial}/telemetry? metric=&from=&to=&agg=	GET	series agregadas (janela/agregacao)
/v1/twins/{serial}/media	GET/POST	midia (URLs pre-assinadas)
/v1/twins/{serial}/events	POST	registra evento de dominio (peca trocada, checklist)
/v1/twins/{serial}/health	GET	Health Score atual + historico + explicabilidade
telemetry.raw (Kafka)	evento	telemetria normalizada ingerida
twin.event.created (Kafka)	evento	novo evento de dominio no twin
twin.healthscore.updated (Kafka)	evento	score recalculado (dispara alerta/OS)

Decisoes de API: versionamento por URI (/v1); paginacao por cursor para eventos/series (nao offset — series sao enormes); leitura de telemetria **sempre agregada** (o cliente pede metrica+janela+agregacao, nunca ponto-a-ponto bruto); escrita de eventos idempotente (chave de idempotencia obrigatoria); RLS/tenant em toda rota. GraphQL considerado e **adiado** — o padrao de acesso e conhecido e REST+eventos e mais simples de cachear e versionar. Dificuldade 3.

6.11 Visualizacao — Dashboard e 3D Opcional

Dashboard do twin (obrigatorio, MVP): pagina "prontuario do drone" com Health Score em destaque, contadores (horas, litros, ciclos), saude por motor/bateria (semaforo), timeline de eventos (OS, alertas, trocas, firmware), galeria de midia/laudos, mapa da ultima localizacao e alertas/RUL da IA Preditiva. Construido em Next.js + Recharts/visualizacao de series (Cap. 4), consumindo a API do twin.


Visao 3D (opcional, GA+): representacao 3D do drone com componentes clicaveis (motor 1..N, bomba, bateria) coloridos pelo estado de saude — "hotspots" que abrem o detalhe/historico da peca. Comparacao de abordagens:

Abordagem 3D	Custo/esforco	Valor percebido	Veredito
Sem 3D — so dashboard 2D + semaforos	baixo	alto (ja resolve 90%)	MVP
3D leve (modelo estatico + hotspots, Three.js/R3F)	medio	alto (efeito "uau" comercial + navegacao intuitiva por componente)	GA (diferencial de venda)
3D realista / simulacao fisica	altissimo	baixo (dados nao sustentam)	Nao

Decisao: dashboard 2D no MVP; **3D leve com hotspots de saude por componente no GA** como diferencial comercial e de UX (navegar o drone e clicar no motor com problema). Simulacao fisica 3D fica fora. Dificuldade: 2D 2, 3D leve 3.

6.12 Integracao com IA Preditiva, Computer Vision e Health Score

O twin e o **substrato** desses tres modulos (detalhados em seus proprios capitulos) — aqui definimos os **contratos de dados**.



- **IA Preditiva:** consome do twin uma **feature store** (series agregadas por janela + contadores + intervalo desde ultima troca + eventos de erro) e devolve **RUL (vida util restante)** e **probabilidade de falha por componente**, que gravam de volta no twin como eventos (`vida_util_prevista` , alertas). Reprocessavel via replay quando o modelo evolui (secao 6.9).
- **Computer Vision:** ao subir foto/video, evento dispara pipeline de CV; deteccoes (trinca em haste, corrosao, desgaste/entupimento de bico, dano em helice) voltam como **eventos de dominio** anexados a midia, entrando no historico e no Health Score.
- **Drone Health Score:** funcao que combina series (temperatura/corrente anômala de motor, degradacao de bateria, frequencia de erros), saidas da IA Preditiva (RUL) e da CV (defeitos visuais) em um **score 0-100 com faixas (verde/amarelo/vermelho) e explicabilidade** (quais fatores puxaram o score). O score e denormalizado no twin state (leitura rapida) e versionado por `model_version` . Score abaixo do limite dispara alerta e sugestao de OS preventiva (fluxo do Cap. 4). Dificuldade da integracao **4**.

6.13 Seguranca, Privacidade e Integridade (LGPD)

Aspecto	Medida
Isolamento multi-tenant	RLS + <code>tenant_id</code> em twin, eventos, series e midia (Cap. 4); testes de vazamento em CI
Imutabilidade do passaporte	<code>twin_event</code> append-only; midia de valor com S3 Object Lock (WORM)
Privacidade na revenda	anonimizacao/redaction de dados sensiveis do dono anterior (fazendas, clientes) na transferencia — [VALIDAR] com juridico
Integridade dos contadores	idempotencia/deduplicacao no ingest (horas/litros nunca duplicam)
Criptografia	em transito (TLS) e repouso (S3/RDS KMS); DAT bruto criptografado
Auditoria	trilha imutavel de quem leu/alterou o twin (compliance e disputa)

Risco de privacidade na heranca de historico entre donos e **alto** juridicamente -> mitigacao: politica de dados por camadas (tecnico herdavel vs sensivel redacted) revisada por juridico antes do GA.

6.14 Estimativa de Custo, Dificuldade e Cronograma

ESTIMATIVA bottom-up: esforco de engenharia (custo/hora blended **~R\$ 180/h** **[VALIDAR]** com folha real) + infra incremental. Cambio R\$ 5,40.


Esforco de construcao (one-time):

Bloco	Fase	Horas est.	Custo (R\$)	Custo (US\$)	Dificuldade
Modelo de dados + event sourcing hibrido	MVP	320-480	57,6k-86,4k	10,7k-16,0k	4
Ingest telemetria (Go) + canonizacao	MVP	360-520	64,8k-93,6k	12,0k-17,3k	4
Parser DAT/DJI	MVP-GA	400-700	72,0k-126,0k	13,3k-23,3k	5
TimescaleDB (hypertables, agregados, retencao)	MVP	160-260	28,8k-46,8k	5,3k-8,7k	3
Object storage + midia + CV hook	MVP	140-220	25,2k-39,6k	4,7k-7,3k	2
API do twin (REST + eventos)	MVP	240-360	43,2k-64,8k	8,0k-12,0k	3
Dashboard 2D do twin	MVP	260-400	46,8k-72,0k	8,7k-13,3k	2
Versionamento/viagem no tempo + snapshots	GA	200-320	36,0k-57,6k	6,7k-10,7k	4
Integracao IA/CV/Health Score (contratos)	GA	240-380	43,2k-68,4k	8,0k-12,7k	4
Visao 3D leve (hotspots)	GA	200-340	36,0k-61,2k	6,7k-11,3k	3
Total		~2.520-3.980 h	~R\$ 454k-816k	~US\$ 84k-151k	

Infra incremental (mensal, ESTIMATIVA):

Item	MVP (R\$/mes)	GA (R\$/mes)
TimescaleDB (armazenamento series + compute)	1,5k-4k	8k-18k
S3 + CDN (midia + DAT)	0,8k-2,5k	4k-10k
Ingest compute (Go) + broker (Redis/Kafka)	0,7k-2,5k	4k-9k
Total incremental	~R\$ 3-9k	~R\$ 16-37k

Cronograma (mermaid):



Prioridade: P0 no MVP — o twin e pre-requisito de IA Preditiva, CV e Health Score e e o moat de dados. O parser DAT e o item mais arriscado e deve começar cedo, entregando valor incremental (campos-chave primeiro).

6.15 Riscos e Mitigacao (consolidado)

Risco	Prob.	Impacto	Mitigacao	Prioridade
Parser DAT/DJI incompleto ou quebra em novo firmware	Alta	Alto	Comecar por campos-chave; camada de parser versionada por firmware; fallback via app; validar contra ferramenta oficial DJI	P0
Contadores duplicados (horas/litros) por reenvio	Media	Alto	Idempotencia por hash + <code>(serial,timestamp)</code> no ingest	P0
Vazamento cross-tenant no twin/series/midia	Media	Critico	RLS no banco + testes de isolamento em CI + auditoria	P0
Custo de series temporais estoura	Alta	Alto	Compressao + retencao hot/cold + agregados desde o MVP	P1
Privacidade na revenda (dados do dono anterior)	Media	Alto (juridico)	Politica de heranca por camadas + redaction; revisao juridica pre-GA	P1
Complexidade do event sourcing afoga o time	Media	Medio	Hibrido (nao puro); libs maduras; snapshots; escopo faseado	P2
3D vira "gold plating" e atrasa	Media	Medio	3D so no GA, apos dashboard 2D validado comercialmente	P2

6.16 Conclusao do Capitulo

O Drone Digital Twin e simultaneamente **produto** (prontuario/passaporte que o cliente ve e valoriza) e **infraestrutura de IA** (substrato de features para predicao, CV e Health Score). A arquitetura recomendada — **twin hibrido (snapshot + event sourcing)**, telemetria em **TimescaleDB**, midia em **S3**, ingest **poliglota canonizado** (DAT, MQTT, app, ERP, IA) e API REST+eventos versionada — entrega leitura rapida, historico completo, versionamento temporal e reprocessamento de IA, mantendo custo e complexidade sob controle para um time em estagio inicial. O twin e o **moat de dados** da AeroCortex: cada drone conectado torna a plataforma mais valiosa e mais dificil de substituir. O detalhamento acionavel (tarefas com horas, custo, equipe, dependencias, impacto, dificuldade, risco e wave) segue no objeto estruturado deste capitulo.

Capítulo 7 — IA Preditiva (Manutencao Preditiva)

Escopo: Este capítulo especifica o módulo **IA Preditiva** da AeroCortex (nome de trabalho, a validar): o conjunto de modelos que transforma o substrato de dados do **Drone Digital Twin (Cap. 6)** em **antecipacao acionavel** — prever falhas, estimar vida util restante (RUL), recomendar troca de pecas, projetar custos e tempo de manutencao, quantificar risco de pane e, criticamente, **risco de incendio de baterias LiPo**, detectar falhas recorrentes e disparar campanhas preventivas de frota. Definimos os tipos de predicao, a comparacao de abordagens de modelagem com recomendacao por tipo, a engenharia de features, a estrategia de **cold-start** (poucos dados iniciais), o pipeline **MLOps** completo, as metricas de aceite, o monitoramento de drift e as estimativas de custo, dificuldade, risco, cronograma e prioridade.

Aviso metodologico: Custos sao **ESTIMATIVAS** de trabalho (dimensionamento bottom-up de esforco de engenharia/ciencia de dados a custo/hora blended **~R\$ 200/h** para perfil ML senior [VALIDAR] com folha real, + infra de treino/inferencia a preco de lista). **Cambio de trabalho:** US\$ 1,00 = R\$ 5,40. Este capítulo herda as decisoes dos Cap. 4 (PostgreSQL 16 + TimescaleDB, Kafka/Redis, S3, event-driven) e Cap. 6 (twin hibrido snapshot + event sourcing como fonte de features). Numeros de mercado sao **ESTIMATIVA** e devem ser validados com fonte primaria (dados de campo da propria frota).


7.1 Sumario Executivo do Capitulo

A IA Preditiva e a **camada de valor percebido** da AeroCortex: o Digital Twin *guarda* a memoria do drone; a IA Preditiva *usa* essa memoria para dizer, antes que aconteca, "**o motor 3 do seu Agras T50 vai falhar em ~28 horas de voo; agende agora**" ou "**esta bateria LiPo apresenta divergencia de celula + inchaco termico; retire de operacao — risco de incendio elevado**". Esse e o momento em que a plataforma deixa de ser um sistema de registro e passa a ser um **copiloto de decisao** — e o que sustenta pricing premium e retencao.

Decisao mestra: adotamos uma **arquitetura de portfolio de modelos** (nao um unico modelo mágico), com o algoritmo escolhido **por tipo de predicao**, orquestrado por um **Prediction Service** que consome features do twin e publica alertas de volta para o twin e para o ERP. A recomendacao de topo por familia: **XGBoost/LightGBM** para classificacao de risco de falha e regressao de custo/tempo (melhor custo-beneficio em dados tabulares esparsos, que e a nossa realidade inicial); **analise de sobrevivencia (Weibull + Cox / Random Survival Forest)** para RUL e probabilidade de falha em janela; **Temporal Fusion Transformer (TFT)** e **LSTM** para RUL fino sobre telemetria densa (fase madura); e **deteccao de anomalias (Isolation Forest + autoencoder)** como **primeira linha de defesa** desde o dia 1 — porque nao exige historico rotulado de falhas e cobre o cold-start.

Decisao critica de seguranca: o **risco de incendio de LiPo** e tratado como **subsistema de seguranca funcional**, nao como "mais um modelo". Ele combina **regras fisicas determinísticas** (limiares de temperatura, tensao de celula, divergencia entre celulas, resistencia interna, inchaco) com um classificador ML, sempre com **fail-safe conservador** (na duvida, alerta) e explicabilidade obrigatoria. Falso negativo aqui pode significar incendio de galpao — o vies e deliberadamente para o alarme.

Investimento estimado do modulo: **~R\$ 620 mil - R\$ 1,15 milhao (US\$ 115 mil - US\$ 213 mil)** ao longo de MVP -> GA -> Scale, mais **~R\$ 4-14 mil/mes** de infra incremental (treino + inferencia + feature store). Prioridade **P0** para o subsistema LiPo e a deteccao de anomalias (entregam valor no cold-start); **P1** para RUL fino e campanhas de frota.



7.2 O Que a IA Preditiva Vai Prever

Cada predicao e um **produto de decisao** com um consumidor claro (oficina, operador, gestor de frota, revenda, fabricante) e uma acao associada. Modelar sem a acao e desperdicio.

#	Predicao	Pergunta de negocio	Saida	Consumidor / acao
1	Risco de falha (janela)	"Qual a prob. de falha nos proximos N voos/horas?"	prob. 0-1 por subsistema	Gestor: agenda manutencao antes da pane
2	RUL — Remaining Useful Life	"Quantas horas/voos ate o fim de vida do componente?"	horas/ciclos + intervalo de confianca	Oficina: planeja troca; compras: antecipa peca
3	Troca de pecas	"Qual peca trocar e quando?"	ranking de pecas + janela	Estoque/compras: gira estoque certo
4	Custo de manutencao	"Quanto vai custar a proxima intervencao?"	R\$ estimado + faixa	Gestor/financeiro: orcamento e contrato
5	Tempo de manutencao (downtime)	"Quanto tempo o drone fica parado?"	horas/dias	Operacao: planeja janela de safra
6	Risco de pane em voo	"Este drone esta apto para a proxima missao?"	semaforo apto/atencao/veta	Operador: go/no-go pre-voo
7	Risco de incendio LiPo (CRITICO)	"Esta bateria pode incendiar?"	nivel de risco + causa	Todos: retirar de operacao / isolar
8	Falhas recorrentes	"Ha padrao sistemico neste modelo/lote/firmware?"	cluster + causa provavel	Produto/fabricante: recall/campanha
9	Campanhas preventivas	"Que grupo de drones abordar preventivamente?"	lista + priorizacao	Frota/pos-venda: campanha em massa

Principio de design: predicoes 1, 6 e 7 sao **operacionais em tempo quase-real** (semaforo pre-voo, alerta de bateria) — precisam de inferencia online e baixa latencia. Predicoes 2-5, 8 e 9 sao **taticas/planejamento** (batch diario/semanal) — toleram latencia e priorizam qualidade. Essa separacao define a topologia de deploy (Secao 7.7-7.8).

7.3 Fundamento Critico: LiPo e o Risco de Incendio

A bateria LiPo do Agras (ex.: DB1560/DB1580 na familia T40/T50, ~30.000 mAh, alta densidade) e o **componente mais perigoso e mais caro-por-ciclo** do drone. *Thermal runaway* (fuga termica) e o modo de falha catastrofico: uma vez

iniciado, a reacao e auto-sustentada e praticamente impossivel de conter. Por isso este subsistema recebe tratamento de **seguranca funcional**, com defesa em camadas:

- 1. **Camada deterministica (regras fisicas, sempre ativa, independente de ML):** dispara em limiares consagrados de engenharia de baterias — temperatura absoluta e taxa de subida (dT/dt) fora de faixa; **divergencia de tensao entre celulas** (cell imbalance) acima de limiar; **resistencia interna** crescente; numero de ciclos e profundidade de descarga (DoD) acumulada; **inchaco/swelling** detectado por CV (Cap. 8) em foto de inspecao; tempo/temperatura de armazenamento em estado de carga alto. Estas regras nao dependem de historico de incendios (que — felizmente — sera escasso).
- 2. **Camada ML (classificador de risco):** XGBoost sobre features de degradacao (SOH — State of Health, deriva de capacidade, assinatura de curva de descarga, historico termico) para **antecipar** deterioracao antes de cruzar limiares duros.
- 3. **Camada de politica (fail-safe):** combinacao por **regra do "mais conservador vence"** — se regra OU ML acusarem, o alerta sobe. Vies deliberado para recall/precaucao. Toda decisao vem com **explicacao** (qual feature disparou) para o operador confiar e agir.

Justificativa: em seguranca, o custo de um falso negativo (incendio) e ordens de magnitude maior que o de um falso positivo (retirar uma bateria boa por precaucao). O modelo LiPo e sintonizado para **recall altissimo** em detrimento de precision, e nunca opera "caixa-preta". Regras fisicas garantem um piso de seguranca mesmo com o ML imaturo (cold-start). Meta de aceite: **recall >= 0,97 em eventos de degradacao severa** com FPR gerenciavel; **[VALIDAR]** limiares com dados de fabricante/campo.

7.4 Abordagens de Modelagem — Comparacao e Recomendacao por Tipo

Comparamos as quatro familias exigidas, avaliando o que importa para a nossa realidade (dados tabulares + series temporais, historico inicial escasso, necessidade de explicabilidade e de intervalos de confianca).

Familia	Forca principal	Fraqueza	Dados necessarios	Explicabilidade	Custo compute	Cold-start
Sobrevivencia (Weibull, Cox, Random Survival Forest)	Modela tempo-ate-evento e censura (drone que ainda nao falhou) nativamente; entrega curva de risco e RUL com incerteza	Cox assume proporcionalidade de hazard; menos flexivel a interacoes ricas	Historico de vida + eventos de falha (mesmo censurados)	Alta (hazard ratios)	Baixo	Boa (Weibull com poucos dados + fisica)
Gradient Boosting (XGBoost, LightGBM)	Estado da arte em tabular ; robusto a dados esparsos/faltantes; rapido; SHAP para explicar	Nao modela tempo/censura nativamente; nao captura sequencia longa	Snapshot de features rotulado (falhou/nao em janela)	Alta (SHAP)	Baixo-medio	Media-boa (funciona com centenas de exemplos)
Series temporais NN (LSTM, TFT)	Captura dinamica temporal e sazonalidade; TFT da attention interpretavel + quantis (incerteza)	Faminto por dados ; caro de treinar/servir; overfit fácil no inicio	Muitas series longas e densas rotuladas	Media (TFT) / Baixa (LSTM)	Alto	Ruim (precisa de volume)
Deteccao de anomalias (Isolation Forest, Autoencoder)	Nao supervisionado — nao precisa de rotulo de falha; acha o "estranho"	Detecta anomalia, nao a <i>causa</i> nem o <i>quando</i> ; ajuste de limiar sensivel	So dados de operacao normal	Media	Baixo (IF) / Medio (AE)	Excelente (ideal no dia 1)

Recomendacao por tipo de predicao (a MELHOR opcao para cada caso):

Predicao	Fase MVP (cold-start)	Fase madura (dados abundantes)	Justificativa
Risco de falha (janela)	XGBoost/LightGBM	XGBoost + TFT (ensemble)	Tabular esparso; SHAP explica; barato e rapido
RUL	Weibull + Cox / RSF (+ fisica)	TFT (quantis) + sobrevivencia	Sobrevivencia lida com censura e incerteza; TFT refina com telemetria densa
Troca de pecas	XGBoost (multi-classe) + regras	XGBoost + RUL por componente	Ranking de peca e classificacao; regras cobrem inicio
Custo de manutencao	LightGBM (regressao)	LightGBM + quantis	Tabular; faixas via regressao quantilica
Tempo/downtime	LightGBM (regressao)	LightGBM + histórico OS	Idem custo; features de OS do ERP
Risco de pane em voo	Regras + XGBoost	XGBoost + anomalia online	Semaforo pre-voo precisa ser explicavel e conservador
Risco de incendio LiPo	Regras fisicas + XGBoost (fail-safe)	+ AE de assinatura termica	Seguranca: piso deterministico + ML de antecipacao
Falhas recorrentes	Clustering + regras (Isolation Forest para outliers de lote)	+ analise de sobrevivencia por coorte	Achar padrao por modelo/lote/firmware
Campanhas preventivas	Sobrevivencia por coorte + XGBoost	+ uplift modeling	Priorizar quem tem maior risco x valor
Guarda transversal (dia 1)	Isolation Forest + Autoencoder	AE por subsistema	Cobre tudo sem rotulo — rede de seguranca no cold-start

Sintese da decisao: comecamos **simples, explicavel e barato** (regras + sobrevivencia + gradient boosting + anomalia) e **evoluimos para deep learning temporal (TFT/LSTM) somente quando o volume de dados justificar** — tipicamente apos alguns milhares de series de voo rotuladas por subsistema. Deep learning cedo demais e o erro classico: caro, opaco e pior que XGBoost com pouco dado.

7.5 Engenharia de Features a partir do Digital Twin / Telemetria

As features saem das quatro categorias do twin (Cap. 6): estado/cadastro, eventos de dominio, series temporais (TimescaleDB) e midia (S3 -> via CV, Cap. 8). O feature engineering e onde mora **80% do ganho de acuracia** neste dominio — mais que a escolha de algoritmo.

Grupo de feature	Exemplos	Origem no twin	Tecnica
Uso acumulado	horas de voo, ciclos, litros pulverizados, decolagens, DoD acumulado	series + estado	contadores + normalizacao por modelo
Assinatura de motor/ESC	RPM medio/pico, corrente, temperatura, vibracao (se disponivel), desbalanceo entre motores	series (TimescaleDB)	janelas (media/std/max), FFT de vibracao, razao entre motores
Saude de bateria	SOH, deriva de capacidade, resistencia interna, cell imbalance, dT/dt, ciclos, temp. de storage	series + eventos	features de degradacao + tendencia (slope)
Ambiente/operacao	temperatura ambiente, altitude, carga, perfil de missao, tipo de cultura	series + cadastro + clima externo	agregacao por voo
Historico de manutencao	pecas trocadas, OS anteriores, MTBF do componente, recall/lote	eventos (ERP)	contagem, tempo-desde-ultima-troca
Contexto de frota/lote	firmware, lote de fabricacao, versao de hardware, coorte	cadastro	one-hot / target encoding
Tendencia (a chave do preditivo)	slope, aceleracao e residuo vs baseline saudavel do proprio drone	series	delta features, EWMA, deteccao de mudanca (change point)
Anomalia (feature derivada)	score de Isolation Forest/AE como input de outros modelos	pipeline de anomalia	stacking

Praticas decisivas:


- **Baseline por individuo:** cada drone tem sua "assinatura saudavel"; features de *desvio do proprio baseline* superam limiares absolutos (dois Agras identicos operam diferente por altitude/cultura). Isso e o coracao do preditivo real.
- **Janelas temporais multiplas** (ultimos 1/5/20 voos) para capturar deterioracao lenta e eventos agudos.
- **Feature Store** (offline p/ treino + online p/ inferencia) para garantir **paridade treino-serving** (o bug #1 de MLOps). Recomendacao: **Feast** (open-source) sobre TimescaleDB/Redis — evita reinventar e integra ao stack do Cap. 4.
- **Point-in-time correctness:** treinar apenas com o que se sabia *naquele instante* (o event sourcing do Cap. 6 habilita isso nativamente — "como estava o drone na data X").

7.6 O Problema do Cold-Start — Como Prever com Poucos Dados

No lancamento nao existe historico de falhas suficiente para treino supervisionado robusto. Ignorar isso condena o produto a "so funcionar daqui a 2 anos". Atacamos com **cinco estrategias combinadas**, do menos ao mais dependente de dados proprios:

Estrategia	Como funciona	Quando aplica	Custo/dificuldade	Limitacao
1. Modelos fisicos / regras de engenharia	Curvas de degradacao conhecidas (Weibull de fabricante, limiares LiPo, MTBF de datasheet, degradacao Arrhenius de bateria)	Dia 1	Baixo / 2	Aproximado; nao personaliza
2. Deteccao de anomalia nao supervisionada	IF/AE aprendem "normal" e sinalizam desvio — sem rotulo de falha	Dia 1	Baixo / 3	Detecta, nao diagnostica
3. Priors bayesianos + Weibull	Comeca com prior de fabricante e atualiza conforme chegam dados reais	Semanas 1+	Medio / 3	Requer curadoria estatistica
4. Transfer learning / modelos por coorte	Treina no agregado do modelo (todos os T50) e especializa por drone; reusa embeddings entre modelos similares	Meses 2-6	Medio / 4	Risco de vies de coorte
5. Dados sinteticos e simulacao	Gera trajetorias de falha via twin fisico + injecao de falha; SMOTE/geradores para classes raras (incendio LiPo)	Meses 1-6	Alto / 4	Realismo precisa validacao


Recomendacao (a MELHOR combinacao): iniciar com **fisica + regras + anomalia** (estrategias 1-2) entregando valor imediato e seguro; sobrepor **priors bayesianos/Weibull** (3) que melhoram automaticamente; e usar **dados sinteticos** (5) especificamente para as **classes raras e criticas** — incendio LiPo, falha catastrofica de motor — onde nunca teremos exemplos suficientes e nem queremos ter. O **transfer por coorte** (4) entra quando houver frota conectada suficiente. Um **human-in-the-loop** (tecnico confirma/rejeita cada alerta) gera rotulos de alta qualidade que aceleram a saida do cold-start — o feedback vira dado de treino (active learning).



7.7 Arquitetura Tecnica dos Modelos

- **Feature Store:** Feast (offline em TimescaleDB/S3 Parquet; online em Redis) para paridade treino-serving.
- **Treino:** Python (scikit-learn, XGBoost/LightGBM, lifelines/scikit-survival para sobrevivencia, PyTorch para TFT/AE). Orquestracao de pipelines com **Airflow** ou **Prefect**.
- **Rastreamento e registro:** **MLflow** para experiment tracking, model registry e versionamento (modelo + dados + metrica ligados a cada versao do twin).
- **Serving:** dois caminhos — (a) **batch** (Airflow diario/semanal) para RUL, custo, campanhas; (b) **online** (API de baixa latencia via FastAPI/BentoML) para semaforo pre-voo e LiPo. Modelos leves (XGBoost) servem em CPU; TFT/AE em CPU tambem no inicio (batch), GPU so se necessario.
- **Edge/TinyML (fase Scale):** para alerta de LiPo/pane **em tempo de voo** no proprio equipamento/gateway, versoes quantizadas (ONNX/TFLite) — decidido no Cap. de Edge AI; aqui fica o gancho.
- **Prediction Service:** microservico que orquestra scoring, aplica **politica de alerta** (limiares, fail-safe LiPo, deduplicacao), grava resultado no twin (Cap. 6) e emite eventos para o ERP (Cap. 5).

7.8 Pipeline MLOps — Coleta -> Features -> Treino -> Validacao -> Deploy -> Drift



Boas praticas por etapa (justificadas):

- Coleta:** ingestao ja resolvida pelo twin (Cap. 6). Aqui garantimos **rotulos** — eventos de falha/OS do ERP + confirmacoes HITL. Rotulo e o ativo mais escasso; capturar bem e prioridade P0.
- Features:** versionadas no Feature Store, com **point-in-time correctness** para evitar *data leakage* (o erro que faz o modelo parecer otimo em teste e falhar em producao).
- Treino:** reproduzivel e rastreado (MLflow); cada modelo carimba a versao de dados e features usadas.
- Validacao — a etapa mais critica:** **backtest temporal** (treina no passado, testa no futuro — nunca k-fold aleatorio em series temporais, que vaza informacao); avaliar por **coorte** (modelo, lote, firmware, regioao) para nao esconder falha em subgrupo; **gate de promocao** com metricas minimas por tipo de predicao (Secao 7.9); revisao de seguranca obrigatoria para o modelo LiPo.
- Deploy progressivo:** **shadow** (modelo roda sem agir, so compara) -> **canary** (fracao da frota) -> **produção**; rollback em 1 clique via registry.
- Monitoramento de drift:** ver Secao 7.10.

7.9 Metricas de Avaliacao e Criterios de Aceite

Metrica errada leva a modelo inutil. Escolhemos **por tipo de predicao** e sempre alinhada a **acao e a assimetria de custo** (falso negativo em LiPo != falso positivo).

Predicao	Metrica primaria	Metrica secundaria	Alvo de aceite (ESTIMATIVA — [VALIDAR] com dados reais)
Risco de falha (classificacao)	Recall (nao perder falha) + Precision	ROC-AUC, PR-AUC	Recall >= 0,85; Precision >= 0,60; PR-AUC >= 0,70
RUL (regressao/sobrevivencia)	MAE de RUL (horas/ciclos)	RMSE, C-index (concordancia), cobertura do IC	MAE <= 15% da vida do componente; C-index >= 0,75
Alerta antecipado (lead time)	PH — Prognostic Horizon (quanto antes avisou)	taxa de alarme util	Lead time mediano >= 1 janela de manutencao antes da falha
Custo de manutencao	MAPE	quantil de cobertura	MAPE <= 20%
Tempo/downtime	MAE (horas)	MAPE	MAE <= 20%
Risco de pane pre-voo	Recall (conservador)	especificidade	Recall >= 0,90; FPR gerenciavel
Risco de incendio LiPo	Recall / Sensibilidade (fail-safe)	FPR, tempo de antecipacao	Recall >= 0,97 ; explicabilidade 100%
Anomalia	Precision@k (top alertas uteis)	taxa de deteccao	Precision@k >= 0,50 (evitar fadiga de alarme)
Campanhas	Uplift / lift	ROI da campanha	lift >= 2x sobre baseline aleatorio

Metricas de negocio (o que a diretoria olha): reducao de **panes nao planejadas**, aumento de **disponibilidade da frota (uptime na safra)**, reducao de **custo de manutencao corretiva vs preditiva**, **zero incidentes de incendio** nao

antecipados, e **taxa de acao sobre alerta** (alertas que geram OS — mede utilidade real). Alarme que ninguem age e ruido; monitoramos **fadiga de alarme** ativamente.

7.10 Monitoramento de Drift e Retreino

Modelo preditivo **apodrece**: novos firmwares, novos modelos de drone, novas culturas e sazonalidade mudam a distribuicao. Sem monitoramento, a acuracia cai silenciosamente.

Tipo de drift	O que muda	Como detectar	Acao
Data drift	distribuicao das features de entrada	PSI, KS-test, Population Stability Index por feature	investigar; possivel retraining
Concept drift	relacao feature->falha muda (novo firmware)	queda de metrica em janela movel	retraining + revisao de features
Label drift	mix de falhas muda	monitor de proporcao de classes	rebalancear
Degradacao de performance	metrica cai vs baseline	backtest continuo com rotulos que chegam	gate de alarme + retraining

Estrategia: ferramentas tipo **Evidently AI** (open-source) ou similar para dashboards de drift; **retraining agendado** (ex.: mensal para modelos taticos) + **retraining disparado por trigger** (drift ou queda de metrica); toda promocao passa pelo mesmo gate da Secao 7.8. O **modelo LiPo** tem monitoramento reforcado e revisao humana antes de qualquer atualizacao (mudanca em modelo de seguranca e evento controlado).

7.11 Explicabilidade, Confianca e Seguranca

Tecnico e operador so agem sobre alerta que **entendem e confiam**. Portanto:

- **SHAP** em todos os modelos de gradient boosting -> "o alerta subiu por: cell imbalance 0,3V + 480 ciclos + dT/dt alto".
- **Attention interpretavel** no TFT quando entrar.
- **Nunca caixa-preta em decisao de seguranca** (LiPo, pane pre-voo).
- **Incerteza calibrada:** intervalos de confianca em RUL; abstencao ("nao sei — dados insuficientes") em vez de palpite ruim.
- **Auditoria:** toda predicao e gravada no twin (event sourcing) com versao de modelo/features — reprocessavel e defensavel juridicamente (importante para garantia, seguro e eventual recall).

7.12 Estimativa de Custo, Dificuldade e Cronograma

ESTIMATIVA bottom-up: esforco de ciencia de dados/ML a custo/hora blended **~R\$ 200/h** [VALIDAR] + infra de treino/inferencia/feature store. Cambio R\$ 5,40.

Esforco de construcao (one-time):


Bloco	Fase	Horas est.	Custo (R\$)	Custo (US\$)	Dificuldade
Feature Store (Feast) + pipeline de features	MVP	360-520	72,0k-104,0k	13,3k-19,3k	4
Deteccao de anomalia (IF + AE) — guarda dia 1	MVP	200-320	40,0k-64,0k	7,4k-11,9k	3
Subsistema LiPo fire-risk (regras + ML + fail-safe)	MVP	320-500	64,0k-100,0k	11,9k-18,5k	5
Risco de falha + pane pre-voo (XGBoost)	MVP	280-420	56,0k-84,0k	10,4k-15,6k	3
RUL sobrevivencia (Weibull/Cox/RSF) + priors	MVP-GA	320-480	64,0k-96,0k	11,9k-17,8k	4
Custo & tempo de manutencao (regressao GB)	GA	180-280	36,0k-56,0k	6,7k-10,4k	3
Cold-start: dados sinteticos + transfer/coorte	MVP-GA	300-460	60,0k-92,0k	11,1k-17,0k	4
Pipeline MLOps (MLflow + Airflow + deploy)	MVP-GA	360-540	72,0k-108,0k	13,3k-20,0k	4
Monitoramento de drift (Evidently) + retreino	GA	200-320	40,0k-64,0k	7,4k-11,9k	3
Prediction Service + politica de alerta + HITL	GA	260-400	52,0k-80,0k	9,6k-14,8k	4
Falhas recorrentes + campanhas (coorte/uplift)	Scale	220-360	44,0k-72,0k	8,1k-13,3k	4
RUL fino temporal (TFT/LSTM)	Scale	320-520	64,0k-104,0k	11,9k-19,3k	5
Total		~3.520-5.620 h	~R\$ 704k-1,03M	~US\$ 130k-192k	

Faixa consolidada do modulo (com contingencia e refino de features): **~R\$ 620k-1,15M / US\$ 115k-213k.**

Infra incremental (mensal, ESTIMATIVA):

Item	MVP (R\$/mes)	GA (R\$/mes)	Scale (R\$/mes)
Compute de treino (CPU; GPU spot sob demanda)	0,8k-2,5k	3k-8k	8k-20k
Inferencia online (Prediction Service)	0,6k-2k	2k-6k	6k-15k
Feature Store (Redis online + storage offline)	0,7k-2k	3k-7k	7k-16k
MLflow/Airflow/monitoramento	0,4k-1,5k	1,5k-4k	4k-9k
Total incremental	~R\$ 2,5-8k	~R\$ 9,5-25k	~R\$ 25-60k

Cronograma (mermaid):



Prioridade: P0 — LiPo fire-risk, deteccao de anomalia e feature store (valor e seguranca no cold-start); **P1** — RUL, custo/tempo, MLOps completo; **P2** — TFT temporal e uplift de campanhas (dependem de volume de dados).

7.13 Riscos e Mitigacao (consolidado)

Risco	Prob.	Impacto	Mitigacao	Prioridade
Falso negativo em incendio LiPo	Baixa	Critico	Camada fisica deterministica + fail-safe conservador + recall alvo $\geq 0,97$ + revisao humana de mudancas de modelo	P0
Cold-start: sem dados, modelo inutil no lancamento	Alta	Alto	Fisica + regras + anomalia dia 1; priors Weibull; sinteticos p/ classes raras; HITL gera rotulos	P0
Data leakage / backtest otimista demais	Media	Alto	Split temporal, point-in-time correctness, feature store; sem k-fold aleatorio em series	P0
Paridade treino-serving quebrada	Media	Alto	Feature Store unico (offline+online); testes de paridade em CI	P1
Model drift silencioso (novo firmware/safra)	Alta	Alto	Monitoramento PSI/KS + backtest continuo + retreino por trigger	P1
Fadiga de alarme (muitos falsos positivos)	Media	Medio	Precision@k, deduplicacao, calibracao de limiar, medir taxa de acao sobre alerta	P1
Deep learning cedo demais (caro e pior que XGBoost)	Media	Medio	So TFT/LSTM apos volume validado; comecar tabular/sobrevivencia	P2
Desconfianca do tecnico (nao age no alerta)	Media	Alto	SHAP/explicabilidade obrigatoria; HITL; medir adocao	P1
Vies por coorte (modelo bom no T50, ruim no T20)	Media	Medio	Avaliacao por coorte no gate; modelos especializados	P2

7.14 Conclusao do Capitulo

A IA Preditiva é o que converte o **moat de dados** do Digital Twin em **decisao antecipada e receita recorrente**. A recomendacao central é um **portfolio de modelos escolhidos por tipo de predicao** — sobrevivencia (Weibull/Cox) para RUL, gradient boosting (XGBoost/LightGBM) para risco/custo/tempo, deteccao de anomalia (IF/AE) como rede de seguranca no cold-start, e deep learning temporal (TFT/LSTM) reservado para a fase de dados abundantes — evitando o erro caro de aplicar redes neurais complexas antes de ter volume. O **subsistema de risco de incendio LiPo** é tratado como **seguranca funcional**, com piso fisico deterministico, ML de antecipacao e fail-safe conservador — porque o custo de um falso negativo é um galpao em chamas. O **cold-start** é vencido com fisica + regras + anomalia no dia 1, priors bayesianos que melhoram sozinhos, dados sinteticos para classes raras e **human-in-the-loop** que transforma cada alerta confirmado em dado de treino. Tudo assentado em um **pipeline MLOps** com feature store (paridade treino-serving), backtest temporal (sem leakage), deploy progressivo (shadow -> canary -> prod) e monitoramento de drift. O detalhamento acionavel (tarefas com horas, custo, equipe, dependencias, impacto, dificuldade, risco e wave) segue no objeto estruturado deste capitulo.

Capítulo 8 — Computer Vision para Inspecao

Escopo: Este capítulo especifica o **modulo de Computer Vision (CV) para inspecao** da AeroCortex (nome de trabalho, a validar): a IA de visao que recebe **fotos e frames de video** enviados pelo tecnico (via app mobile ou upload web) e **reconhece automaticamente** defeitos em drones agricolas — rachaduras, trincas, oxidacao, parafusos frouxos, cabos danificados, desgaste de helices, vazamentos, residuos quimicos, corrosao, umidade, superaquecimento, pecas quebradas, componentes ausentes, deformacoes, danos estruturais, amassados, desgaste de conectores, componentes queimados, defeitos em placas electronicas (PCB), soldas frias, oxidacao em PCB, e o estado de sensores, antenas, bombas, mangueiras e reservatorios. A partir da deteccao, a IA **gera laudo, explica o problema, calcula gravidade, informa risco, estima custo e tempo, sugere reparo, lista pecas e gera orcamento automatico** ligado ao ERP/catalogo (Cap. 5) e ao Digital Twin (Cap. 6). Definimos o pipeline completo (pre-processamento -> deteccao -> segmentacao -> severidade -> OCR), a comparacao de arquiteturas, a estrategia de dataset/rotulagem, active learning, human-in-the-loop, augmentation, classes raras, metricas e MLOps de visao.

Aviso metodologico: Custos sao **ESTIMATIVAS** de trabalho (dimensionamento bottom-up de esforco de engenharia + GPU/nuvem x precos de lista, com desconto de committed-use). **Cambio de trabalho:** US\$ 1,00 = R\$ 5,40. Todo valor deve ser validado com **[VALIDAR]** cotacao real (AWS/GCP Pricing, folha de custo de time, cotacao de rotulagem terceirizada) antes de decisao de orcamento. Este capítulo herda decisoes dos Caps. 4 (S3, pgvector, event-driven), 5 (catalogo de pecas/ERP) e 6 (Digital Twin como destino do laudo).


8.1 Sumario Executivo do Capitulo

O modulo de CV e o **diferencial sensorial** da AeroCortex: transforma o celular do tecnico em um **inspetor especialista assistido por IA**, padronizando um processo hoje 100% subjetivo (o olho e a experiencia do tecnico). O ganho de negocio e triplo — **velocidade** (laudo em segundos, nao horas), **consistencia** (mesmo criterio de severidade para toda a rede) e **monetizacao** (orcamento automatico ligado ao catalogo aumenta conversao de reparo e venda de pecas).

Decisao mestra: adotamos um **pipeline multi-estagio hibrido** — nao um unico modelo "faz-tudo". Cada estagio usa a arquitetura de melhor custo-beneficio: **YOLOv11** para deteccao (com **YOLOv11-seg** cobrindo tambem a segmentacao de instancia no MVP), **RT-DETR** como upgrade de precisao no GA, **SAM 2** para rotulagem assistida e mascaras finas de defeitos difusos (corrosao, umidade, residuo), **ViT/ConvNeXt** para classificacao de severidade, **PaddleOCR/TrOCR** para leitura de seriais, **modelos de deteccao de anomalia (PatchCore/EfficientAD)** para classes raras e defeitos nunca vistos, e um **VLM (Claude com visao)** para redigir o laudo em linguagem natural e fazer deteccao open-vocabulary de cauda longa. A orquestracao gera o laudo estruturado que abastece Twin, ERP e o orcamento.

Custo de construcao estimado: ~R\$ 620 mil - R\$ 1,15 mi (US\$ 115 mil - US\$ 213 mil) ao longo de MVP+GA, mais ~R\$ 4-14 mil/mes de infra de inferencia (GPU) escalavel. **Prioridade P0** para o subconjunto visual de maior valor (helices, estrutura, bomba/mangueira/reservatorio, conectores) e **P1** para PCB/microdefeitos e OCR robusto. Fator critico de sucesso: **dados rotulados** — a arquitetura e commodity, o dataset proprietario e o moat.

8.2 Papel do CV na Plataforma e Fluxo de Valor



O CV nao vive isolado: ele **le** do catalogo de pecas (para mapear defeito -> peca), **escreve** no Twin (evento "laudo emitido") e **dispara** o orcamento no ERP. O loop de correcao do tecnico (HITL) realimenta o dataset — cada inspecao melhora o modelo.

8.3 Taxonomia de Defeitos — O Que a IA Reconhece


Organizamos os ~25 defeitos-alvo em **grupos por tecnica de deteccao dominante**, porque isso define qual modelo resolve cada um e o custo de rotulagem.

Grupo	Defeitos	Tecnica dominante	Dificuldade CV	Dado necessario
Estrutural macro	rachaduras, trincas, quebras, deformacoes, amassados, danos estruturais, componentes ausentes	Deteccao + segmentacao (bbox/mask)	2-3	Fotos rotuladas por regioao
Superficie/quimico	oxidacao, corrosao, residuo quimico, umidade, vazamento	Segmentacao semantica (area difusa) + cor/textura	3-4	Mascaras + variacao de iluminacao
Helices/desgaste	desgaste de helice, laminas lascadas, empenamento	Deteccao + classificacao de severidade	2-3	Fotos padronizadas da helice
Fixacao/conexao	parafusos frouxos/faltando, cabos danificados, desgaste de conectores	Deteccao fina (objeto pequeno) + estado	4	Close-ups anotados
Termico	superaquecimento, componentes queimados	Classificacao (marca de queima) + termografia opcional	3	RGB + (opcional) camera termica
PCB/eletronica	soldas frias, oxidacao em PCB, trilhas queimadas, capacitor estufado	Deteccao micro + anomalia	5	Macro-fotos de alta resolucao
Hidraulico/fluidico	bomba, mangueiras (rachadura/ressecamento), reservatorio (trinca/vazamento)	Deteccao + segmentacao de vazamento	3	Fotos + video de operacao
Sensores/antenas	dano, sujeira, obstrucao, desalinhamento	Deteccao + presenca/ausencia	3	Fotos por posicao conhecida

Decisao: priorizar no MVP os grupos **Estrutural, Helices, Hidraulico e Fixacao** (alto volume de inspecao, defeitos visiveis, ROI rapido) e deixar **PCB (dificuldade 5)** e **termografia** para GA/Scale — exigem hardware/macro e dataset mais caro.

8.4 Pipeline de Visao — Arquitetura End-to-End

O pipeline e **modular e assincrono**: a foto entra por fila (Cap. 4), passa por estagios independentes e versionaveis. Cada estagio pode rodar em modelo diferente e ser atualizado sem quebrar os demais.



Por que multi-estagio e nao um modelo unico? Um detector unico "end-to-end" seria mais simples, mas: (a) severidade exige raciocinio de area/textura que bbox nao captura; (b) OCR e problema separado; (c) classes raras precisam de anomalia nao-supervisionada; (d) modularidade permite atualizar so a peca fraca. O custo e latencia maior (~0,8-2,5 s/imagem em GPU) — aceitavel para inspecao assincrona.

8.5 Pre-processamento e Captura Guiada

A maior fonte de erro em CV de campo e a qualidade da foto (borrao, sombra, angulo, distancia). Investir em captura guiada tem ROI maior que trocar de modelo.

- **QA on-device (edge):** detector de blur (variancia de Laplaciano), checagem de luminancia e de enquadramento — o app so aceita a foto se passar; senao instrui "aproxime", "mais luz", "estabilize".
- **Overlay de guia:** silhueta/mascara na tela por tipo de peca (ex.: contorno da helice, do reservatorio) — padroniza angulo e escala, o que reduz drasticamente o esforco de treino.
- **Pre-processamento cloud:** correcao de orientacao via EXIF, resize para o input do modelo (ex.: 640/1024 px), denoise leve, normalizacao de cor/brilho (importante para oxidacao/umidade), e **tiling** para imagens de PCB de alta resolucao (recorta em blocos para nao perder microdefeito).

- **Escala fisica:** quando ha marcador/dimensao conhecida (ou EXIF de distancia), converter pixels em mm para medir tamanho real da rachadura — insumo direto da severidade.

8.6 Estagio de Deteccao — Comparacao de Arquiteturas

Deteccao localiza e classifica os defeitos. Comparamos as principais familias considerando **precisao, velocidade, facilidade de treino, licenca e maturidade de tooling**.

Arquitetura	mAP tipico*	Velocidade (GPU)	Objetos pequenos	Licenca	Tooling/Comunidade	Melhor uso
YOLOv8	Alta	Muito rapida	Boa	AGPL-3.0 / comercial paga	Excelente (Ultralytics)	Baseline maduro
YOLOv11	Alta+	Muito rapida	Boa+	AGPL-3.0 / comercial paga	Excelente	Escolha MVP
RT-DETR	Alta++	Rapida	Muito boa	Apache-2.0 (impl. varia)	Boa e crescente	Upgrade precisao GA
RF-DETR	Alta++	Rapida	Muito boa	Apache-2.0	Boa (Roboflow)	Alternativa DETR aberta
Faster R-CNN	Media-Alta	Lenta	Boa	BSD/Apache	Madura (Detectron2)	Referencia academica
Grounding DINO	Open-vocab	Lenta	Media	Apache-2.0	Boa	Zero-shot / cauda longa

*mAP "tipico" e qualitativo/comparativo — o mAP real depende do **nosso** dataset e sera medido (secao 8.14). Nao ha numero de mercado confiavel para o dominio "drone agricola". **[VALIDAR]** com benchmark interno.

Decisao e justificativa:

- **MVP -> YOLOv11 (via Ultralytics), variante -seg**. Motivos: melhor razao precisao/velocidade, tooling de treino/export/deploy sem igual, roda em GPU barata e ate em edge, e a versao -seg **entrega deteccao + segmentacao no mesmo modelo**, economizando um estagio. Ponto de atencao: **licenca AGPL-3.0** — como a AeroCortex e SaaS, AGPL pode obrigar disponibilizar codigo; por isso orcamos a **licenca comercial Ultralytics** (custo previsivel) e mantemos RT-DETR/RF-DETR (Apache-2.0) como plano B sem amarra de licenca. **[VALIDAR]** com juridico.
- **GA -> RT-DETR** onde precisao marginal justificar (ex.: rachadura fina em estrutura critica): transformers de deteccao lidam melhor com contexto e reduzem falsos positivos, ao custo de treino mais caro.
- **Cauda longa -> Grounding DINO / VLM open-vocabulary:** para defeitos raros sem dado suficiente, deteccao por texto ("localize corrosao no conector") complementa ate acumularmos labels.

8.7 Estagio de Segmentacao

Segmentacao delimita a **area** do defeito (nao so a caixa), essencial para **medir extensao** (ex.: % da helice desgastada, area de corrosao) — insumo direto de severidade e custo.

Abordagem	Tipo	Precisao de borda	Custo treino	Uso na AeroCortex
YOLOv11-seg	Instancia (supervis.)	Boa	Baixo	MVP — mascara junto da deteccao
Mask R-CNN (Detectron2)	Instancia	Muito boa	Alto	Fallback de alta fidelidade
SAM 2 (Meta)	Promptable/zero-shot	Excelente	Zero (pre-treinado)	Rotulagem assistida + defeitos difusos
SegFormer/DeepLabv3+	Semantica	Muito boa	Medio	Areas difusas: corrosao, umidade, residuo

Decisao: YOLOv11-seg para mascaras de instancia no MVP (unificado com deteccao). **SAM 2** entra em dois papeis de altissimo valor: (1) **acelera a rotulagem** — o rotulador clica, o SAM gera a mascara (reducao estimada de **40-70%** no tempo de anotacao **[VALIDAR]**); (2) segmenta **areas difusas** (corrosao/umidade/vazamento) onde bbox nao serve. Para essas areas continuas, avaliar **SegFormer** (semantica) no GA.

8.8 Estagio de Classificacao de Severidade

Depois de localizar/segmentar, classificamos a **gravidade** em **leve** | **moderado** | **critico** (e um score continuo 0-100). Isso e o que converte "achei uma trinca" em "risco de falha em voo".

Modelo	Acuracia relativa	Custo inferencia	Dado necessario	Recomendacao
CNN (EfficientNet-B0/ConvNeXt-Tiny)	Alta	Baixo	Medio	MVP — leve, roda barato
ViT (Vision Transformer)	Alta+	Medio-alto	Alto (precisa mais dado)	GA, com dataset maduro
DINOv2 (features) + head linear	Alta	Baixo (features prontas)	Baixo (few-shot)	Classes raras / arranque frio

Decisao: ConvNeXt-Tiny / EfficientNet no MVP (robusto com pouco dado, barato). **DINOv2 como extrator de features** e a jogada mais inteligente para o inicio: embeddings pre-treinados de altissima qualidade permitem um classificador leve com **poucas amostras por classe** — ideal enquanto o dataset e pequeno. **ViT completo** no GA, quando houver volume. A severidade nao e so o modelo: combinamos a **saida do CNN** com **regras deterministicas** (tamanho medido da trinca em mm, % de area corroida, localizacao em componente critico vindo do Twin) num **score hibrido** auditavel — indispensavel para seguranca e para explicar o laudo.

8.9 Estagio de OCR de Seriais

Ler o **serial/etiqueta** casa a foto com o **Digital Twin correto** automaticamente (sem digitacao) e comprova procedencia da peca.

Engine	Precisao	Idioma/alfanumerico	Licenca	Recomendacao
PaddleOCR	Muito boa	Excelente (alfanumerico)	Apache-2.0	Escolha — robusto e livre
TrOCR (transformer)	Muito boa	Boa (texto denso)	MIT	Casos dificeis/manuscrito
EasyOCR	Boa	Boa	Apache-2.0	Prototipo rapido
Tesseract	Media	Media	Apache-2.0	Fallback offline
VLM (visao)	Boa+ (contexto)	Excelente	API paga	Etiquetas danificadas/anguladas


Decisao: PaddleOCR como padrao (livre, forte em alfanumerico de etiqueta), com **fallback para VLM** quando a etiqueta esta danificada/oxidada/angulada — o VLM le com contexto ("serial do modelo T50 tem formato X"). Pipeline: deteccao localiza a etiqueta -> recorte -> OCR -> validacao por regex/checksum do formato DJI -> match no Twin.

8.10 Do Defeito ao Laudo e Orcamento Automatico

Aqui o CV vira **dinheiro**. O orquestrador funde as saidas dos estagios num **laudo estruturado (JSON)** e um **VLM** o transforma em texto tecnico legivel + recomendacao. O laudo dispara o orcamento no ERP.

Anatomia do laudo (JSON -> ERP + Twin):

Campo	Origem	Exemplo
defeito	Deteccao/classificacao	"trinca em braco do motor 3"
localizacao	Deteccao + guia de captura	"braco M3, face superior"
severidade + score	Severidade hibrida	"critico" / 88
extensao_medida	Segmentacao + escala	"42 mm"
risco	Regras + Twin (horas/criticidade)	"risco de falha estrutural em voo"
causa_provavel	VLM + base de conhecimento	"fadiga por vibracao / impacto"
peças_sugeridas[]	Mapa defeito->SKU (catalogo Cap.5)	["braco M3", "parafusos"]
custo_estimado	Catalogo + tabela de M.O.	"R\$ 1.240 (peca) + R\$ 380 (M.O.)"
tempo_estimado	Tabela de tempo por reparo	"2,5 h"
reparo_sugerido	Base de procedimentos	"substituir braco, torquear 3,2 Nm"
confianca	Score dos modelos	0,91
evidencia	Imagem + heatmap/mask	link S3



Decisao: o **VLM (Claude com visao)** e usado para **redigir/explicar**, **nao para decidir severidade critica sozinho**. A severidade critica passa pelo score hibrido + regras (auditavel) e por **confirmacao humana obrigatoria acima de um limiar de risco** — questao de seguranca e responsabilidade civil. Confianca baixa -> laudo entra como "sugestao" para revisao, nunca como orcamento auto-aprovado. Todo orcamento gerado registra a versao do modelo e a evidencia (rastreabilidade).

8.11 Estrategia de Dataset e Rotulagem

O dataset e o moat. Nenhum dataset publico cobre "drone DJI Agras com corrosao/trinca" — teremos que construi-lo. Estrategia em camadas:

- Bootstrap (frio):** coleta interna de fotos em oficinas parceiras + fotos historicas + defeitos induzidos (fotografar pecas danificadas descartadas) + geracao sintetica leve. Meta MVP: **~3.000-8.000 imagens rotuladas [VALIDAR]** cobrindo os grupos prioritarios.
- Crescimento (producao):** cada inspecao real vira dado candidato (com consentimento/LGPD, Cap. de seguranca). O HITL do tecnico gera labels "de graca".


3. **Escala:** 50k+ imagens, curadas por active learning.

Estrategia de rotulagem	Custo	Qualidade	Velocidade	Uso
Time interno especialista	Alto	Muito alta	Baixa	Gold set / classes criticas
BPO/terceirizado (com guia)	Medio	Media-alta	Alta	Volume geral
Rotulagem assistida por SAM 2	Baixo	Alta	Muito alta	Padrao (mascaras)
Auto-label + revisao (modelo atual)	Muito baixo	Media	Muito alta	Pos-MVP (active learning)

Decisao: rotulagem assistida por SAM 2 + revisao por especialista de manutencao de drone, com um **gold set** pequeno (500-1.000 imagens) rotulado em dupla-cega pelo time interno para servir de referencia de qualidade e teste. Ferramenta: **CVOLTs open-source (ex.: CVAT/Label Studio)** self-hosted (dado sensivel, LGPD). Guia de anotacao versionado e treinamento dos rotuladores sao mandatorios — inconsistencia de label e a causa #1 de modelo ruim.

8.12 Active Learning e Human-in-the-Loop (HITL)

- HITL:** todo laudo mostra ao tecnico a deteccao; ele **confirma/corrige** (arrasta bbox, muda classe/severidade). A correcao (a) melhora o laudo daquele cliente na hora e (b) vira label de altissimo valor.
- Active learning:** em vez de rotular tudo, priorizamos rotular o que o modelo mais erra/tem incerteza:
 - Uncertainty sampling** (baixa confianca), **disagreement** (modelos discordam), **diversity** (embeddings distantes via DINOv2), e **flags de anomalia** (secao 8.13).
- Loop:** producao -> flag de incerteza/correcao HITL -> fila de rotulagem -> re-treino periodico -> A/B do novo modelo -> promocao. Estimativa: reduz custo de rotulagem para o mesmo ganho de mAP em **~50-70% [VALIDAR]** vs rotular aleatorio.



8.13 Aumento de Dados e Classes Raras

Data augmentation (barato, alto impacto para poucos dados):

- Geometrico:** flip, rotacao, escala, crop, perspectiva (simula angulos do tecnico).
- Fotometrico:** brilho, contraste, matiz, ruido, blur, sombra sintetica, simulacao de sujeira/poeira/pulverizacao (dominio agricola!).
- Composicao:** **Mosaic/MixUp/CutMix/Copy-Paste** — cola defeitos raros (corrosao, componente queimado) em fundos variados: multiplica exemplos de classes raras sem novas fotos.
- Sintetico:** renderizacao 3D (Blender) de pecas com defeitos parametrizados e **modelos generativos (difusao) para inpainting** de defeitos em pecas boas — util para PCB e defeitos perigosos de coletar. Usar com cautela (gap de dominio) e sempre validar em dado real.

Classes raras / cauda longa (o problema mais dificil — muitos defeitos sao raros mas criticos):

Tecnica	Como ajuda	Prioridade
Deteccao de anomalia nao-supervisionada (PatchCore, PaDiM, EfficientAD)	Treina so com pecas boas ; flag do que "foge do normal" mesmo sem nunca ter visto o defeito	Alta — rede de segurancia para o desconhecido
Few-shot com DINOv2	Classifica com poucas amostras via features fortes	Alta
Copy-Paste augmentation	Multiplifica raras artificialmente	Alta
Loss ponderada / focal loss	Corrige desbalanceamento de classe	Media
Open-vocabulary (Grounding DINO/VLM)	Detecta por texto sem treino	Media
Oversampling + coleta dirigida	Prioriza coletar as raras	Media

Decisao: combinar **PatchCore/EfficientAD (anomalia) como camada de segurancia** — garante que um defeito nunca-visto ainda seja **sinalizado para revisao humana** ("algo esta estranho aqui"), evitando falso negativo perigoso — com **Copy-Paste + DINOv2 few-shot** para acelerar as classes raras rumo a supervisao plena.

8.14 Metricas de Avaliacao


Medir bem e o que separa demo de produto. Metricas por estagio, com **alvos por fase** (a validar contra o dataset real).

Metrica	Estagio	O que mede	Alvo MVP	Alvo GA
mAP@0.5 / mAP@0.5:0.95	Deteccao	Precisao media de localizacao+classe	mAP@0.5 >= 0,70	>= 0,85
IoU / Dice	Segmentacao	Sobreposicao mascara vs verdade	IoU >= 0,65	>= 0,80
F1 / Precision / Recall	Classificacao/severidade	Equilibrio erro	F1 >= 0,80	>= 0,90
Matriz de confusao	Todos	Onde confunde (ex.: oxidacao x residuo)	Analizada por classe	idem
Recall de defeito critico	Severidade	Falso negativo critico (o pior erro)	>= 0,95	>= 0,98
CER (Character Error Rate)	OCR serial	Erro de leitura de serial	<= 5%	<= 2%
Latencia p95 / imagem	Pipeline	Experiencia	<= 3,0 s	<= 1,5 s
AUROC	Anomalia	Separacao normal x anomalo	>= 0,90	>= 0,95

Principio de segurancia: para defeito critico, **recall > precisao** — preferimos um falso alarme (revisao humana descarta) a deixar passar uma trinca estrutural. Otimizamos o limiar de decisao por classe conforme o **custo do erro**, nao por acuracia global. Reportamos **por classe** (nao so agregado) para nao esconder falha em classe rara critica. Todo modelo tem um **gold set congelado** de teste que nunca entra no treino.

8.15 MLOps de Visao

Pipeline reproduvel do dado ao deploy, integrado a stack do Cap. 4.



Componente	Escolha	Justificativa
Versao de dados	DVC + S3	Rastreia qual dataset gerou qual modelo (auditoria/reproducao)
Experimentos	MLflow (self-host) ou W&B	Comparar runs, hiperparametros, metricas
Model Registry	MLflow Registry	Estagios dev->staging->prod, rollback
Serving	NVIDIA Triton	Multi-modelo, batching dinamico, GPU eficiente; suporta TensorRT/ONNX
Otimizacao	ONNX + TensorRT / quantizacao INT8	2-4x throughput, custo menor de GPU
Edge (futuro)	TensorRT / CoreML / TFLite	Pre-triagem no app offline
Monitoramento	Prometheus/Grafana (Cap.4) + drift de embedding	Detecta degradacao antes do cliente reclamar
CI/CD ML	GitHub Actions + gate de metricas	So promove modelo que bate o gold set

Decisoes: Triton + TensorRT pela eficiencia de GPU (reduz custo de inferencia, o maior OPEX do modulo). **Treino em GPU spot** (economia de 60-80% **[VALIDAR]**). **Gate automatico:** nenhum modelo vai a producao sem superar o gold set e sem regressao em nenhuma classe critica. **Monitoramento de drift** (distribuicao de imagens muda com estacao, cultura, modelo de drone) dispara re-treino. **Human-in-the-loop e parte do MLOps**, nao um extra.

8.16 Custos, Cronograma, Riscos e Prioridade

Custo de construcao (ESTIMATIVA de trabalho — **[VALIDAR]**):

Bloco	Esforco	Custo R\$	Custo US\$	Fase
Coleta + rotulagem dataset MVP	3-5 meses (BPO+interno)	R\$ 120k-260k	US\$ 22k-48k	MVP
Pipeline deteccao+seg+severidade	2 eng. CV x 4 meses	R\$ 180k-300k	US\$ 33k-56k	MVP
OCR + orquestrador de laudo + ERP	1,5 eng. x 3 meses	R\$ 90k-150k	US\$ 17k-28k	MVP
MLOps (Triton, DVC, registry, CI)	1 eng. MLOps x 3 meses	R\$ 80k-140k	US\$ 15k-26k	MVP/GA
Anomalia + classes raras + PCB	2 eng. x 4 meses	R\$ 130k-260k	US\$ 24k-48k	GA
Licenca Ultralytics comercial	anual	R\$ 20k-40k	US\$ 3,7k-7,4k	MVP
Total construcao	—	R\$ 620k-1,15M	US\$ 115k-213k	MVP+GA
Infra inferencia (GPU)	por mes	R\$ 4k-14k/mes	US\$ 0,7k-2,6k/mes	escala com uso

Riscos e mitigacao:

Risco	Prob.	Impacto	Mitigacao
Dataset insuficiente / classes raras	Alta	Alto	Active learning, anomalia, augmentation, coleta em parceiros desde o dia 1
Falso negativo em defeito critico	Media	Critico (seguranca)	Recall>=0,95, HITL obrigatorio acima de limiar, camada de anomalia
Qualidade de foto ruim no campo	Alta	Medio	Captura guiada + QA on-device
Licenca AGPL (Ultralytics) em SaaS	Media	Medio-alto	Licenca comercial ou RT-DETR/RF-DETR (Apache)
Custo de GPU escala mal	Media	Medio	TensorRT/quantizacao, batching, spot, edge pre-triagem
Drift (nova cultura/modelo drone)	Media	Medio	Monitoramento + re-treino agendado
LGPD (fotos/local/serial)	Media	Alto	Consentimento, anonimizacao de fundo, dado self-host (Cap. seguranca)
Responsabilidade por laudo errado	Media	Alto	Laudo = "sugestao"; aprovacao humana; rastreabilidade de versao/evidencia

Prioridade: P0 para pipeline base (deteccao+seg+severidade+OCR+laudo+orcamento) nos grupos de alto valor; **P1** para anomalia/classes raras e OCR robusto; **P2** para PCB/microdefeitos, termografia e edge on-device.

8.17 Roadmap por Waves (resumo)

- **MVP:** captura guiada + QA; YOLOv11-seg (estrutural, helices, hidraulico, fixacao); ConvNeXt/DINOv2 severidade; PaddleOCR; orquestrador de laudo + orcamento automatico ligado ao ERP/Twin; HITL; dataset v1; MLOps minimo (DVC+MLflow+Triton).
- **GA:** RT-DETR onde precisar; SegFormer para areas difusas; anomalia (EfficientAD) para cauda longa; active learning maduro; ViT severidade; monitoramento de drift; metas de mAP>=0,85.
- **Scale:** PCB/microdefeitos com macro; termografia; edge on-device (TensorRT/TFLite) para pre-triagem offline; auto-label em larga escala.
- **Internacional:** OCR multi-idioma de etiquetas, adaptacao de dominio por regio/cultura, catalogo de pecas multi-fabricante (XAG, Jacto) no laudo.

Nota de fonte: nomes de arquiteturas/ferramentas (YOLO/Ultralytics, RT-DETR, RF-DETR, SAM 2, ViT, ConvNeXt, DINOv2, PatchCore/PaDiM/EfficientAD, PaddleOCR/TrOCR, Detectron2, Triton, DVC, MLflow, CVAT/Label Studio) sao projetos reais e amplamente conhecidos; numeros de precisao/custo/tempo aqui sao **ESTIMATIVAS** de trabalho a serem confirmadas por **benchmark interno no dataset da AeroCortex** e por **cotacao real** de nuvem e rotulagem antes de decisao de orcamento.

Capítulo 9 — IA Offline / Edge AI

Escopo: Este capítulo especifica a camada de **IA embarcada (Edge AI) e operacao offline-first** da AeroCortex (nome de trabalho, a validar): como a plataforma continua **inteligente e util sem internet** — no meio do talhao, dentro de um galpao de zinco, numa oficina rural com 3G intermitente. Definimos (1) **por que** offline-first e requisito, nao luxo, no agro brasileiro; (2) a **comparacao tecnica de runtimes de inferencia edge** (ONNX Runtime, TensorFlow Lite/LiteRT, OpenVINO, ExecuTorch, MLC LLM, llama.cpp/GGUF, TinyML) e de **hardware** (Jetson Orin/Nano, Raspberry Pi, Intel NPU, Apple Neural Engine, Snapdragon AI); (3) as **tecnicas de compressao** — quantizacao INT8/INT4, destilacao, pruning; (4) a **arquitetura hibrida** que decide o que roda no dispositivo (CV leve, assistente, deteccao rapida) versus nuvem (modelos grandes, treino); (5) a **sincronizacao automatica offline-first** — fila, outbox pattern, CRDTs, resolucao de conflitos e sync de midia/laudos quando a rede volta; e (6) uma **stack de referencia por classe de dispositivo** (celular, tablet, Jetson na oficina), com custo, dificuldade, risco, cronograma e prioridade.

Aviso metodologico: Custos sao **ESTIMATIVAS** de trabalho (dimensionamento bottom-up de esforco de engenharia a custo/hora blended ~R\$ 200/h para perfil senior [VALIDAR] com folha real, + precos de lista de hardware/nuvem). **Cambio de trabalho:** US\$ 1,00 = R\$ 5,40 [VALIDAR cotacao do dia]. Este capítulo herda decisoes dos Caps. 4 (event-driven, S3, PostgreSQL, Kafka/Redis), 6 (Digital Twin como fonte/destino de estado), 7 (IA Preditiva) e 8 (Computer Vision — a "pre-triagem edge" prometida no Cap. 8 e detalhada aqui). Nomes de projetos/ferramentas citados sao reais e amplamente conhecidos; numeros de latencia/tamanho/custo sao **ESTIMATIVAS** a validar por **benchmark interno** no hardware-alvo.

9.1 Sumario Executivo do Capitulo


A conectividade e a **premissa mais fragil** de qualquer plataforma agro. O drone opera onde a fibra nao chega; o tecnico inspeciona em galpao metalico que bloqueia sinal; a oficina fica na estrada de terra. Se a AeroCortex so funciona online, ela **falha exatamente no momento de maior valor**. Por isso adotamos **offline-first como principio de arquitetura, nao como recurso opcional**: o app e utilizavel por padrao sem rede, e a nuvem e um acelerador (modelos grandes, treino, consolidacao), nao um pre-requisito de operacao.

Decisao mestra: arquitetura **hibrida em tres niveis de inferencia** — (A) **on-device** para tarefas de baixa latencia e alto valor offline: QA de imagem, pre-triagem de defeitos (CV leve), leitura de serial/OCR, regras de segurancas LiPo (deterministicas, do Cap. 7) e um **assistente LLM pequeno** de consulta a manuais; (B) **edge de oficina (Jetson)** para inferencia CV pesada e assistente maior quando ha um mini-servidor local; (C) **nuvem** para os modelos grandes, ensembles, treino, active learning e o VLM que redige laudo (Cap. 8). A regra de roteamento e simples: **se ha rede boa, usa nuvem (melhor qualidade); se nao ha, usa edge com degradacao graciosa e marca o resultado como "provisorio — a confirmar"**.

Decisao de runtime: padronizamos **ONNX Runtime** como *runtime unificado* de CV/tabular no edge (portabilidade Android/iOS/Linux/Jetson, mesmo modelo em toda a frota de dispositivos), com **delegates nativos** por plataforma (CoreML/ANE no iOS, NNAPI/QNN no Android/Snapdragon, **TensorRT** no Jetson conforme Cap. 8, OpenVINO em edge x86/Intel). Para o **assistente LLM offline**, **llama.cpp + GGUF** (CPU/GPU, maduro, roda ate em tablet e Jetson) como padrao, e **MLC LLM** onde quisermos explorar GPU movel agressivamente. Compressao padrao: **INT8** para CV (quantizacao pos-treino com calibracao) e **INT4** (GGUF Q4_K_M / AWQ) para LLM, com **destilacao** para criar as versoes "edge" dos modelos de nuvem.

Decisao de sincronizacao: **outbox pattern + fila local duravel** (SQLite/WatermelonDB no mobile) com **sync incremental idempotente**; **CRDTs (Automerger/Yjs)** apenas para os poucos documentos genuinamente colaborativos/mergeaveis (rascunho de laudo, checklist de inspecao, anotacoes), e **last-write-wins com relógio hibrido (HLC)** para o resto; midia (fotos/video) via **upload multipart resumivel para o S3** (Cap. 4), content-addressed para dedup.

Investimento estimado: ~R\$ 480 mil - R\$ 920 mil (US\$ 89 mil - US\$ 170 mil) ao longo de MVP -> GA -> Scale, mais **hardware de kit-oficina** (Jetson) a **~R\$ 3,5k-9k por unidade**. **Prioridade P0** para o motor de sincronizacao offline-first e a pre-triagem CV no celular (destravam a operacao de campo); **P1** para assistente LLM offline e kit-Jetson; **P2** para TinyML em perifericos.



9.2 Por Que Offline-First e Requisito (Contexto)

O Brasil rural tem cobertura celular **desigual e instavel**: talhoes fora de cobertura, galpoes metalicos que atenuam sinal, latencia alta e franquias de dados caras via satellite. Uma inspecao que exige upload de 40 fotos de 8 MP antes de dar qualquer feedback e **inutilizavel** nessas condicoes. O offline-first inverte a logica: **o valor e entregue localmente e imediatamente**; a nuvem recebe/melhora depois, de forma assincrona.

Cenario	Conectividade tipica	Exigencia offline
Operador no talhao (pre-voo/pos-voo)	Nenhuma a 3G fraco	Critica — checklist, semaforo apto/veta, foto
Tecnico em oficina rural	3G/4G intermitente	Alta — inspecao guiada, pre-triagem CV, laudo rascunho
Kit-oficina com mini-servidor	LAN local, WAN intermitente	Media — inferencia pesada local, sync em janela
Gestor no escritorio	4G/fibra estavel	Baixa — usa nuvem plena

Principio de design: *"funciona no avião em modo aviao"*. Toda tela critica de operacao/inspecao deve renderizar, capturar e dar um primeiro veredito **sem uma unica chamada de rede**. Rede e otimizacao, nao dependencia.

9.3 Comparacao de Runtimes de Inferencia Edge

Runtime e o motor que executa o modelo no dispositivo. A escolha define portabilidade, latencia e quais aceleradores (GPU/NPU) sao aproveitados.

Runtime	Tamanho binario (aprox.)	Latencia relativa	Hardware suportado	Licenca	Casos de uso	Maturidade
ONNX Runtime	~5-15 MB (mobile build)	Muito boa (com EP nativo)	CPU x86/ARM, GPU CUDA, CoreML/ANE, NNAPI, QNN, TensorRT, OpenVINO, DirectML	MIT	CV, tabular (XGBoost via ONNX), NLP encoder — runtime unificado cross-platform	Alta
TensorFlow Lite / LiteRT	~1-3 MB core	Muito boa (GPU/NNAPI delegate)	ARM CPU, GPU (OpenGL/Vulkan/Metal), NNAPI, Hexagon/QNN, Coral Edge TPU	Apache 2.0	CV/audio em Android e microcontroladores; ecossistema mobile maduro	Alta
OpenVINO	~30-100 MB	Excelente em Intel	Intel CPU, iGPU, NPU (Core Ultra) , VPU	Apache 2.0	Edge x86/Intel (kit-oficina alternativo, PC industrial)	Alta
ExecuTorch	~1-5 MB	Boa (em evolucao)	ARM CPU, CoreML/ANE, Vulkan, Qualcomm, MediaTek	BSD	Deploy de modelos PyTorch direto no edge; futuro do stack PyTorch mobile	Media (novo)
llama.cpp	~2-10 MB	Boa p/ LLM (CPU/GPU)	CPU x86/ARM (NEON/AVX), CUDA, Metal, Vulkan	MIT	LLM offline (assistente, RAG local) via GGUF	Alta
GGUF (formato)	— (formato de peso)	—	Consumido por llama.cpp/derivados	MIT (spec)	Formato quantizado padrao de LLM edge (Q4/Q5/Q8)	Alta
MLC LLM	~10-30 MB	Muito boa em GPU movel	GPU via TVM (Metal/Vulkan/CUDA), WebGPU	Apache 2.0	LLM em GPU de celular/tablet e browser	Media-alta
TinyML (TFLite Micro / uTensor)	~KBs-centenas KB	Ultra-baixa (MCU)	Microcontroladores (Cortex-M, ESP32)	Apache/MIT	Sensor/wake-word/anomalia em periférico (dock, sensor)	Media
"Edge AI" (guarda-chuva)	—	—	—	—	Termo abrangente para IA no dispositivo — engloba os acima	—

Recomendacao e por que:

- **ONNX Runtime = padrao unificado de CV/tabular.** Um unico formato (`.onnx`) roda em iOS (delegate CoreML->ANE), Android (NNAPI/QNN), Jetson (TensorRT EP) e x86 (OpenVINO EP). Isso reduz drasticamente o custo de manter modelos: **exportamos uma vez** do treino (Cap. 7/8) e distribuimos para toda a frota heterogenea. Trade-off: em Android puro, o **LiteRT** as vezes extrai mais performance do GPU/NNAPI — por isso o mantemos como **plano B por plataforma**, nao como padrao global.
- **llama.cpp + GGUF = padrao do assistente offline.** E o caminho mais maduro e portavel para LLM local (roda em CPU de tablet ate GPU de Jetson), com quantizacao INT4/INT5 pronta. **MLC LLM** fica como trilha de P&D para espremer GPU movel.
- **OpenVINO** entra **so** se optarmos por kit-oficina x86/Intel (mini-PC com NPU Core Ultra) em vez de Jetson — decisao de hardware (9.5), nao de app.
- **ExecuTorch** e a aposta de futuro (alinha com PyTorch), mas ainda **imaturo** para producao critica em 2026 — monitorar, nao depender.
- **TinyML** so no P2, para perifericos dedicados (ex.: sensor de temperatura de bateria no dock com deteccao de anomalia local).

9.4 Comparacao de Hardware Edge

Hardware	Poder de IA (aprox.)	RAM tipica	Consumo	Onde usamos	Runtime ideal	Custo unit. (ESTIMATIVA)
Jetson Orin Nano / NX	~40-100 TOPS (INT8)	8-16 GB	7-25 W	Kit-oficina (CV pesada, LLM medio)	ONNX+TensorRT, llama.cpp CUDA	R\$ 3,5k-9k / US\$ 650-1,7k
Jetson AGX Orin	~200-275 TOPS	32-64 GB	15-60 W	Hub regional / lab	TensorRT, Triton (Cap.8)	R\$ 12k-22k / US\$ 2,2k-4,1k
Raspberry Pi 5 (+ acelerador)	CPU only ~ baixo; +Hailo/Coral = ~13-26 TOPS	4-8 GB	5-12 W	Kit-oficina economico, gateway sync	ONNX RT / TFLite + delegate	R\$ 0,6k-2k / US\$ 110-370
Intel NPU (Core Ultra "Meteor/Lunar Lake")	~10-48 TOPS	16-32 GB (PC)	15-28 W	Mini-PC de oficina x86	OpenVINO	R\$ 4k-9k (mini-PC) / US\$ 740-1,7k
Apple Neural Engine (iPhone/iPad)	~16-38 TOPS	6-16 GB	movel	App iOS (operador/tecnico premium)	ONNX RT (CoreML EP) / CoreML	(device do usuario)
Snapdragon AI (Android flagship/mid)	~10-45 TOPS (Hexagon NPU)	6-16 GB	movel	App Android (maioria do campo)	ONNX RT (QNN) / LiteRT (NNAPI)	(device do usuario)

Recomendacao e por que:

- **Kit-oficina padrao = Jetson Orin Nano** (melhor custo/TOPS/ecossistema CUDA-TensorRT; reaproveita 100% dos modelos ONNX/TensorRT do Cap. 8; roda LLM 3B-8B em INT4). **Raspberry Pi 5 + Hailo-8L** e a **opcao economica** para oficinas pequenas (so pre-triagem, sem LLM local).
- **Mobile:** projetar para o **meio da tabela Android** (Snapdragon mid-range, NPU Hexagon), nao so para o topo — e onde esta a maioria dos operadores. iOS aproveita ANE automaticamente via CoreML EP.
- **Intel NPU/OpenVINO** so se um cliente ja tiver parque de mini-PCs x86 — evitamos introduzir uma terceira stack sem demanda.

9.5 Compressao de Modelos — Quantizacao, Destilacao, Pruning

Modelos de nuvem sao grandes demais para o edge. Reduzimos com tres tecnicas complementares:


Tecnica	O que faz	Ganho tipico (ESTIMATIVA)	Custo de acuracia	Quando usar
Quantizacao INT8 (PTQ)	FP32->INT8 com calibracao	~4x menor, ~2-4x mais rapido	Baixo (<1-2% mAP) com bom calib set	Padrao para CV no edge
Quantizacao INT4	pesos em 4 bits (GGUF Q4_K_M, AWQ, GPTQ)	~8x menor que FP16	Moderado (aceitavel p/ assistente)	Padrao para LLM offline
QAT (quant-aware training)	treina simulando quantizacao	recupera acuracia perdida	~esforco extra de treino	Se PTQ INT8 cair demais em classe critica
Destilacao (distillation)	modelo "aluno" pequeno imita "professor" grande	modelo 5-20x menor	Controlado	Criar a versao edge dos modelos de nuvem
Pruning estrutural	remove canais/filtros redundantes	20-50% menor/rapido	Baixo-moderado	Combinado com quantizacao

Politica AeroCortex: para CV, o pipeline de treino (Cap. 8) produz **duas saidas por modelo** — a versao *cloud* (FP16, precisao maxima) e a versao *edge* (destilada + INT8, exportada em ONNX). Para o **LLM offline**, partimos de modelos

abertos pequenos (~1B-3B para celular, ~7B-8B para Jetson), quantizados em **GGUF Q4_K_M**. Regra de aceite: a versao edge nao pode perder **recall em classe critica** (defeito/seguranca) acima de limiar definido — se perder, cai para QAT ou o dispositivo delega a decisao para a nuvem quando reconectar.

9.6 Arquitetura Híbrida — O Que Roda Onde

A decisao "on-device vs nuvem" segue quatro criterios: **latencia exigida, tamanho do modelo, sensibilidade (seguranca), e disponibilidade offline**.



Capacidade	Onde roda	Modelo/técnica	Motivo
QA de imagem (blur/luz/enquadramento)	On-device (sempre)	CNN minúscula INT8 / heurística	Feedback instantâneo na captura, zero rede
Pre-triagem de defeito (CV leve)	On-device	YOLO-nano/small destilado INT8 (ONNX)	Veredito imediato; nuvem confirma depois
OCR de serial	On-device	detector leve + PaddleOCR-lite	Casar com Twin offline
Regras segurança LiPo	On-device (determinístico)	limites físicos (Cap.7)	Nunca pode depender de rede — fail-safe
Semaforo pre-voo apto/veta	On-device	XGBoost->ONNX + regras	Go/no-go no talhão sem sinal
Assistente de manual/duvida	On-device (fallback) / Nuvem (padrão)	LLM 1-3B GGUF local; Claude na nuvem	Consulta offline com RAG local dos manuais
Laudo em linguagem natural (redação)	Nuvem (VLM) / rascunho edge	VLM Cap.8; template local offline	Qualidade de redação exige modelo grande
Deteção fina (PCB, microdefeito)	Nuvem ou Jetson	modelos pesados	Não cabe em celular
Ensemble/anomalia de cauda longa	Nuvem	PatchCore/EfficientAD (Cap.8)	Precisão e dado; batch
Treino / Active learning / drift	Nuvem (sempre)	pipeline Cap.7/8	GPU e dado centralizado

Regra de ouro da degradação graciosa: todo resultado gerado offline por modelo edge nasce com flag `confidence_source = "edge_provisional"`. Ao sincronizar, se houver rede, a nuvem **re-processa** com o modelo grande e **promove/corrigir** o resultado, notificando o usuário apenas se houver divergência material. Isso dá o melhor dos dois mundos: **resposta imediata offline + qualidade final online**.

9.7 Escolha de Modelo por Classe de Dispositivo

Classe	Hardware-alvo	CV	LLM offline	Runtime	Orcamento de recursos
Celular (maioria)	Snapdragon mid / ANE	YOLO-nano INT8 (~3-8 MB)	Nenhum ou 1B GGUF Q4 (opcional)	ONNX RT + NNAPI/QNN/CoreML	<100 MB modelos, <300 ms/foto
Celular topo / Tablet	Snapdragon flagship / iPad	YOLO-small INT8, seg leve	1-3B GGUF Q4 (assistente)	ONNX RT + delegate; llama.cpp	<500 MB, <150 ms/foto
Kit-oficina Jetson	Orin Nano/NX	YOLO-M/L, seg, anomalia leve	7-8B GGUF Q4 (assistente pleno)	ONNX+TensorRT; llama.cpp CUDA	GBs; usa TensorRT do Cap.8
Kit economico	RPi5 + Hailo/Coral	YOLO-nano/small INT8	Nenhum	ONNX RT / TFLite + delegate	pre-triagem apenas
Nuvem	GPU (Cap.4)	pipeline completo Cap.8	Claude / VLM	Triton/TensorRT	sem restrição edge

Decisão: projetamos o **modelo edge de CV para o pior caso viável** (celular mid-range) e deixamos os dispositivos melhores rodarem versões maiores. Um único *catálogo de modelos versionados* (no S3/registry, Cap. 4/8) serve variantes por *tier* de dispositivo; o app baixa a variante certa no primeiro login e via OTA.

9.8 Assistente LLM Offline


O assistente (consulta a manuais, procedimento de reparo, interpretação de código de erro) usa **RAG local**: os manuais/procedimentos são indexados em um **vetor store embarcado** (SQLite + `sqlite-vec` ou index FAISS-lite) no dispositivo; a consulta recupera trechos e um **LLM pequeno** redige a resposta citando a fonte.



Decisao: quando **online**, o assistente usa **Claude** (qualidade, contexto grande, sempre atualizado — Cap. de IA/plataforma). Quando **offline**, cai para o **LLM local** com aviso claro de que a resposta é "assistida offline" e pode ser confirmada. Modelo local: **1-3B no mobile** (so tablets/celulares fortes), **7-8B no Jetson**. Isso evita a armadilha de tentar rodar LLM grande em celular fraco — melhor **nao ter assistente offline** naquele device do que ter um que trava e da respostas ruins.

9.9 Sincronizacao Automatica Offline-First

O coracao do offline-first é o **motor de sync**. Principios: (1) o dispositivo é **fonte de verdade local** enquanto offline; (2) escritas são **idempotentes** e carregam **ID gerado no cliente (UUID) + relógio híbrido (HLC)**; (3) **outbox pattern** garante que nada se perde; (4) sync é **incremental e retomavel**.



Padroes de sincronizacao

Padrao	Uso na AeroCortex	Por que
Outbox pattern	toda mutacao offline (OS, inspecao, laudo, estoque)	Durabilidade: mutacao persiste local ate confirmada pelo servidor
Fila duravel + retry com backoff	envio de mutacoes e midia	Rede intermitente; reenvio automatico sem duplicar (idempotencia)
Idempotencia por client-UUID	criacao de registros	Evita duplicata se o ACK se perdeu
Relogio hibrido (HLC)	ordenacao de eventos multi-device	Ordena sem depender de relógio perfeito
CRDT (Automerge/Yjs)	rascunho de laudo, checklist, anotacoes colaborativas	Merge automatico sem perder edicoes concorrentes
Last-Write-Wins + HLC	campos simples (status, valores escalares)	Simples e suficiente para a maioria dos campos
Upload multipart resumivel + content-hash	fotos/videos de inspecao	Retoma upload interrompido; dedup por hash
Delta sync (cursor/updated_at)	pull de catalogo, precos, modelos	Baixa so o que mudou; economiza dados

Resolucao de conflitos por tipo de entidade

Nao existe estrategia unica. Definimos por entidade:

Entidade	Estrategia	Justificativa
Rascunho de laudo / anotacao	CRDT (merge)	Dois tecnicos podem editar; nao pode perder texto
Checklist de inspecao	CRDT (por item)	Itens independentes, merge campo a campo
Status de OS (aberta/fechada)	LWW + regra de negocio	Transicoes validas so avancam (nao "reabre" por conflito)
Estoque / contagem de peca	Servidor autoritativo + reconciliacao	Numero financeiro: conflito vira tarefa de revisao, nunca merge cego
Foto/midia	Append-only (content-hash)	Midia nunca conflita; so acumula; dedup por hash
Resultado de IA (edge provisional)	Servidor re-processa e promove	Qualidade final e da nuvem (Sec. 9.6)

Decisao: usar **CRDT** so onde ha real concorrencia de edicao de texto/lista (laudo, checklist, anotacoes) — CRDT em tudo seria over-engineering, custa memoria e complexidade. Para **numeros financeiros/estoque**, conflito **nunca** e resolvido automaticamente por LWW: gera **tarefa de reconciliacao** para um humano, porque errar aqui e erro de dinheiro. Bibliotecas candidatas: **WatermelonDB/RxDB** (store + sync no React Native/mobile), **Automerge** ou **Yjs** (CRDT), tudo sobre **SQLite** local e o backend event-driven do Cap. 4.

9.10 Distribuicao e Atualizacao de Modelos (OTA) e Governanca

Modelos edge precisam ser **versionados, assinados e atualizaveis** sem republicar o app.

Aspecto	Decisao	Motivo
Distribuicao	catalogo de modelos no S3/CDN, download OTA no 1o login e em janela de rede	Nao inflar o binario da loja; atualizar sem release
Versionamento	semver por modelo + tier de device; registry (Cap.8)	Rastreabilidade e rollback
Assinatura/integridade	hash + assinatura; app valida antes de carregar	Seguranca: impedir modelo adulterado
Rollback	manter versao N-1 no device	Se modelo novo degrada, volta na hora
Telemetria de inferencia	logar confianca/latencia/divergencia (quando sincroniza)	Alimenta drift/active learning (Cap.7/8)
Privacidade (LGPD)	inferencia local nao envia imagem crua ate consentimento/sync; anonimizar	Cap. de seguranca/LGPD

9.11 Stack de Referencia Recomendada por Dispositivo

Dispositivo	Store local	Sync	Runtime IA	Modelos	Assistente
Celular Android (maioria)	WatermelonDB (SQLite)	outbox + delta + multipart S3	ONNX RT + NNAPI/QNN (LiteRT plano B)	YOLO-nano INT8, XGBoost->ONNX, QA-CNN	(opcional 1B) / Claude online
iPhone/iPad	WatermelonDB (SQLite)	idem	ONNX RT + CoreML (ANE)	idem + seg leve em topo	1-3B GGUF (iPad Pro) / Claude
Tablet tecnico	RxDB/WatermelonDB	idem + CRDT (laudo/checklist)	ONNX RT + delegate	YOLO-small, OCR-lite	3B GGUF / Claude
Kit-oficina Jetson Orin	SQLite/Postgres local	sync como gateway da oficina	ONNX + TensorRT; llama.cpp CUDA	YOLO-M/L, seg, anomalia leve	7-8B GGUF Q4
Kit economico RPi5	SQLite	gateway sync	ONNX RT / TFLite + Hailo/Coral	YOLO-nano/small INT8	—
Nuvem	PostgreSQL/Twin (Cap.4/6)	autoridade + reconciliacao	Triton/TensorRT (Cap.8)	pipeline completo + VLM	Claude

Justificativa da stack unica de runtime: um so formato de modelo (**ONNX**) + delegates por plataforma minimiza o custo de manutencao numa frota heterogenea; **llama.cpp/GGUF** cobre LLM offline de forma portavel; **WatermelonDB + outbox + CRDT seletivo** e o padrao offline-first mais provado para mobile. Evitamos multiplicar stacks (nao adotar TFLite e ONNX e ExecuTorch como padroes concorrentes — escolhemos um padrao e planos B pontuais).


9.12 Custos, Dificuldade e Cronograma

Custo de construcao (ESTIMATIVA de trabalho — [VALIDAR]):

Bloco	Esforço	Custo R\$	Custo US\$	Fase
Motor sync offline-first (outbox, fila, delta, idempotencia)	2 eng. x 3 meses	R\$ 130k-210k	US\$ 24k-39k	MVP
Pre-triagem CV no celular (export ONNX + delegates + QA)	1,5 eng. x 3 meses	R\$ 90k-150k	US\$ 17k-28k	MVP
Midia resumível + dedup + S3 pipeline	1 eng. x 2 meses	R\$ 45k-80k	US\$ 8k-15k	MVP
CRDT (laudo/checklist) + resolução de conflito	1 eng. x 2-3 meses	R\$ 55k-95k	US\$ 10k-18k	GA
Assistente LLM offline + RAG local	1,5 eng. x 3 meses	R\$ 90k-150k	US\$ 17k-28k	GA
Kit-oficina Jetson (integração TensorRT + provisionamento)	1 eng. x 2 meses	R\$ 45k-90k	US\$ 8k-17k	GA
OTA de modelos (assinatura, versionamento, rollback)	1 eng. x 1,5 mes	R\$ 35k-70k	US\$ 6k-13k	GA
TinyML periférico (P&D)	1 eng. x 2 meses	R\$ 45k-90k	US\$ 8k-17k	Scale
Total construção	—	R\$ 480k-920k	US\$ 89k-170k	MVP->Scale
Hardware kit-oficina	por unidade	R\$ 3,5k-9k	US\$ 650-1,7k	por cliente

Nível de dificuldade (1-5): motor de sync 4 (concorrência, idempotência, conflitos), CV edge 3, CRDT 4, LLM offline 3-4, OTA 3, TinyML 4.

Cronograma macro:



9.13 Riscos e Mitigacao

Risco	Prob.	Impacto	Mitigacao
Conflitos de sync corrompem dados (estoque/financeiro)	Media	Alto	LWW proibido em dado financeiro; reconciliacao humana; idempotencia + HLC
Modelo edge perde recall em defeito critico	Media	Alto (seguranca)	Aceite por recall minimo; QAT; degradacao graciosa (confirma na nuvem)
Fragmentacao de hardware Android (NPU/driver)	Alta	Medio	ONNX RT com fallback CPU; testar em tier mid-range real; LiteRT plano B
Modelo grande demais para celular fraco	Alta	Medio	Variantes por tier; desligar assistente offline em device fraco
Upload de midia estoura franquia/dados do cliente	Media	Medio	Compressao, WiFi-only opcional, upload em janela, dedup por hash
CRDT explode memoria/uso em docs grandes	Baixa-media	Medio	CRDT so em texto/lista pequenos; nao usar como banco geral
Modelo OTA adulterado / seguranca	Baixa	Alto	Assinatura + hash + validacao antes de carregar
LGPD: imagem crua/local sensivel no device	Media	Alto	Consentimento, inferencia local sem envio ate sync, anonimizacao
ExecuTorch/dependencia imatura	Baixa	Medio	Nao adotar como padrao; ONNX/llama.cpp maduros primeiro
Custo/logistica do kit Jetson	Media	Medio	Oferecer tier RPi5 economico; kit opcional, nao obrigatorio

Prioridade: P0 — motor de sync offline-first + pre-triagem CV no celular + midia resumivel (destravam a operacao de campo, o valor central do capitulo). **P1** — CRDT de laudo/checklist, assistente LLM offline, kit-Jetson + OTA. **P2** — TinyML em perifericos e otimizacoes de GPU movel (MLC LLM).

9.14 Roadmap por Waves (resumo)

- **MVP:** offline-first de fato — store local (WatermelonDB) + outbox + delta sync idempotente + upload de midia resumivel; pre-triagem CV no celular (YOLO-nano INT8 em ONNX RT com delegate nativo); QA de imagem on-device; regras de seguranca LiPo deterministicas offline (Cap. 7); semaforo pre-voo offline.
- **GA:** CRDT (Automerge/Yjs) para laudo/checklist/anotacoes + resolucão de conflito por entidade; assistente LLM offline (1-3B mobile, RAG local sqlite-vec); kit-oficina Jetson Orin (ONNX+TensorRT + llama.cpp 7-8B); OTA de modelos assinado com rollback; telemetria de inferencia realimentando drift/active learning.
- **Scale:** TinyML em perifericos (dock/sensor de bateria); MLC LLM em GPU movel; kit RPi5+Hailo economico; adaptacao de modelos edge por regioao/cultura.
- **Internacional:** assistente offline multi-idioma; catalogo de modelos por mercado; conformidade de dados por pais (residencia/soberania de dado no sync).

Nota de fonte: ONNX Runtime, TensorFlow Lite/LiteRT, OpenVINO, ExecuTorch, MLC LLM, llama.cpp/GGUF, TFLite Micro, Jetson (Orin/Nano/AGX), Raspberry Pi, Intel Core Ultra/NPU, Apple Neural Engine, Snapdragon/Hexagon, WatermelonDB, RxDB, Automerge, Yjs, sqlite-vec e FAISS sao projetos/produtos reais e amplamente conhecidos. **Numeros de TOPS, tamanho, latencia e custo sao ESTIMATIVAS** de trabalho — devem ser confirmados por **benchmark no hardware-alvo real da AeroCortex** e por **cotacao de mercado** (fornecedor de Jetson/RPi, precos de nuvem) antes de decisao de orcamento.